APPUNTI DEL CORSO

IDENTIFICAZIONE DEI MODELLI E ANALISI DEI DATI

A.A. 2017/2018 - UNIVERSITY OF BERGAMO

PARTE I: SISTEMI STATICI

AUTORE: MIRKO MAZZOLENI

L'uso e la distribuzione di questi appunti è consentita previa citazione dell'autore e della fonte originari

Corso di IDENTIFICAZIONE DEI MODELLI & ANALISI DEI DATI

1) IDENTIFICAZIONE DEI MODELLI

trovare il legame tra queste grandezze e descriverlo matematicamente

MODELLO: Descrizione matematica di un fenomeno o di un sistema
- economico: relazione tra reddito ed educazione
- sociale: relazione tra luogo di abitazione e criminalità
- fisico: relazione tra massa e peso di una persona $P = M \cdot g$
- $V = R \cdot I$

SISTEMA: Meccanismo astratto che trasforma input (cause) in output (effetti)

$u \longrightarrow [\ S\ ] \longrightarrow y$

Due approcci fondamentali:

a) WHITE BOX MODELING: - approccio basato su leggi e principi base della FISICA o CONOSCENZA A PRIORI
- es. modello di un condensatore $I(t) = C \cdot \frac{dV(t)}{dt}$

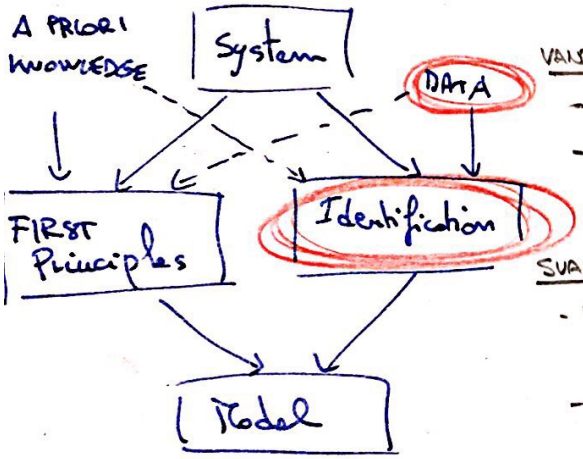

VANTAGGI
- conoscenza del significato delle variabili (C: capacità del condensatore)
- generalizzabile: se cambio C, il modello vale ancora
  - perché conosco una relazione CAUSALE tra C ed $I(t)$

SVANTAGGI
- richiede conoscenza avanzata delle leggi del problema SPECIFICO
  - tanto, costi alti
- per sistemi complessi la scrittura di molte equazioni diventa impossibile
- limitato a campi in cui esistono leggi CAUSALI

b) BLACK BOX MODELING: → approccio basato su DATI SPERIMENTALI

VANTAGGI
- prescindono dal particolare tipo di problema, limitandosi a caratterizzare il legame tra le variabili $y = f(u)$
- veloci da costruire

SVANTAGGI
- non interpretabili fisicamente
- non generali, dipendono dal tipo di dati acquisiti. Per ogni modifica del sistema, bisogna ripetere l'esperimento

IDENTIFICAZIONE DEI MODELLI → deve trovare un modello che mi descriva i dati
⇓
PROBLEMA DI STIMA → stima le caratteristiche di questi dati

2) ANALISI DEI DATI

- Determinare le caratteristiche statistiche dei dati e delle variabili misurate
  - Essi infatti sono affetti da RUMORE ed INCERTEZZA
  - media — correlazione tra variabili
  - varianza — distribuzione probabilistica

  } STATISTICA DESCRITTIVA

- Individuare una STRUTTURA, delle regolarità (se ci sono)
  - i dati presentano dei "PATTERN" riconoscibili o sono RANDOM?
  - possiamo ALLENARE algoritmi che MI SOLI individuino pattern)

  } ML

LE PROCEDURE 1) ed 2)

1) e 2) sono fortemente interconnesse:

i) Spesso l'analisi preliminare dei dati da indicazioni sul modello migliore per descriverli

ii) Tecniche di analisi dei dati sono usate per descrivere le bontà del modello

iii) Una rappresentazione probabilistica dei dati da luogo ad un modello probabilistico capace di gestire l'incertezza
  - sia nella misura
  - sia nella conoscenza della realtà
    - quantificare quello che non so

DECLINERETTO le due procedure sia per SISTEMI STATICI che per SIST. DINAMICI

- SISTEMI STATICI: la sola conoscenza delle variabili u e y è sufficiente a calcolare $y \Rightarrow V(t) = R \cdot I(t)$ (y = V, u = I)

- SISTEMI DINAMICI: è bisogno di sapere la condizione iniziale: $\frac{dV(t)}{dt} = \frac{1}{C} \cdot I(t)$
  per conoscere V(t) devo sapere $V(t_0)$
  - concetto di STATO: $V(t) = x_1(t) \Rightarrow \begin{cases} \dot{x}_1(t) = \frac{1}{C} \cdot u(t) \\ y(t) = x_1(t) \end{cases}$
    $I(t) = u(t)$
    $V(t) = y(t)$

- Fondamenti di automatica !! $\Rightarrow$ la G(s) era DATA. Come trovarla?: - WHITE BOX
  - BLACK BOX

$\Downarrow$

$G(z)$

IMAD

SISTEMI STATICI

STIMA PARAMETRICA → modello matematico che descrive y attraverso ϑ
- VARIABILI STOCASTICHE
- PROPRIETÀ STIMATORI

↓ OBIETTIVO: $\hat{\vartheta}$

- CASO 1) ϑ è deterministico (un numero/vettore)
  - Stima di proprietà dati una popolazione: $y = \mu, \sigma^2$ — NO ASSUNZIONI PDF
  - Applico struttura LINEARE a y: $y = \vartheta^T x + \varepsilon$
    - Minimi quadrati - Regressione lineare → NO ASSUNZIONI SU PDF
    - ANALISI PROBABILISTICA
  - Massima Verosimiglianza → SI ASSUNZIONI PDF
    - caso y
    - caso $y = \vartheta^T x + \varepsilon$

    SE PDF ~ N, ML = LS → Regressione lineare
  - Regressione Logistica → SI ASSUNZIONI PDF
- CASO 2) ϑ variabile casuale
  - Stima Bayesiana

CONCETTI DI MACHINE LEARNING
- INTRO
- BIAS/VARIANCE
- REGOLARIZATION
- VALIDAZIONE

(3')

SISTEMI DINAMICI

STIMA PARAMETRICA
- PROCESSI STOCASTICI
- PROPRIETÀ STIMATORI

- caso ϑ deterministico
  - MODELLI LINEARI DI PROCESSI STOCASTICI STAZIONARI
  - PREDIZIONE (ad un passo)
  - IDENTIFICAZIONE
    - Metodo dei minimi quadrati (ARX)
    - " " massima verosimiglianza (ARMAX)
  - PERSISTENTE ECCITAZIONE
  - ANALI ASINTOTICA PEM
  - ANALISI INCERTEZZA STIMA (N finito)
  - COMPLESSITÀ MODELLO
  - NON-LINEARI (se stiesco...)

RICHIAMI DI STATISTICA

- Una variabile casuale $|V|$ è una variabile definita a partire dall'esito $|S|$ di un esperimento casuale → Es. L'esperimento è il lancio di una moneta. A seconda se esce testa o croce, V assume un valore

  L indichiamo una v.c. come $|V(S)|$

  L il valore assunto da V a seguito di un particolare esito $|\bar{S}|$ è $V(\bar{S})$

$$V = \begin{cases} 1 & \text{se } S = \text{TESTA} \\ 0 & \text{se } S = \text{CROCE} \end{cases}$$

Se V può assumere diversi valori, come li descriviamo? ⇒ Assegno una probabilità che ogni esito occada => questo influisce sulla probabilità dei valori che V può assumere

- Se V assume valori DISCRETI (V è una variabile casuale discreta)

  L funzione di probabilità di massa $p(x) = P(V = x)$ associa ad ogni valore x di V una probabilità (pmf)

  Indichiamo con x_i i valori di V. Se V può assumere n diversi valori, allora $\sum_{i=1}^{n} p(x_i) = 1$

Esempio DADO

$x_1 = 1$ $p(x_1) = P(V = x_1) = P(V = 1) = 1/6$

$x_2 = 2$ $p(x_2) = P(V = 2) = 1/6$

$\vdots$ $\vdots$

$x_6 = 6$

$m = 6$ $p(x_6) = P(V = 6) = 1/6$

$$\sum_{i=1}^{6} p(x_i) = 6 \cdot \frac{1}{6} = 1$$

- Se V assume valori CONTINUI (V è una v.c. continua)

  L funzione di densità di probabilità $f(x)$ (pdf)

  Es V è l'altezza di un uomo adulto

  b) non ha senso chiedersi la probabilità che un uomo sia alto ESATTAMENTE 1,7235162... metri

  - ~~$P(V = x)$~~ = $P(V = x)$ NON HA SENSO $= P(V = x) = 0$

    ci sono infiniti possibili valori: la prob. che sia esattamente uno di quelli è zero

    ← anche se i valori fossero equiprobabili come nel dado, la prob. di un valore sarebbe $\frac{1}{\infty} \Rightarrow$

$$P(V \in [a,b]) = \int_a^b f(x)\,dx$$

- $f(x) \geq 0$
- $\int_{-\infty}^{+\infty} f(x) = 1$

- Funzione di densità cumulata (cdf) o distribuzione di probabilità

$$F(z) = \int_{-\infty}^{z} f(x)\,dx = P(x \leq z)$$

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}}\, e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

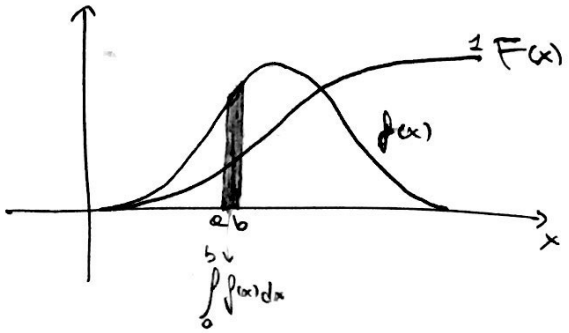

A FINI PRATICI x È DISCRETA

$f(x) \propto P(V = x)$

- Il VALORE ATTESO di una v.c. CONTINUA è:

$$E[v] = \int_{-\infty}^{+\infty} x \cdot f(x)\, dx$$

somma pesata dei valori x che v può assumere. I pesi sono la prob $f(x)$. Peso ogni valore per la sua probabilità di manifestarsi

- LINEARITÀ: $E[\alpha v_1 + \beta v_2 + \gamma] = \alpha E[v_1] + \beta E[v_2] + \gamma \quad \forall \alpha, \beta, \gamma \in \mathbb{R}$

- La varianza di una v.c. continua è:

$$Var[v] = \int_{-\infty}^{+\infty} (x - E[v])^2 \cdot f(x)\, dx$$

$$= E\left[(x - E[v])^2\right]$$

- di quanto i valori x si scostano dalla loro media
- se piccola, v assume valori molto vicini fra loro

Osservazione

- $Var[v] \geq 0$. Se $Var[v] = 0$, la variabile v è deterministica (assume sempre un solo valore)
- Deviazione standard: $\sigma[v] = \sqrt{Var[v]}$

$$- \boxed{Var[v] = E\left[(v - E[v])^2\right]} = E\left[v^2 - 2E[v]v + E[v]^2\right] = E[v^2] - 2E[v \cdot E[v]] + E[E[v]^2]$$

$$= E[v^2] - 2E[v] \cdot E[v] + E[v]^2 = \boxed{E[v^2] - E[v]^2}$$

- $Var[\alpha \cdot v_1 + \beta] = \alpha^2 \cdot Var[v_1] \quad \forall \alpha \in \mathbb{R}, \forall \beta \in \mathbb{R}$

- Date due v.c. v_1 e v_2 si definisce il coefficiente di correlazione come:

$$\rho = \frac{E[(v_1 - E[v_1]) \cdot (v_2 - E[v_2])]}{\sigma[v_1] \cdot \sigma[v_2]}$$

- ρ indica il grado di dipendenza lineare tra v_1 e v_2. Infatti se $v_2 = \alpha v_1 + \beta \Rightarrow \rho = 1$
- Se $\rho = 0$ le due variabili si dicono scorrelate

- Date v_1 e v_2 si definisce ~~covarianza~~ la covarianza come

$$Cov(v_1, v_2) = E[(v_1 - E[v_1]) \cdot (v_2 - E[v_2])]$$

e quindi:

$$\rho = \frac{Cov(v_1, v_2)}{\sigma[v_1] \cdot \sigma[v_2]}$$

- v_1 e v_2 sono scorrelate se $Cov(v_1, v_2) = 0$

- Le precedenti definizioni si possono estendere al caso di vettori di variabili casuali $\bar{v} = [v_1, v_2, \dots, v_d]^T$

- distribuzione di probabilità $F(x_1, x_2, x_3, \dots, x_d) = P(v_1 \le x_1, v_2 \le x_2, \dots, v_d \le x_d)$

$$= \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \dots \int_{-\infty}^{x_d} \underbrace{f(x_1, x_2, \dots, x_d)}_{\text{pdf congiunta}} \, dx_1 \, dx_2 \dots dx_d$$

- valor atteso è un vettore colonna di d componenti

$$E[\bar{v}] = [E[v_1], E[v_2], \dots, E[v_d]]^T \in \mathbb{R}^{d \times 1}$$

- la varianza è una matrice $d \times d$ semidefinita positiva e SIMMETRICA
  - L simile al ≥ 0 per numeri reali
  - L $M_{d \times d}$ reale è semidefinita positiva se $z^T_{1 \times d} M_{d \times d} z_{d \times 1} \ge 0$, $\forall z \in \mathbb{R}^d$ (e simmetrica)
  - L autovalori > 0 tranne $\lambda_i = 0$

$$Var[\bar{v}] = \int_{\mathbb{R}^d} \underbrace{(x - E[\bar{v}])}_{d \times 1} \underbrace{(x - E[\bar{v}])^T}_{1 \times d} f(x) \, \underbrace{dx}_{x \in \mathbb{R}^{d \times 1}}$$

$x \in \mathbb{R}^{d \times 1}$

$$\begin{bmatrix} VAR[v_1] & Cov(v_1, v_2) \\ Cov(v_2, v_1) & VAR[v_d] \end{bmatrix} \in \mathbb{R}^{d \times d}$$

- COVARIANZE TRA $v_1 e v_2$, $v_1 e v_3$, ____
- SIMMETRICA: la covarianza tra $v_1 e v_2$ è la stessa che tra $v_2 e v_1$

→ VARIANZE DI $v_1, v_2, \dots, v_d$

MATRICE DI VARIANZE - COVARIANZE

- Due variabili casuali v_1 e v_2 con funzione di probabilità congiunta f si dicono indipendenti se e solo se:

$$f(x_1, x_2) = f(x_1) \cdot f(x_2)$$

Teorema

Se v_1 e v_2 sono indipendenti, allora sono scorrelate

ovviamente μ e σ^2 determinano cose sono le caratteristiche dei miei dati

Es la densità di probabilità di y ha una forma funzionale nota che dipende da (θ^0) $\theta^0 \in \mathbb{R}^2$ $d=2$

STIMA

Obbiamo detto che ci concentriamo sulla STIMA PARAMETRICA. Vogliamo quindi stimare il parametro θ^0 che le genera: dati $D = \{y(1), \dots, y(M)\}$

Interpretiamo: dati come v.c. per tenere l'incertezza, l'incertezza nella fase misura

$D = D(\underline{s}, \theta^0)$ → i dati sono variabili casuali

↳ dipendono dallo specifico esito $\bar{s}$ quelli che noi osserviamo $\Rightarrow D = D(\bar{s}, \theta^0)$

che associa ai dati un valore del parametro da stimare

Uno STIMATORE è una funzione $T(D(s, \theta^0))$. La STIMA è il risultato di uno stimatore su una SPECIFICA realizzazione dei dati $\hat{\theta} = T(D(\bar{s}, \theta^0))$ → poiché il risultato di T dipende dall'esito s (da cui dipendono i dati), allora lo stimatore è una variabile casuale dipendente da s

Es

Misuro il peso (modo) degli studenti che fanno IMAD $\Rightarrow \hat{\theta}_1 = T(D(s_1, \theta^0))$

↳ peso misurato solo 5 studenti $D = \{y(1) - y(5)\} \Rightarrow \hat{\theta}_2 = T(D(s_2, \theta^0))$

Ha senso quindi calcolare valore atteso e varianza di questa variabile casuale: in base a queste, valuteremo le bontà di uno stimatore.

PROPRIETÀ DI UNO STIMATORE

- Uno stimatore si dice corretto se e solo se: $E[\hat{\theta}] = \theta^0$
  ↳ altrimenti avrei un errore sistematico di stima

- Uno stimatore si dice asintoticamente corretto se e solo se: $\lim_{N \to \infty} E[\hat{\theta}] = \theta^0$
  - è una proprietà più debole

PRIMA DEF. CONSISTENTE

Se due stimatori sono entrambi corretti, qual è il migliore? Quello a minima varianza

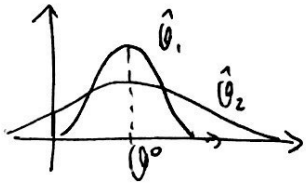

$\hat{\theta}_1$ ha una maggior probabilità di ritornare una stima vicina al valore vero!

- Uno stimatore si definisce <u>consistente</u> se: $\lim_{N\to\infty} Var[\hat{\theta}] = 0$

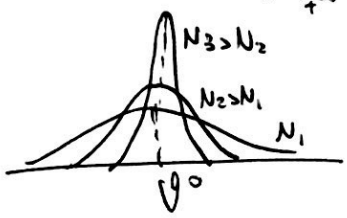

- la consistenza garantisce che all'aumentare del numero dei campioni la qualità della stima aumenta
- Se $\hat{\theta}$ è corretto si ha che $Var[\hat{\theta}] = E[(\hat{\theta} - E[\hat{\theta}])^2] = E[(\hat{\theta} - \vartheta^\circ)^2] = Var[\varepsilon^2]$

$\varepsilon = \hat{\theta} - \vartheta^\circ$ = ERRORE DI STIMA

- Uno stimatore corretto si dice <u>ottimo</u> se la sua varianza è la più piccola per una serie N di dati $D = \{y_{(1)}, y_{(2)}, \dots, y_{(N)}\}$

<u>ES</u> STIMATORE MEDIA

Siano $D = \{y_{(1)}, \dots, y_{(N)}\}$ variabili casuali con media μ e varianza σ^2. Lo stimatore media campionaria $\hat{\mu} = \frac{1}{N}\sum_{i=1}^{N} y_{(i)}$ è corretto. Infatti $E[\hat{\mu}] = E\left[\frac{1}{N}\sum_{i=1}^{N} y_{(i)}\right] = \frac{1}{N}\sum_{i=1}^{N} E[y_{(i)}] = \frac{1}{N} \cdot N \cdot \mu = \mu$

Si dimostra che è consistente, $Var[\hat{\mu}] = \frac{Var[y]}{N} = \frac{\sigma^2}{N}$

<u>ES</u> STIMATORE VARIANZA

$D = \{y_{(1)}, \dots, y_{(N)}\}$ con varianza σ^2 e media $\hat{\mu}$. Lo stimatore S^2_{N-1} è corretto, $S^2_{N-1} = \frac{\sum_{i=1}^{N} (y_{(i)} - \hat{\mu})^2}{N-1}$

$= Var\left[\frac{1}{N}\sum_{i=1}^{N} y_{(i)}\right] = \frac{1}{N^2}\sum_{i=1}^{N} Var[y_{(i)}] = \frac{1}{N^2} \cdot N \cdot \sigma^2 = \frac{\sigma^2}{N} = \frac{Var[y]}{N}$

$\frac{1}{N}\sum_{i=1}^{N} y_{(i)} = \hat{\mu}$

$$S^2_{N-1} = E\left[\frac{1}{N-1}\sum_{i=1}^{N}(y_{(i)} - \hat{\mu})^2\right] = E\left[\frac{1}{N-1}\sum_{i=1}^{N}\left(y_{(i)}^2 + \hat{\mu}^2 - 2y_{(i)}\hat{\mu}\right)\right] \overset{\text{SPEZZO}}{=} E\left[\frac{1}{N-1}\left(\sum_{i=1}^{N} y_{(i)}^2 + N\hat{\mu}^2 - 2\hat{\mu}\sum_{i=1}^{N} y_{(i)}\right)\right] =$$

$$= E\left[\frac{1}{N-1}\left(\sum_{i=1}^{N} y_{(i)}^2 + N\hat{\mu}^2 - 2\hat{\mu} \cdot N\hat{\mu}\right)\right] = E\left[\frac{1}{N-1}\left(\sum_{i=1}^{N} y_{(i)}^2 - N\hat{\mu}^2\right)\right] = E\left[\frac{1}{N-1}\sum_{i=1}^{N} y_{(i)}^2 - \frac{N}{N-1}\hat{\mu}^2\right]$$

$$= \frac{1}{N-1}\left(\sum_{i=1}^{N} E[y_{(i)}^2] - N \cdot E[\hat{\mu}^2]\right) = \frac{1}{N-1}\left(N \cdot E[y_{\xi}^2] - N E[\hat{\mu}^2]\right) = \frac{N}{N-1}\left(E[y_{\xi}^2] - E[\hat{\mu}^2]\right)$$

$Var[y] = E[y^2] - E[y]^2$

$$= \frac{N}{N-1}\left(Var[y_{\xi}] + E[y]^2 - Var[\hat{\mu}] - E[\hat{\mu}]^2\right) = \frac{N}{N-1}\left(Var[y] + \mu^2 - Var[\hat{\mu}] - \mu^2\right)$$

$$= \frac{N}{N-1}\left(Var[y] - \frac{Var[y]}{N}\right) = \frac{N}{N-1}\left(\frac{(N-1)\,Var[y]}{N}\right) = Var[y] = \sigma^2$$

<u>CORRETTO!</u>

LIMITE DI CRAMER-RAO (CRAMER-RAO BOUND)

Stabilisce un limite inferiore per la varianza di un qualsiasi stimatore
↓
non posso essere più preciso di un certo valore
↳ questo perché i dati sono affetti da un errore di misura che non posso rimuovere con la mia stima

Nel caso di stimatori corretti dobbiamo che: $\mathrm{Var}[\hat{\theta}] \geq m^{-1}$ m: quantità di informazione di Fisher
↳ se $\hat{\theta}$ è un vettore di d: $\underset{d\times d}{\mathrm{Var}[\hat{\theta}]} - \underset{d\times d}{M^{-1}} \geq 0$ ↳ la differenza è semi-definita positiva

più è grande, più è facile stimare θ° dai dati, ovvero più è buona la stima di θ° → la varianza è inversamente proporzionale infatti se m è grande la varianza è piccola

- Uno stimatore si dice **efficiente** se $\mathrm{Var}[\hat{\theta}] = m^{-1}$
- Uno stimatore si dice **asintoticamente efficiente** se $\lim_{N\to\infty} \mathrm{Var}[\hat{\theta}] = m^{-1}$

STIMA DI MODELLI LINEARI:

STIMA A MINIMI QUADRATI (LEAST SQUARES)

Obbiamo finora descritto i dati $D = \{y(1), \dots, y(N)\}$ in termini della loro media e varianza, dando degli stimatori per queste due quantità $\hat{\mu} = \frac{1}{N}\sum_{i=1}^{N} y(i)$, $S^2_{N-1} = \frac{\sum_{i=1}^{N}(y(i)-\hat{\mu})^2}{N-1}$

Supponiamo ora di **voler descrivere** i dati D tramite una **relazione lineare**:

supponga ipotesi che i dati abbiano questa struttura, la impongo

$$y(i) = \theta_0 + \theta_1 x_1(i) + \theta_2 x_2(i) + \dots + \theta_{d_1} x_{d_1}(i) + \boldsymbol{e(i)}$$ ← errore

dove $x_1, x_2, \dots, x_{d_1}$ sono variabili di cui si dispongono misure. Questo modello prende il nome di **regressione lineare**

↓ regressori o features

Es

y = Peso [kg]
x_1 = altezza [m] => variabile numerica (c'è ordinamento e quantifico la distanza)
x_2 = sesso [M/F] => variabile categoriale (non c'è ordinamento)
⋮
x_{d_1} = luogo di nascita [≡]

Voglio esprimere il peso in funzione delle varie $x_1, x_2, \dots, x_d$

N persone misurate

Definiamo i vettori:

$$\underset{d\times 1}{\theta} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_{d_1} \end{bmatrix} \qquad \underset{d\times 1}{\varphi(i)} = \begin{bmatrix} 1 \\ x_1(i) \\ x_2(i) \\ \vdots \\ x_{d_1}(i) \end{bmatrix} \Rightarrow$$

$$\underset{1\times 1}{y(i)} = \underset{1\times d}{\varphi(i)^T} \cdot \underset{d\times 1}{\theta} + e(i), \quad i = 1 \dots N$$

$[\text{——}] \cdot [\,|\,]$

Approfondimento

Possiamo misurare le stesse entità con diversi tipi di variabili. Ad esempio, i partecipanti ad una maratona possono essere rappresentati come:

1) Tempo impiegato per raggiungere il traguardo ⇒ VARIABILE METRICA (NUMERICA)
2) Posizione di arrivo (primo, secondo, terzo, ...) ⇒ VARIABILE ORDINALE
3) Nome del team di appartenenza ⇒ VARIABILE NOMINALE (CATEGORICA)

VARIABILE METRICA (METRIC VARIABLE)

- Descrivono una quantità (es. tempo, altezza, temperatura, peso)
- È definito un ordinamento (si dice quale valore è "più grande" di un altro)
- È definita una distanza (si "quanto" un numero è più grande di un altro)

Un caso speciale di variabile metrica è una VARIABILE CONTEGGIO (COUNT VARIABLE)
- L esprime il numero di eventi occorsi (nel tempo o nello spazio)
- L ES. numero di macchine transitate al casello in un'ora

VARIABILE ORDINALE

- Descrivono oggetti sui quali ha senso imporre un ordine
- Non ha senso chiedersi "di quanto" una volta è più grande di un altra
- ES. Posizionamento in una corsa (primo, secondo, ...)
- L Grado di confidenza su un argomento (0 = non confidente; 1 = poco confidente, ... 5 = molto confidente)
- L Taglia di un vestito (XS, S, M, L, XL)

VEDI RETRO

VARIABILE CATEGORICA

- Descrive delle categorie di appartenenza
- Non ha senso imporre un ordinamento
- " " chiedersi di quanto un valore è più grande di un altro
- ES
- L Sesso: (M/F)
- L Affiliazione politica (REPUBBLICANI/DEMOCRATICI)
- L Colore degli occhi (BLU, VERDE, MARRONE)

PERCHÈ CI INTERESSA IL TIPO DI VARIABILE?

Ci interessa perché, a seconda del tipo di variabile, utilizziamo un modello appropriato per quel tipo

Es

1) VARIABILE METRICA: $y \sim N(\mu, \sigma^2)$
2) VARIABILE COUNT: $y \sim \text{Poisson}(\lambda)$ λ: # medio eventi nell'unità di tempo
3) VARIABILE CATEGORICA DICOTOMICA $(y=0, y=1)$: $y \sim \text{Bernoulli}(\pi)$ π: probabilità che $y=1$

Esistono modelli più complessi per dati ordinali.

Consiglio

Uno degli step iniziali per sviluppare un modello dei dati è DETERMINARE LA TIPOLOGIA DELLE VARIABILI in gioco

8.5 RETRO

Il metodo dei MINIMI QUADRATI minimizza la somma quadratica tra i dati ed il modello

$$J(\theta) = \frac{1}{N}\sum_{i=1}^{N} \underset{1\times 1}{\left(y(i) - \underset{1\times d}{\varphi(i)^T}\underset{d\times 1}{\theta}\right)^2} = \sum_{i=1}^{N} e(i)^2$$

Voglio il $\hat{\theta}$ che minimizza questa quantità

GRADIENTE

$$\nabla J(\theta) = \frac{dJ(\theta)}{d\theta} = 0 \Rightarrow \frac{2}{N}\sum_{i=1}^{N} \underset{d\times 1}{\varphi(i)} \cdot \left(\underset{1\times 1}{y(i)} - \underset{1\times d}{\varphi(i)^T}\underset{d\times 1}{\theta}\right) = 0 \Rightarrow \sum_{i=1}^{N} \underset{d\times 1}{\varphi(i)}\underset{1\times 1}{y(i)} - \sum_{i=1}^{N} \underset{d\times 1}{\varphi(i)}\underset{1\times d}{\varphi(i)^T}\underset{d\times 1}{\theta} =$$

$$\Rightarrow \left[\sum_{i=1}^{N} \varphi(i)\varphi(i)^T\right]\theta = \sum_{i=1}^{N} \varphi(i)y(i) \Rightarrow \boxed{\underset{d\times 1}{\hat{\theta}} = \left[\sum_{i=1}^{N} \underset{d\times 1}{\varphi(i)}\underset{1\times d}{\varphi(i)^T}\right]^{-1} \cdot \left[\sum_{i=1}^{N} \underset{d\times 1}{\varphi(i)}\underset{1\times 1}{y(i)}\right]}$$

$d\times d$ $\quad$ $d\times 1$

Osservazioni

- Se $\det\left[\sum_{i=1}^{N} \varphi(i)\varphi(i)^T\right] \neq 0$ la soluzione è UNICA!
- " " $= 0$, $\exists$ INFINITE SOLUZIONI
- Dato che il modello è lineare e la funzione di costo quadratica, essa sarà una forma quadratica di θ.
  - Si dimostra che $\hat{\theta}$ è MINIMO GLOBALE di $J(\theta)$

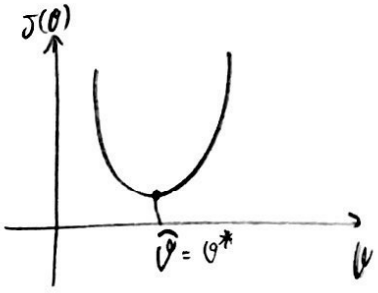

MINIMI QUADRATI - NOTAZIONE MATRICIALE

$$\underset{N\times d}{X} = \begin{bmatrix} 1 & x_1(1) & x_2(1) & \cdots & x_{d-1}(1) \\ 1 & x_1(2) & x_2(2) & \cdots & x_{d-1}(2) \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_1(N) & x_2(N) & \cdots & x_{d-1}(N) \end{bmatrix} \quad \underset{d\times 1}{\theta} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_{d-1} \end{bmatrix} \quad \underset{N\times 1}{Y} = \begin{bmatrix} y(1) \\ y(2) \\ \vdots \\ y(N) \end{bmatrix} \quad \underset{N\times 1}{E} = \begin{bmatrix} e(1) \\ e(2) \\ \vdots \\ e(N) \end{bmatrix}$$

$\varphi(1)^T$ (1×d)

↳ ogni colonna è un regressore / feature

$$\|X\|_{d\times 1} = \sqrt{x_1^2 + x_2^2 + \cdots + x_d^2}$$

$$X = \begin{bmatrix} \varphi(1)^T \\ \varphi(2)^T \\ \vdots \\ \varphi(N)^T \end{bmatrix}$$

$$\underset{N\times 1}{Y} = \underset{N\times d}{X}\underset{d\times 1}{\theta} + \underset{N\times 1}{E} \Rightarrow J(\theta) = \frac{1}{N}\|Y - X\theta\|^2 = \frac{1}{N}\underset{1\times N}{(Y - X\theta)^T}\underset{N\times 1}{(Y - X\theta)} =$$

somma numeri 1×1 = uguale al trasposto

$$= \frac{1}{N}\left(\underset{1\times N}{Y^T}\underset{N\times 1}{Y} - \underset{1\times N}{Y^T}\underset{N\times d}{X}\underset{d\times 1}{\theta} - \underset{1\times d}{\theta^T X^T}\cdot\underset{N\times 1}{Y} + \underset{1\times d}{\theta^T}\underset{d\times N}{X^T}\underset{N\times d}{X}\underset{d\times 1}{\theta}\right)$$

$\nabla_\theta(\theta^T A\theta) = (A + A^T)\theta$ $\quad$ $\frac{1}{N}(Y^TY - 2\theta^TX^TY + \theta^TX^TX\theta)$ $\quad$ $\nabla_\theta(\theta^Tb) = b$ $\quad$ $\underset{(1\times d)}{(X\theta)^T} = \underset{d\times N}{\theta^T X^T}$ $\quad$ $(1\times N)^T$ $\quad$ $1\times N$

$$\nabla J(\theta) = 0 \Rightarrow \frac{1}{N}\left(\underset{d\times N}{-2X^T}\underset{N\times 1}{Y} + \underset{d\times N}{2X^T}\underset{N\times d}{X}\underset{d\times 1}{\theta}\right) = 0 \Rightarrow \boxed{\underset{d\times 1}{\hat{\theta}} = \underset{d\times d}{(X^TX)^{-1}}\underset{d\times N}{X^T}\underset{N\times 1}{Y}}$$

$d\times d$

$\nabla_\theta(-) = (X^TX + (X^TX)^T)\theta = 2X^TX\theta$

Come si comporta lo STIMATORE A MINIMI QUADRATI appena visto (modello lineare) col caso in cui il MODELLO VERO sia effettivamente lineare?

$$y(i) = \varphi(i)^T \vartheta^\circ + v(i) \qquad \vartheta^\circ: \text{valore vero dei parametri}$$

- Supponendo $v(i)$ un rumore casuale di valor atteso nullo $E[v(i)] = 0$

$$\Downarrow$$

$$E[\hat{\vartheta}] = \vartheta^\circ \qquad \text{CORRETTO}$$

- Supponendo inoltre che i rumori siano indipendenti $E[v(i)\,v(j)] = 0 \quad \forall i \neq j$ e varianza $\lambda^2 \rightarrow Var[v(i)] = \lambda^2$

$$\Downarrow$$

$$Var[\hat{\vartheta}] = \lambda^2 \cdot \left[\sum_{i=1}^{N} \underset{dm}{\varphi(i)}\,\underset{1\times d}{\varphi(i)^T}\right]^{-1} \qquad \text{CONSISTENTE}$$

Es ϑ° scalare

$S: y(i) = x(i)\vartheta^\circ + v(i)$

$M: y(i) = x(i)\vartheta + e(i) \Rightarrow J(\vartheta) = \frac{1}{N}\sum_{i=1}^{N}\left(y(i) - x(i)\vartheta\right)^2$

$$\frac{dJ(\vartheta)}{d\vartheta} = 0 \rightarrow -\frac{2}{N}\sum_{i=1}^{N}\left(y(i) - x(i)\vartheta\right)x(i) = 0$$

$$\Rightarrow \sum_{i=1}^{N}\left(y(i)x(i) - x(i)^2\vartheta\right) = 0 \Rightarrow \sum_{i=1}^{N} y(i)x(i) - \sum_{i=1}^{N} x(i)^2\vartheta = 0$$

$$\Rightarrow \hat{\vartheta} = \frac{\sum_{i=1}^{N} y(i)x(i)}{\sum_{i=1}^{N} x(i)^2}$$

$$E[\hat{\vartheta}] = E\left[\frac{\sum_{i=1}^{N} y(i)\,x(i)}{\sum_{i=1}^{N} x(i)^2}\right] = \frac{\sum_{i=1}^{N} E[y(i)]\,x(i)}{\sum_{i=1}^{N} x(i)^2} = \frac{\sum_{i=1}^{N} E[x(i)\vartheta^\circ + v(i)]\,x(i)}{\sum_{i=1}^{N} x(i)^2}$$

$$= \sum_{i=1}^{N} \frac{\left(x(i)\vartheta^\circ + 0\right)x(i)}{\sum_{i=1}^{N} x(i)^2} = \boxed{\vartheta^\circ}$$

$$Var[\hat{\vartheta}] = \frac{\lambda^2}{\sum_{i=1}^{N} x(i)^2}$$

STIMA A MASSIMA VEROSIMIGLIANZA

Abbiamo presentato finora due diversi tipi di stimatori,

- $\hat{\mu} = \frac{1}{N}\sum_{i=1}^{N} y(i)$ media campionaria $\Rightarrow \hat{\vartheta} = \mu \in \mathbb{R}$
- $S^2_{N-1} = \frac{1}{N-1}\sum(y(i)-\hat{\mu})^2$ varianza campionaria $\Rightarrow \hat{\vartheta} = \sigma^2 \in \mathbb{R}$
- STIMA MIN. QUADRATI $y(i) = \vartheta_0 + \vartheta_1 x_1(i) + \vartheta_2 x_2(i) + \dots + \vartheta_{d-1} x_{d-1}(i) + \varepsilon(i)$, $\varepsilon(i)$ i.i.d $(0, \lambda^2)$
  $\Rightarrow \hat{\vartheta} = [\hat{\vartheta}_0, \hat{\vartheta}_1, \dots, \hat{\vartheta}_{d-1}]^T \in \mathbb{R}^{d\times 1}$

Abbiamo presentato stimatori PARAMETRICI, quindi rappresentano i dati tramite un modello parametrico (es modello lineare)

- Non abbiamo mai fatto ossevazioni sulle pdf dei dati $D = \{y(1), \dots, y(N)\}$

Il metodo della MASSIMA VEROSIMIGLIANZA è una procedura di stima le, dato un modello probabilistico, stima i suoi parametri in modo da avere il più possibile consistenti con quanto osservato

Supponiamo di avere $Y = [y(1), \dots, y(N)]^T$: N osservazioni della variabile scalare y

- $y(i) \sim N(\mu, \sigma^2)$ i.i.d.

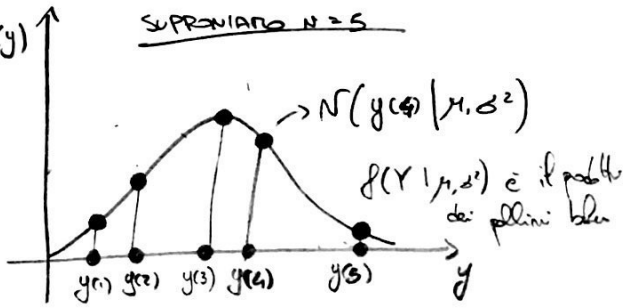

La pdf del vettore dei dati è:

$$f(y(1), y(2), \dots, y(N) \mid \mu, \sigma^2) = \prod_{i=1}^{N} N(y(i) \mid \mu, \sigma^2)$$

- È la prob. che si realizzi il vettore di dati osservato
  - siccome $y(i)$ i.i.d, la prob di osservare $y(1)$ AND $y(2)$ AND — è il prodotto delle varie pdf delle singole variabili
  - se in funzione delle y, è una pdf N-dimensionale
    ↓
    però in σ il valor ver delle $y(i)$ $\Rightarrow$ se conosco anche μ e σ^2, posso calcolarmi il valore assunto dalla pdf

- Quando questa funzione è vista in funzione di μ e σ^2 (conoscendo le Y), allora prende il nome di VEROSIMIGLIANZA (LIKELIHOOD)

$$f(y) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{y-\mu}{\sigma}\right)^2} = f(y \mid \mu, \sigma^2)$$

(y: VARIABILE; μ: NUMERO NOTO; σ: NUMERO NOTO; funzione di y)

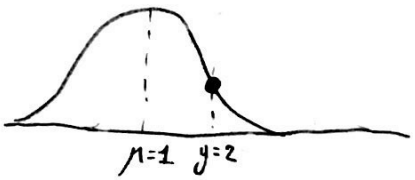

$$\Rightarrow L(\mu, \sigma^2 \mid y) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{1}{2}\left(\frac{y-\mu}{\sigma}\right)^2}$$

(μ, σ²: NOTO; y: VARIABILE)

$$\mathcal{L}(\mu, \sigma^2 | y) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{y-\mu}{\sigma}\right)^2}$$

SUPPONIAMO σ^2 NOTO $\Rightarrow \mathcal{L}(\mu|y)$

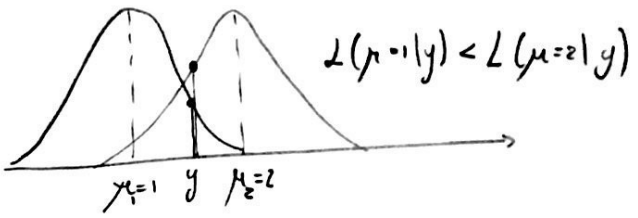

Lo stimatore Massima Verosimiglianza è quel valore del parametro θ che massimizza $\mathcal{L}(\theta|y)$

↳ nell'esempio, $\theta = \mu$ (σ^2 noto) $\Rightarrow \mu=2$ è più verosimile di $\mu=1$ perché $f(y|\mu=1) < f(y|\mu=2)$

↳ in questo caso, la stima più verosimile sarà $\mu = y$

$\Downarrow$

Quindi, nel caso di più osservazioni $\overset{iid}{\sim}$ di $y \sim N(\mu, \sigma^2)$, $Y = [y_{(1)}, \dots, y_{(N)}]^T$, devo massimizzare

$$f(\underbrace{y_{(1)}, \dots, y_{(N)}}_{Y} | \underbrace{\mu, \sigma^2}_{\theta}) = \mathcal{L}(\mu, \sigma^2 | Y) = \prod_{i=1}^{N} N(y_{(i)} | \mu, \sigma^2)$$

SUPPONIAMO $N=5$

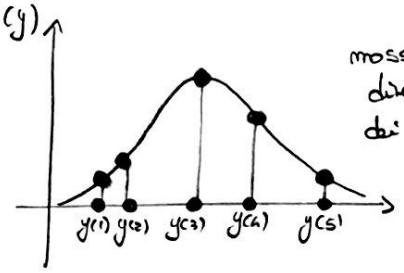

massimizzare la verosimiglianza vuol dire applicare μ e σ^2 t.c. il prodotto dei pallini blu è max

$$\hat{\theta}_{ML} = \begin{bmatrix} \hat{\mu} \\ \hat{\sigma}^2 \end{bmatrix} = \arg\max_{\theta} \mathcal{L}(\theta|Y) = \arg\max_{\theta} \prod_{i=1}^{N} N(y_{(i)}|\theta)$$

In generale posso attribuire ai dati qualsiasi pdf $f(Y|\theta)$

$\Downarrow$

$$\hat{\theta}_{ML} = \arg\max_{\theta} \mathcal{L}(\theta|Y) = \arg\max_{\theta} \prod_{i=1}^{N} f(y_{(i)}|\theta)$$

Spesso, anziché massimizzare $\mathcal{L}(\theta|Y)$, si massimizza il suo logaritmo naturale

↳ dato che il logaritmo di $\mathcal{L}(\theta|Y)$ è una funzione monotona crescente, ha lo stesso massimo di $\mathcal{L}(\theta$

↳ è efficiente dal punto di vista implementativo, perché evita l'underflow dato dal prodotto di piccole probabilità (sostituendolo con la somma delle log-probabilità)

$$\hat{\theta}_{ML} = \arg\max_{\theta} \ln\left[\mathcal{L}(\theta|Y)\right]$$

Solitamente questa ottimizzazione viene effettuata con metodi numerici iterativi

↓

In questi casi si può fare analiticamente (Gaussiana, —)

STIMA DI PARAMETRI DI UNA POPOLAZIONE:

Es 1: Supponiamo di voler stimare dei parametri della popolazione delle y

Siano $y(i) \sim N(\mu, \sigma^2)$ $i = 1, \dots, N$ i.i.d. ⇒ trovare la stima max verosimiglianza di $\theta = [\mu, \sigma^2]$

$$f(y(i)|\mu,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{y(i)-\mu}{\sigma}\right)^2} \Rightarrow \text{i.i.d} \Rightarrow \mathcal{L}(\underbrace{\mu,\sigma^2}_{\theta} | \underbrace{y(1),\dots,y(N)}_{Y}) = \prod_{i=1}^{N} f(y(i)|\mu,\sigma^2)$$

$$\mathcal{L}(\theta|Y) = \prod_{i=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{y(i)-\mu}{\sigma}\right)^2} \xrightarrow{\text{Log}} \ln[\mathcal{L}(\theta|Y)] = \sum_{i=1}^{N} \ln\left[\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{y(i)-\mu}{\sigma}\right)^2}\right] =$$

$$= \sum_{i=1}^{N} \left(\ln\left[\frac{1}{\sqrt{2\pi\sigma^2}}\right] + \ln\left[e^{-\frac{1}{2}\left(\frac{y(i)-\mu}{\sigma}\right)^2}\right] \right) = \sum_{i=1}^{N} \ln\left[\frac{1}{\sqrt{2\pi\sigma^2}}\right] + \sum_{i=1}^{N} \ln\left[e^{-\frac{1}{2}\left(\frac{y(i)-\mu}{\sigma}\right)^2}\right] =$$

$$= N \cdot \ln\left[\frac{1}{\sqrt{2\pi\sigma^2}}\right] + \sum_{i=1}^{N} -\frac{1}{2}\left(\frac{y(i)-\mu}{\sigma}\right)^2 \underbrace{\ln e}_{1} = N \cdot \ln\left[2\pi\sigma^2\right]^{-\frac{1}{2}} - \frac{1}{2}\sum_{i=1}^{N}\left(\frac{y(i)-\mu}{\sigma}\right)^2 =$$

$$-\frac{N}{2}\ln(2\pi\sigma^2) - \frac{1}{2}\sum_{i=1}^{N}\left(\frac{y(i)-\mu}{\sigma}\right)^2 = \boxed{-\frac{N}{2}\ln 2\pi - \frac{N}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum_{i=1}^{N}(y(i)-\mu)^2}$$

$$\hat{\theta} = \arg\max_{\theta} \mathcal{L}(\theta|Y) \Rightarrow \begin{cases} \frac{\partial \mathcal{L}(\mu,\sigma^2|Y)}{\partial \mu} = 0 \\ \frac{\partial \mathcal{L}(\mu,\sigma^2|Y)}{\partial \sigma^2} = 0 \end{cases} \Rightarrow \begin{cases} +\frac{2}{2\sigma^2}\sum_{i=1}^{N}(y(i)-\mu) = 0 \\ -\frac{N}{2}\cdot\frac{1}{\sigma^2} - \frac{1}{2}\sum_{i=1}^{N}(y(i)-\mu)^2 \cdot \left(-\frac{1}{\sigma^4}\right) \end{cases}$$

$\theta = [\mu, \sigma^2]$

$\frac{1}{x} \to \frac{dx^{-1}}{dx} = -x^{-2} = -(\sigma^2)^{-2} = -\frac{1}{\sigma^4}$

$$\begin{cases} \frac{1}{\sigma^2}\sum_{i=1}^{N}(y(i)-\mu) = 0 \Rightarrow \sum_{i=1}^{N}(y(i)-\mu) = 0 \Rightarrow \sum_{i=1}^{N} y(i) - \sum_{i=1}^{N}\mu = 0 \Rightarrow \sum_{i=1}^{N} y(i) - N\mu = 0 \\ \text{CORRETTO!} \Rightarrow \boxed{\hat{\mu} = \frac{1}{N}\sum y(i)} \quad \text{MEDIA CAMPIONARIA} \\ -\frac{N}{2}\cdot\frac{1}{\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^{N}(y(i)-\mu)^2 = 0 \xrightarrow{\text{sostituisco } \hat{\mu}} \frac{1}{2\sigma^4}\sum_{i=1}^{N}(y(i)-\hat{\mu})^2 = \frac{N}{2}\cdot\frac{1}{\sigma^2} \end{cases}$$

$$\Rightarrow \boxed{\hat{\sigma}^2 = \frac{1}{N}\sum(y(i)-\hat{\mu})^2} \quad \text{VARIANZA CAMPIONARIA}$$

DISTORTO!!

Lo stimatore a massima verosimiglianza può essere distorto!

⇓ In generale però, essa gode di buone proprietà

PROPRIETÀ STIMA MASSIMA VEROSIMIGLIANZA

1) Asintoticamente corretta: $\lim_{N \to +\infty} E[\hat{\theta}_{ML}] = \theta^0$

2) Consistente: più N grande, + stima precisa

3) Asintoticamente efficiente: $\lim_{N \to +\infty} Var[\hat{\theta}_{ML}] = H^{-1}$ H: matrice di informazione di Fisher

4) Asintoticamente normale: $\hat{\theta}_{ML} \sim N\left(\theta^0, \frac{1}{H}\right)$ se $N \to +\infty$

L $\hat{\theta}_{ML}$ è centrato sul valore vero e la varianza poi ~~è~~ ~~l'inverso~~ dell'inverso dell'informazione di Fisher

ES. STIMATORE VARIANZA

$\hat{\sigma}^2_{ML} = \frac{1}{N}\sum(y_{(i)} - \hat{\mu})^2$

quando $N \to +\infty$ divisa per N o per N-1 non cambia

Esempio 1 - con numeri

Sia $y_{(i)} \sim N(\mu, \sigma^2 = 1)$, $i = 1, 2$, i.i.d. Calcolare la stima di μ nel caso in cui i dati osservati sono:

$y_{(1)} = 4 \quad y_{(2)} = 6$

$$f(y|\mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{1}{2}\left(\frac{y-\mu}{\sigma}\right)^2} \overset{\sigma=1}{=} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(y-\mu)^2}$$

La densità in corrispondenza delle due osservazioni è:

$$f(y_{(1)}=4 | \mu, \sigma^2=1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(4-\mu)^2}$$

$$f(y_{(2)}=6 | \mu, \sigma^2=1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(6-\mu)^2}$$

La pdf congiunta (i.i.d.) è:

$$f(y_{(1)}=4, y_{(2)}=6 | \mu, \sigma^2=1) = \left(\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(4-\mu)^2}\right) \cdot \left(\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(6-\mu)^2}\right)$$

⇓

È FUNZIONE SOLO DI μ!

Interpretando $f(y_{(1)}=4, y_{(2)}=6 \mid \mu, \sigma^2=1)$ come funzione di μ, otteniamo la VEROSIMIGLIANZA

$$\mathcal{L}\underbrace{(\mu}_{\theta} \mid \underbrace{y_{(1)}=4, y_{(2)}=6}_{Y=[y_{(1)}, y_{(2)}]^T}) = \left(\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(4-\mu)^2}\right) \cdot \left(\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(6-\mu)^2}\right)$$

$$\boxed{\hat{\mu} = \arg\max_{\mu} \mathcal{L}(\mu \mid y_{(1)}=4, y_{(2)}=6)}$$

Calcolo la log-likelihood:

$$\ln[\mathcal{L}] = \ln\left[\left(\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(4-\mu)^2}\right) \cdot \left(\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(6-\mu)^2}\right)\right] =$$

$$= \ln\left[\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(4-\mu)^2}\right] + \ln\left[\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(6-\mu)^2}\right] =$$

$$= \ln\frac{1}{\sqrt{2\pi}} + \ln\left[e^{-\frac{1}{2}(4-\mu)^2}\right] + \ln\frac{1}{\sqrt{2\pi}} + \ln\left[e^{-\frac{1}{2}(6-\mu)^2}\right]$$

$$= 2 \cdot \ln\frac{1}{\sqrt{2\pi}} - \frac{1}{2}(4-\mu)^2 \ln e - \frac{1}{2}(6-\mu)^2 \ln e$$

$$= \boxed{2\ln\frac{1}{\sqrt{2\pi}} - \frac{1}{2}(4-\mu)^2 - \frac{1}{2}(6-\mu)^2}$$

Trovo il massimo:

$$\frac{\partial \ln[\mathcal{L}]}{\partial \mu} = 0 \Rightarrow +\frac{2}{2}(4-\mu) + \frac{2}{2}(6-\mu) = 0 \Rightarrow 4+6 = 2\mu$$

$$\Rightarrow \boxed{\hat{\mu} = \frac{4+6}{2} = 5}$$

MEDIA CAMPIONARIA!

Es

Calcolare lo stimatore massimo verosimiglianza nel caso in cui N dati iid provengano da una distribuzione di Bernoulli con parametro π

$$P(y|\pi) = \pi^y \cdot (1-\pi)^{1-y} \qquad y = 0, 1$$

π: probabilità di ottenere $y=1$ (lancio una moneta ed esce testa)

$1-\pi$: " " $y=0$

$\Rightarrow$ Infatti - se $y=1 \Rightarrow P(y=1|\pi) = \pi^1 \cdot (1-\pi)^{1-1} = \pi$

- se $y=0 \Rightarrow P(y=0|\pi) = \pi^0 \cdot (1-\pi)^{1-0} = 1-\pi$

$$\mathcal{L}(\pi|Y) = \prod_{i=1}^{N} \pi^{y(i)} \cdot (1-\pi)^{1-y(i)} = \pi^{\sum_{i=1}^{N} y(i)} \cdot (1-\pi)^{\sum_{i=1}^{N}(1-y(i))}$$

$$= \pi^{\#\text{successi}} \cdot (1-\pi)^{\#\text{fallimenti}}$$

Calcolo la log-verosimiglianza

$$\ln[\mathcal{L}] = \ln\left[\pi^{\sum_{i=1}^{N} y(i)} \cdot (1-\pi)^{\sum_{i=1}^{N}(1-y(i))}\right] = \ln \pi^{\sum_{i=1}^{N} y(i)} + \ln (1-\pi)^{\sum_{i=1}^{N}(1-y(i))}$$

$$= \left[\sum_{i=1}^{N} y(i) \cdot \ln \pi + \sum_{i=1}^{N}(1-y(i)) \ln(1-\pi)\right] = \boxed{\gamma \ln \pi + (N-\gamma)\ln(1-\pi)}$$

$\sum_{i=1}^{N} y(i) = \gamma$

$\sum_{i=1}^{N} 1 - \sum_{i=1}^{N} y(i) = N - \gamma$

Trovo il massimo

$$\frac{\partial \ln[\mathcal{L}]}{\partial \pi} = 0 \Rightarrow \frac{\gamma}{\pi} - \frac{(N-\gamma)}{1-\pi} = 0 \Rightarrow \frac{(1-\pi)\gamma - \pi(N-\gamma)}{\pi(1-\pi)} = 0$$

$$\Rightarrow \gamma - \pi\gamma - \pi N + \pi\gamma = 0 \Rightarrow \boxed{\hat{\pi} = \frac{\gamma}{N} = \frac{1}{N}\sum_{i=1}^{N} y(i)}$$

MEDIA CAMPIONARIA

è la % di successi

Osservazione

La distribuzione di Bernoulli $P(y|\pi)$ è una distribuzione DISCRETA. Infatti π è FISSO AD UN VALORE ed il dato y è la variabile che assume solo 2 valori discreti: 0 e 1

La likelihood $\mathcal{L}(\pi|Y) = \pi^{\gamma} \cdot (1-\pi)^{N-\gamma}$ è una funzione CONTINUA del parametro π che è continuo tra $[0,1]$. Non è una distribuzione perché non integra a 1

Osservazione

È importante notare che massimizzare la log-likelihood equivale a minimizzare la meno log-likelihood

$$\hat{\vartheta}_{ML} = \arg\max_{\vartheta} \ln\left[\mathcal{L}(\vartheta|Y)\right]$$

$$= \arg\min_{\vartheta} -\ln\left[\mathcal{L}(\vartheta|Y)\right]$$

In questo modo, abbiamo un problema di minimizzazione come con la regressione lineare, dove minimizzavamo (tramite il metodo dei minimi quadrati):

$$J(\vartheta) = \frac{1}{N}\sum_{i=1}^{N}\left(y(i) - \varphi(i)^T\vartheta\right)^2$$

$$\hat{\vartheta} = \arg\min_{\vartheta} J(\vartheta)$$

STIMA

MASSIMA VEROSIMIGLIANZA DI MODELLI LINEARI

Come nel caso in cui non vi erano ossservazioni sulla pdf dei dati, abbiamo cercato degli stimatori per descrivere i dati con dei parametri della loro popolazione

↳ possiamo usare il metodo ML anche nel caso in cui vogliamo descrivere i dati attraverso un modello lineare

$$y(i) = \vartheta_0 + \vartheta_1 x_1(i) + \vartheta_2 x_2(i) + \text{---------} + \vartheta_{d-1} x_{d-1}(i) + e(i)$$

$$= \underset{1\times d}{\varphi(i)^T}\underset{d\times 1}{\vartheta} + e(i)$$

$$\underset{d\times 1}{\varphi(i)} = \begin{bmatrix} 1 \\ x_1(i) \\ x_2(i) \\ \vdots \\ x_{d-1}(i) \end{bmatrix} \qquad \underset{d\times 1}{\vartheta} = \begin{bmatrix} \vartheta_0 \\ \vartheta_1 \\ \vdots \\ \vartheta_{d-1} \end{bmatrix}$$

$e(i) \sim \mathcal{N}(0, \lambda^2)$ (i.i.d.), $e(i) \perp \vartheta$

$$\Downarrow$$

$$y(i) \sim \mathcal{N}\left(\varphi(i)^T\vartheta, \lambda^2\right)$$

$$\downarrow \mu$$

La moda è espressa come funzione lineare dei regressori!

La probabilità di osservare i dati misurati è data dalla probabilità congiunta delle $y(i)$:

$$f(\underbrace{y(1), \dots, y(N)}_{Y} \mid X, \theta, \lambda^2) \overset{iid}{=} \prod_{i=1}^{N} f(y(i) \mid \varphi(i), \theta, \lambda^2) =$$

$$X = \underset{N \times d}{\begin{bmatrix} \varphi(1)^T \\ \varphi(2)^T \\ \vdots \\ \varphi(N)^T \end{bmatrix}} \qquad = \prod_{i=1}^{N} \mathcal{N}(\varphi(i)^T\theta, \lambda^2) =$$

$$= \prod_{i=1}^{N} \frac{1}{\sqrt{2\pi\lambda^2}} e^{-\frac{1}{2}\left(\frac{y(i) - \varphi(i)^T\theta}{\lambda}\right)^2} = \mathcal{L}(\theta, \lambda^2 \mid Y, X)$$

Supponiamo λ^2 NOTO per semplicità.

La verosimiglianza è funzione del solo vettore dei coefficienti $\underset{d\times 1}{\theta} = \begin{bmatrix} \theta_0 \\ \vdots \\ \theta_{d-1} \end{bmatrix}$

Calcolo la log-verosimiglianza

$$\ln[\mathcal{L}(\theta \mid X, Y)] = \ln\left[\prod_{i=1}^{N} \frac{1}{\sqrt{2\pi\lambda^2}} e^{-\frac{1}{2}\left(\frac{y(i) - \varphi(i)^T\theta}{\lambda}\right)^2}\right]$$

$$= \sum_{i=1}^{N} \ln\left[\frac{1}{\sqrt{2\pi\lambda^2}} \cdot e^{-\frac{1}{2}\left(\frac{y(i) - \varphi(i)^T\theta}{\lambda}\right)^2}\right] = \sum_{i=1}^{N}\left(\ln\frac{1}{\sqrt{2\pi\lambda^2}} + \ln\left[e^{-\frac{1}{2}\left(\frac{y(i) - \varphi(i)^T\theta}{\lambda}\right)^2}\right]\right)$$

$$= \sum_{i=1}^{N} \ln\frac{1}{\sqrt{2\pi\lambda^2}} + \sum_{i=1}^{N} \ln\left[e^{-\frac{1}{2}\left(\frac{y(i) - \varphi(i)^T\theta}{\lambda}\right)^2}\right] = N \cdot \ln(2\pi\lambda^2)^{-\frac{1}{2}} + \sum_{i=1}^{N} -\frac{1}{2}\left(\frac{y(i) - \varphi(i)^T\theta}{\lambda}\right)^2 \text{ché}$$

$$= -\frac{1}{2} N \cdot \ln 2\pi\lambda^2 - \frac{1}{2\lambda^2}\sum_{i=1}^{N}\left(y(i) - \varphi(i)^T\theta\right)^2 = \boxed{-\frac{N}{2}\ln 2\pi - \frac{N}{2}\ln\lambda^2 - \frac{1}{2\lambda^2}\sum_{i=1}^{N}\left(y(i) - \varphi(i)^T\theta\right)^2}$$

Calcolare il massimo di $\ln[\mathcal{L}(\theta \mid X, Y)]$ è uguale a calcolare il minimo di $-\ln[\mathcal{L}(\theta \mid X, Y)]$

$$-\ln[\mathcal{L}(\theta \mid X, Y)] = +\frac{N}{2}\ln 2\pi + \frac{N}{2}\ln\lambda^2 \boxed{+ \frac{1}{2\lambda^2}\sum_{i=1}^{N}\left(y(i) - \varphi(i)^T\theta\right)^2}$$

NON DIPENDONO DA θ

$$\Rightarrow \boxed{\hat{\theta}_{ML} = \arg\min_{\theta} \frac{1}{2\lambda^2}\sum_{i=1}^{N}\left(y(i) - \varphi(i)^T\theta\right)^2}$$

Osservazione

La stima ML così ottenuta ha lo stesso minimo (è equivalente) alla stima ottenuta con i minimi quadrati (in assenza di osservazioni probabilistiche)

$$\hat{\theta}_{ML} = \arg\min_{\theta} \frac{1}{2\lambda^2} \sum_{i=1}^{N} \left(y(i) - \varphi(i)^T \theta \right)^2$$

$$\hat{\theta}_{LS} = \arg\min_{\theta} \frac{1}{N} \sum_{i=1}^{N} \left(y(i) - \varphi(i)^T \theta \right)^2$$

$\Rightarrow$ scalare per una costante (che esse sia $\frac{1}{2\lambda^2}$ o $\frac{1}{N}$) non cambia il minimo della funzione di costo

$\Downarrow$

La stima ML del modello $y(i) = \varphi(i)^T \theta + e(i)$, dove $e(i) \sim N(0, \lambda^2)$ iid, è equivalente alla stima LS.

↳ queste assunzioni di modello danno origine al modello di REGRESSIONE LINEARE

Osservazione

Cambiando le ipotesi sulla distribuzione del rumore, si ottengono altre funzioni di costo e quindi altri algoritmi, che modellano i dati in modo diverso dalla regressione lineare.

REGRESSIONE LOGISTICA

Il procedimento della regressione lineare modellizza dati metrici attraverso un modello lineare, tramite l'ausilio di regressori (features)

↓

Un problema frequente è la modellizzazione di dati CATEGORICI DICOTOMICI, in cui y assume valore 0 o 1, $\Rightarrow$ Es
- predire se una persona in uno studio demografico sia maschio o femmina in base a peso e altezza
- predire cosa voterà una persona fra due candidati in base al reddito
- predire se un giocatore di baseball colpirà la pallina in base al suo ruolo

↓

In questo caso, NON HA SENSO utilizzare il modello lineare $y(i) = \varphi(i)^T \theta + e(i)$

↳ non ha senso sommare un errore continuo ($\in \mathbb{R}$) ad una variabile y che può assumere solo valori come 0 e 1, e non 0,98 o 1,01

↳ il modello potrebbe prevedere anche valori <0 o >1! Non c'è niente che "limita" l'uscita $\hat{y}$ tra 0 ed 1

$\Downarrow$

quello che si fa è utilizzare la FUNZIONE LOGISTICA (SIGMOIDE)

$$s(a) = \frac{1}{1+e^{-a}} = \frac{e^a}{1+e^a}$$

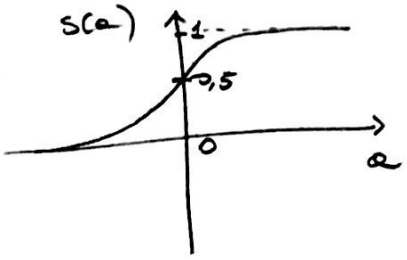

- se $a \gg 0 \Rightarrow s(a) = 1$
- se $a \ll 0 \Rightarrow s(a) = 0$

L'obiettivo di questo modello è modellare la probabilità che $y=1$ tramite un modello lineare

Probabilità

$$P(y=1 \mid \underset{d\times 1}{\varphi}) = s\left(\underset{1\times d}{\varphi^T} \cdot \underset{d\times 1}{\theta}\right) = \frac{1}{1+e^{-(\varphi^T \cdot \theta)}}$$

l'output di $s(\varphi^T\theta)$ è interpretato come una probabilità

- se $\varphi^T \cdot \theta \gg 0 \Rightarrow P(y=1 \mid \varphi) = 1$
- se $\varphi^T \cdot \theta \ll 0 \Rightarrow P(y=1 \mid \varphi) = 0$

REGRESSIONE LINEARE	REGRESSIONE LOGISTICA
$\mu = \underset{1\times d}{\varphi^T} \cdot \underset{d\times 1}{\theta} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_{d-1} x_{d-1}$	$\pi = s(\varphi^T\theta) = s(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_{d-1} x_{d-1})$
$y \sim N(\mu, \lambda^2)$	$y \sim \text{Bernoulli}(\pi)$

Sia la regressione lineare che la regressione logistica fanno parte dei cosiddetti GLM (Generalized Linear Model) in cui:

Una funzione di un modello lineare è usata per modellare un parametro di "tendenza centrale" τ della distribuzione dei dati

Quindi dire che modello il parametro della distribuzione che mi indica il valore medio dei dati $\Rightarrow$ non è sempre la media!

I dati y sono modellati tramite una distribuzione di probabilità in cui c'è il parametro τ

In generale:

$$\tau = f(\theta_0 + x_1\theta_1 + x_2\theta_2 + \dots + x_{d-1}\theta_{d-1}) = f(\varphi^T\theta) \Rightarrow$$

(f → generica funzione)

$$y \sim pdf(\tau, [\text{dati parametri}])$$

REGRESSIONE LINEARE

$\tau = f(\varphi^T\theta) = \varphi^T\theta$ (funzione identità)

$\tau = \mu \Rightarrow \mu = \varphi^T\theta$

$y \sim N(\mu, \lambda^2)$

REG. LOGISTICA

$\tau = f(\varphi^T\theta) = s(\varphi^T\theta)$ (funzione logistica)

$\tau = \pi \Rightarrow \pi = s(\varphi^T\theta)$

$y \sim \text{Bernoulli}(\pi)$

STIMA MAXIMUM LIKELIHOOD DI UN MODELLO DI REGRESSIONE LOGISTICA

Sia dato un dataset $D = \{(\varphi(1), y(1)), (\varphi(2), y(2)), \dots, (\varphi(N), y(N))\}$

$\varphi(i) \in \mathbb{R}^{d \times 1}$, dove $y(i) \in \{0,1\}$, $i = 1, \dots, N$, i.i.d

Stimare un modello di regressione logistica $P(y=1 \mid \varphi) = \dfrac{1}{1+e^{-(\varphi^T \vartheta)}} \equiv \hat{\pi}$

Interpretiamo i dati come $y \sim \text{Bernoulli}(\hat{\pi})$ $\quad \Big\lfloor P(y(i)=1 \mid \varphi(i)) = \dfrac{1}{1+e^{-(\varphi(i)^T \vartheta)}} \equiv \hat{\pi}(i)$

↓

Calcoliamo la Verosimiglianza dei dati

$$\mathcal{L}(\hat{\pi} \mid Y) = \prod_{i=1}^{N} \hat{\pi}(i)^{y(i)} \cdot (1-\hat{\pi}(i))^{1-y(i)} \Longrightarrow$$

calcolo la **meno** log-likelihood → diventa una **funzione di costo** da minimizzare

$$Y = \begin{bmatrix} y(1) \\ \vdots \\ y(N) \end{bmatrix}_{N \times 1}$$

dipende dai parametri ϑ!!

$\mathcal{L}(\hat{\pi} \mid Y) = \mathcal{L}(\vartheta \mid Y)$

i veri parametri sono questi

$$-\ln\left[\mathcal{L}(\hat{\pi} \mid Y)\right] = -\ln\left[\prod_{i=1}^{N} \hat{\pi}(i)^{y(i)} (1-\hat{\pi}(i))^{1-y(i)}\right] =$$

$$= -\sum_{i=1}^{N} \ln\left[\hat{\pi}(i)^{y(i)} \cdot (1-\hat{\pi}(i))^{1-y(i)}\right] = -\sum_{i=1}^{N} \left(\ln \hat{\pi}(i)^{y(i)} + \ln\left[1-\hat{\pi}(i)\right]^{1-y(i)}\right) =$$

$$= \boxed{-\sum_{i=1}^{N} \left(y(i) \ln \hat{\pi}(i) + (1-y(i)) \ln\left[1-\hat{\pi}(i)\right]\right)} \equiv J(\vartheta)$$

Interpretazione della funzione di costo

Supponiamo di avere un solo dato $D = \{(\varphi, y)\}$:

$$J(\vartheta) = \begin{cases} -\ln \hat{\pi} & \text{se } y = 1 \\ -\ln[1-\hat{\pi}] & \text{se } y = 0 \end{cases}$$

CASO $y = 1$

$J(\vartheta) = -\ln \hat{\pi} \Rightarrow$ **$J(\vartheta) = 0$ SE $y = 1$ & $\hat{\pi} = 1$** → Costo = 0 se predico giusto

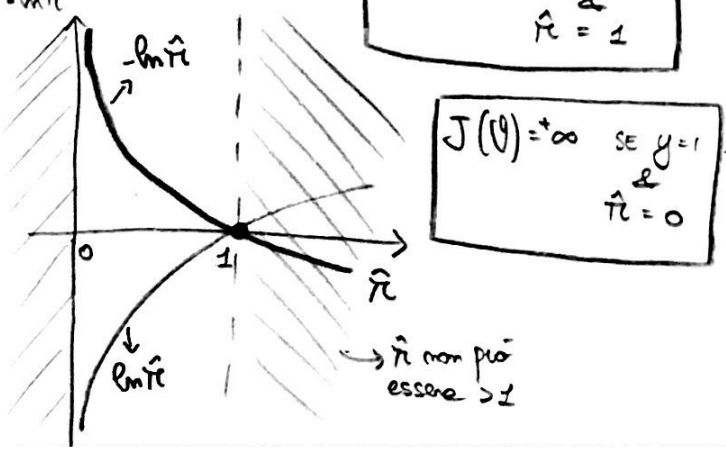

$J(\vartheta) = +\infty$ SE $y = 1$ & $\hat{\pi} = 0$

Costa l'intervallo che se $y=1$, ma io predico una bassa probabilità che $y=1$, ovvero predico $\hat{\pi} \ll 1$ ($P(y=1 \mid \varphi) \ll 1$) allora commetto un grande sbaglio e $J(\vartheta) \to +\infty$ (penalità molto)

↓

io voglio **minimizzare** questo sbaglio! ☺

CASO $y = 0$

$$J(\theta) = -\ln[1-\hat{\pi}]$$

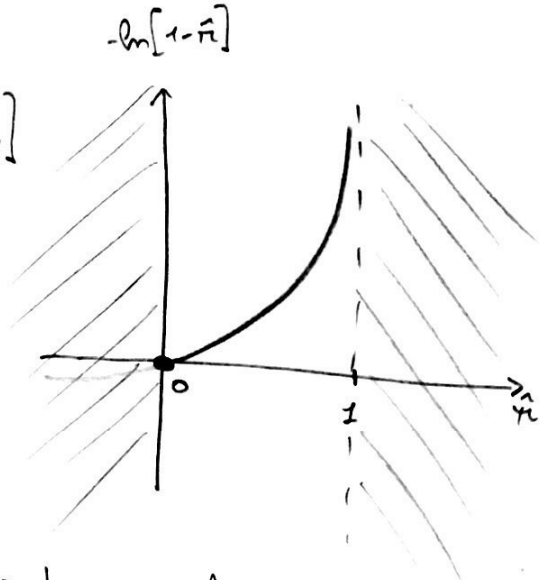

$J(\theta) = 0$ SE $y = 0$ & $\hat{\pi} = 0$

$J(\theta) = +\infty$ SE $y = 0$ & $\hat{\pi} = 1$

Se $y=0$ ma io predico con alta probabilità che $y=1$, avrei predetto $\hat{\pi} \gg 0$ ($P(y=1|p) \gg 0$) allora sbaglio molto e $J(\theta) \to +\infty$

CALCOLO DEL MINIMO

Calcolerò il gradiente di $J(\theta)$ rispetto al vettore di parametri $\theta \in \mathbb{R}^{d \times 1}$

↓

Per prima cosa, calcolerò la derivata di $s(a) = \frac{1}{1+e^{-a}}$

$$\frac{d\,s(a)}{a} = \frac{d}{da}\left[\frac{1}{1+e^{-a}}\right] = \frac{d}{da}\left[(1+e^{-a})^{-1}\right] = -(1+e^{-a})^{-2}\cdot(e^{-a})(-1) = -(1+e^{-a})^{-2}(-e^{-a})$$

$$= \frac{1\,e^{-a}}{1(1+e^{-a})^2} = \frac{e^{-a}}{(1+e^{-a})^2} = \frac{1}{(1+e^{-a})}\cdot\frac{e^{-a}}{(1+e^{-a})} = \frac{1}{(1+e^{-a})}\cdot\frac{(1+e^{-a})-1}{1+e^{-a}}$$

$$= \underbrace{\frac{1}{1+e^{-a}}}_{s(a)}\cdot\left(\underbrace{\frac{1+e^{-a}}{1+e^{-a}}}_{1} - \underbrace{\frac{1}{1+e^{-a}}}_{s(a)}\right) = \boxed{s(a)\cdot[1-s(a)]}$$

uguale formalmente

Nel caso in cui $a = \varphi^T\theta \Rightarrow s(a) = s(\varphi^T\theta) = \frac{1}{1+e^{-\varphi^T\theta}}$

$$\frac{d\,s(\varphi^T\theta)}{d\theta} = \frac{d}{d\theta}\left[\frac{1}{1+e^{-\varphi^T\theta}}\right] = \frac{d}{d\theta}\left[(1+e^{-\varphi^T\theta})^{-1}\right] = \underset{d\times 1}{\varphi}\cdot\underset{1\times 1}{(-1)}\underset{1\times 1}{(1+e^{-\varphi^T\theta})^{-2}}\underset{1\times 1}{(e^{-\varphi^T\theta})}$$

$$= -\varphi\cdot(1+e^{-\varphi^T\theta})^{-2}(e^{-\varphi^T\theta}) \overset{\text{stessi passaggi di prima}}{=} \underset{d\times 1}{\varphi}\cdot\underset{1\times 1}{s(\varphi^T\theta)}\underset{1\times 1}{[1-s(\varphi^T\theta)]}$$

$$= \boxed{\varphi\cdot\hat{\pi}\cdot(1-\hat{\pi})}$$

Possiamo ora calcolare il gradiente della $J(\theta)$

$$J(\theta) = -\sum_{i=1}^{N} \left(y(i) \ln \hat{\pi}(i) + (1-y(i)) \ln [1-\hat{\pi}(i)] \right) \qquad \hat{\pi}(i) = \frac{1}{1+e^{-\varphi^T(i)\theta}}$$

$$\nabla J(\theta) = -\sum_{i=1}^{N} \left(y(i) \frac{\hat{\pi}'(i)}{\hat{\pi}(i)} + (1-y(i)) \frac{-\hat{\pi}'(i)}{1-\hat{\pi}(i)} \right) =$$

$$= -\sum_{i=1}^{N} \left(y(i) \cdot \frac{\varphi(i) \cdot \hat{\pi}(i)[1-\hat{\pi}(i)]}{\hat{\pi}(i)} + (1-y(i)) \frac{-\varphi(i)\hat{\pi}(i)[1-\hat{\pi}(i)]}{1-\hat{\pi}(i)} \right)$$

$$= \sum_{i=1}^{N} \left(-y(i)\varphi(i)[1-\hat{\pi}(i)] + (1-y(i))(\varphi(i)\cdot\hat{\pi}(i)) \right)$$

$$= \sum_{i=1}^{N} \left(\varphi(i)[-y(i) + y(i)\hat{\pi}(i)] + \varphi(i)[\hat{\pi}(i) - y(i)\hat{\pi}(i)] \right)$$

$$= \sum_{i=1}^{N} \left(\varphi(i)[-y(i) + y(i)\hat{\pi}(i) - y(i)\hat{\pi}(i) + \hat{\pi}(i)] \right)$$

$$\boxed{= \sum_{i=1}^{N} \underset{dx1}{\varphi(i)} \cdot \underset{1x1}{(\hat{\pi}(i) - y(i))}}$$

Osservazione

Le derivate $\sum_{i=1}^{N} \underset{dx1}{\varphi(i)} (\hat{\pi}(i) - y(i)) = 0$ sono un sistema di $\boxed{d}$ equazioni NON LINEARI in θ

↳ Non possiamo risolvere in forma chiusa come per la regressione lineare ⇒ per via della non linearità della sigmoide

↳ si dimostra però che $J(\theta)$ è CONVESSA, quindi ha un UNICO MINIMO

L'ottimizzazione è quindi volta ad usare algoritmi iterativi di ottimizzazione. Uno di questi è il GRADIENT DESCENT:

⇓

il valore stimato dei parametri all'iterazione $j+1$ è: $\boxed{\hat{\theta}(j+1) = \hat{\theta}(j) - \alpha \nabla J(\theta)\big|_{\theta=\hat{\theta}(j)}}$

↳ α è la LEARNING RATE (determina il passo con cui aggiorno il valore)

↳ $\hat{\theta}(0)$ è inizializzato RANDOM

$$\hat{\theta}(j+1) = \hat{\theta}(j) - \alpha \nabla J(\theta)\Big|_{\theta=\hat{\theta}(j)}$$

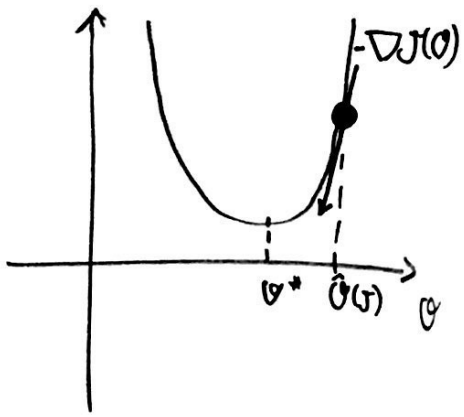

- SE $\nabla J(\theta)\Big|_{\theta=\hat{\theta}(j)} > 0 \Rightarrow \hat{\theta}(j+1) < \hat{\theta}(j)$

- SE $\nabla J(\theta)\Big|_{\theta=\hat{\theta}(j)} < 0 \Rightarrow \hat{\theta}(j+1) > \hat{\theta}(j)$

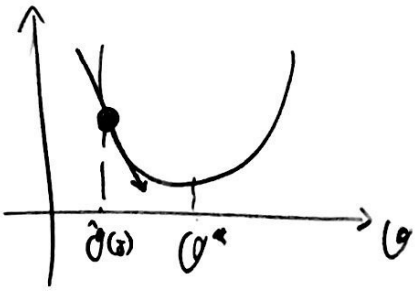

STIMA BAYESIANA (BAYESIAN INFERENCE)

PROBABILITÀ CONGIUNTE, CONDIZIONATE, MARGINALI

Supponiamo di avere 2 variabili casuali a e b, discrete binarie, con la seguente distribuzione di probabilità congiunta:

DISTRIBUZIONE CONGIUNTA

$P(a,b)$

b \ a	0	1
0	0,06	0,24
1	0,28	0,42

$\sum_{a,b} p(a,b) = 1$

probabilità che si verifichi sia a che b, contemporaneamente

La distribuzione MARGINALE è la distribuzione di probabilità di un sottoinsieme di variabili casuali

↳ nel nostro caso, dato che abbiamo 2 variabili casuali, ci saranno 2 prob. marginali, ovvero $p(a)$ e $p(b)$

- È ottenuta "marginando", ovvero sommando, rispetto alle variabili che non sono di interesse

DISTRIBUZIONE MARGINALE

b \ a	0	1	
0	0,06	0,24	$p(b=0) = 0,3$
1	0,28	0,42	$p(b=1) = 0,7$

$p(a=0) = 0,34$ $\quad p(a=1) = 0,66$

non mi interessa se $a=0$ o $a=1$ MI interessa solo che $b=0$. Quindi la Probabilità che $b=0$ è la somma delle probabilità quando $b=0$ $\Rightarrow p(b=0, a=0) + p(b=0, a=1) = p(b=0)$

$p(b)$

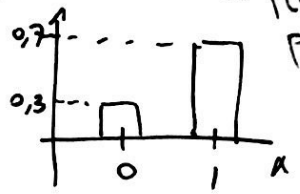

$\Rightarrow$

$p(b=1) = p(b=1, a=0) + p(b=1, a=1)$

$\Rightarrow \sum_b p(b) = 1$

$p(a)$

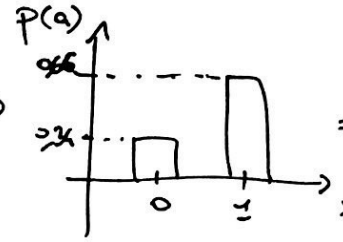

$\Rightarrow$ $\Rightarrow \sum_a p(a) = 1$

$p(a=0) = p(a=0, b=0) + p(a=0, b=1)$

$p(a=1) = p(a=1, b=0) + p(a=1, b=1)$

La distribuzione CONDIZIONATA indica come le probabilità si redistribuiscono dato che si restringe la popolazione ad un particolare sottoinsieme

Es

Siano date N persone, dove N_A è il numero di persone con capelli lunghi e N_B è il numero di persone di sesso femminile. Siano gli eventi:

A = persone con capelli lunghi

B = persone di sesso femminile $\Rightarrow P(A) = \frac{N_A}{N} = \frac{\#\text{ di persone con capelli lunghi}}{\#\text{ totale di persone}}$

$P(B) = \frac{N_B}{N} = \frac{\#\text{ di donne}}{\#\text{ totale di persone}}$

Consideriamo la sola popolazione femminile:

La probabilità che una persona scelta a caso da questa popolazione abbia i capelli lunghi è $\frac{N_{AB}}{N_B}$, dove N_{AB} è il numero di donne con capelli lunghi.

Questa probabilità è chiamata probabilità condizionata (al fatto che la persona sia di sesso femminile)

$$P(A|B) = \frac{N_{AB}}{N_B}$$

// la popolazione considerata è N_B, non N

- La probabilità di selezionare una donna con i capelli lunghi è $P(A,B) = \frac{N_{AB}}{N}$

$= \frac{\#\text{ numero di donne con capelli lunghi}}{\#\text{ totale di persone}}$

⇓

- Posso esprimere $P(A|B)$ come: $P(A|B) = \frac{N_{AB}/N}{N_B/N} = \frac{P(A,B)}{P(B)}$

⇓

Quindi $P(A|B) = \frac{P(A,B)}{P(B)} \Rightarrow \boxed{P(A,B) = P(A|B)P(B)}$

Osservazione

- La probabilità che accada sia A che B è la probabilità che si verifichi B moltiplicata per la probabilità che si verifichi A dato che B si è verificato
- $P(A,B) = P(A) \cdot P(B)$ se e solo se $P(A|B) = P(A)$. Questo vuol dire che A e B sono indipendenti, ovvero il verificarsi di B non modifica la probabilità che A si verifichi
  - Es: A: lancio un dado ed esce 4
    B: lancio una moneta ed esce TESTA ⇒ anche se uscisse CROCE, il dado ha la stessa probabilità ($\frac{1}{6}$) di risultare in un 4
    ↳ $P(A,B) = P(A) \cdot P(B)$

- Supponiamo che $P(A,B) = P(B,A)$. Quindi $P(B,A) = P(B|A)P(A)$, e di conseguenza:

$$P(A|B)P(B) = P(B|A)P(A) \Rightarrow \boxed{P(B|A) = \frac{P(A|B)P(B)}{P(A)}}$$

TEOREMA DI BAYES

Osservazione

- Il teorema di Bayes permette di ridistribuire le probabilità: prima conoscevo $P(B)$, adesso $P(B|A)$ ⇒ la probabilità di B è cambiata in seguito alla conoscenza di A

- $P(A) = \sum_B \underbrace{P(A|B)P(B)}_{P(A,B)}$ è la marginale di A, ovvero sommo rispetto a tutti i valori di B

Riprendendo l'esempio della tabella, calcoliamo la distribuzione $p(a|b)$

b \ a	0	1
0	0,06	0,8
1	0,4	0,42

$$p(a=1|b=0) = \frac{p(a=1, b=0)}{p(b=0)} = \frac{0,24}{0,3} = 0,8$$

$$p(a|b) = \frac{p(a,b)}{p(b)}$$

$$p(a=0|b=1) = \frac{p(a=0, b=1)}{p(b=1)} = \frac{0,28}{0,7} = 0,4$$

$$p(b=1) = p(b=1|a=0)\,p(a=0) + p(b=1|a=1)\,p(a=1)$$
$$= p(b=1, a=0) + p(b=1, a=1)$$

Allo stesso modo posso calcolare $p(b|a)$.

Esempio: Interpretazione della probabilità condizionata come ridistribuzione della probabilità

Supponi di tirare bendato una freccetta contro un bersaglio con 20 cerchi concentrici

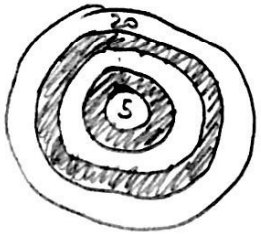

↓

le probabilità di beccare un cerchio qualsiasi, senza vedere, supponiamo sia $\frac{1}{20}$ (ogni cerchio è equiprobabile)

- Qual è la probabilità di aver beccato il cerchio numero 5?

$$P(\text{cerchio } \#5) = \frac{1}{20}$$

Supponiamo che io adesso ti dica che NON HAI PRESO il cerchio #20.

- Qual è adesso la probabilità di aver beccato il cerchio #5?

↓

Dato che non lo sicuramente preso il #20, la probabilità di aver preso il #5 è $P(\#5 \mid \text{NOT } \#20) = \frac{1}{19}$, perché ho 19 valori possibili, avendone esclusi 1

⇓

la probabilità si è quindi ridistribuita sui 19 esiti anziché sui 20 esiti

$$P(\#5|\text{NOT } \#20) = \frac{P(\#5, \text{NOT } \#20)}{P(\text{NOT } \#20)} = \frac{P(\#5)}{P(\text{NOT } \#20)} = \frac{1/20}{19/20} = \boxed{\frac{1}{19}}$$

INTRODUZIONE ALLA STIMA BAYESIANA

Abbiamo finora considerato il parametro ignoto θ come una variabile deterministica. Spesso, però, abbiamo delle informazioni, delle credenze, sui possibili valori che potrebbe avere θ.

↳ Esempio:

↳ stima della concentrazione di acido solforico nell'aria: si ha un'idea dell'ordine di grandezza, in base anche a studi precedenti

↳ stima della probabilità che una moneta non truccata risulti TESTA dopo un lancio: so che non può essere 0,1 o 0,9 ma sarà attorno agli 0.5

Ha quindi senso considerare θ come una variabile casuale anziché come variabile deterministica

↳ In questo modo posso specificare una distribuzione di probabilità per θ (dato che è una v.c.), assegnando una probabilità maggiore a valori di θ che io credo siano più verosimili che θ assuma, e minor probabilità a valori di θ che io credo non potrà assumere

Es

Sia θ la probabilità che il lancio di una moneta non truccata risulti in TESTA

Una possibile distribuzione per θ è:

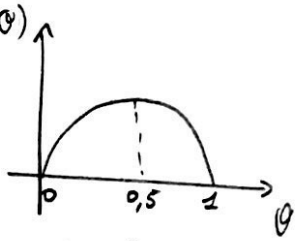

Osservazioni

- $P(\theta)$ ha dominio $[0,1]$, poiché θ, modellando una probabilità, deve stare tra 0 ed 1
- Dato che la moneta è non truccata, $\theta = 0,5$ sarà il valore più probabile di θ, e $\theta = 0$ o $\theta = 1$ sono praticamente impossibili (la probabilità che θ sia 0 o 1 è vicina a 0)
- Dando una distribuzione su θ, abbiamo già una stima di θ (STIMA A PRIORI). Ad esempio possiamo prendere come valore puntuale per la stima di θ il valore atteso di $P(\theta)$. L'incertezza sulla stima sarà allora la varianza di $P(\theta)$ (INCERTEZZA A PRIORI)
- Con l'arrivo di dati osservati, ci si aspetta che:
  1) Il valore atteso cambi
  2) L'incertezza decresca (+ più informazioni!)

Abbiamo quindi due elementi da poter informazione:

1) La distribuzione A PRIORI sui possibili valori di θ, ovvero $P(\theta)$

2) L'informazione da portare i dati sui possibili valori di θ, ovvero la LIKELIHOOD $P(Y|\theta)$

⇓

Quello da voglio veramente è sapere quanto può valere θ dato che ho osservato i dati Y: $P(\theta|Y)$

⇓

Usando il Teorema di Bayes possiamo unire i due elementi di informazione:

$$P(\theta|Y) = \frac{P(Y|\theta)\,P(\theta)}{P(Y)}$$

- $P(\theta)$: PRIOR
- $P(Y|\theta)$: LIKELIHOOD
- $P(Y)$: MARGINAL LIKELIHOOD
- $P(\theta|Y)$: POSTERIOR

Osservazione

- $P(\theta|Y)$ è una distribuzione di possibili valori di θ, le cui probabilità sono modificate (riallocate, redistribuite), rispetto a $P(\theta)$, dall'aver osservato i dati Y
- Nel caso in cui $P(Y|\theta)$ e $P(\theta)$ siano pdf continue (es. Gaussiane), allora $P(Y)$ sarà $P(Y) = \int_{-\infty}^{\infty} P(Y|\theta)P(\theta)\,d\theta$
- Conoscere la forma funzionale di $P(\theta)$ e $P(Y|\theta)$ perché le impongo io. Cosa posso dire su che distribuzione sarà $P(\theta|Y)$?
  1) In generale, nulla. Solo in dati casi fortunati so che $P(\theta|Y)$ è in una forma funzionale nota
  2) Questo avviene se, ad esempio, $P(\theta)$ è Gaussiana e $P(Y|\theta)$ è Gaussiana. Allora anche $P(\theta|Y)$ sarà Gaussiana
  3) Un altro problema è che $P(Y)$ è un integrale che potremmo non sapere come risolvere.

⇓

Per far fronte a questi problemi, si usano metodi numerici e di campionamento che evitano il calcolo analitico. Questi metodi si chiamano MARKOV CHAIN MONTE CARLO (MCMC)

Un modo per calcolare $P(\theta|Y)$ che non si basa né sul calcolo analitico né sui metodi MCMC è quello di <u>discretizzare</u> il range di valori del parametro θ tramite <u>una griglia</u> di valori
↳ <u>valuto</u> $P(Y|\theta)$ e $P(\theta)$ solo in quei valori di θ

<u>Esempio</u>

Stimare la probabilità che il lancio di una moneta risulti in TESTA. Supponiamo di lanciare una moneta N volte. Osserviamo i dati $y(i)$:

$$y(i) = \begin{cases} 1 & \text{se TESTA} \\ 0 & \text{se CROCE} \end{cases} \qquad i = 1, \dots, N$$

Modelliamo i dati, categoriali e dicotomici, con una distribuzione di Bernoulli:

$y(i) \sim \text{Bernoulli}(\pi)$, i.i.d., π: Prob. TESTA (parametro ignoto)

$$\downarrow$$

$$P(y|\pi) = \pi^{y} \cdot (1-\pi)^{1-y}$$

- Se $y=1 \Rightarrow P(y=1|\pi) = \pi$
- se $y=0 \Rightarrow P(y=0|\pi) = 1-\pi$

$$\mathcal{L}(\pi|Y) = \prod_{i=1}^{N} \pi^{y(i)} \cdot (1-\pi)^{1-y(i)}$$

$\downarrow$ $\downarrow$

θ $[y(1), \dots, y(N)]^T$

$$= \pi^{\sum_{i=1}^{N} y(i)} \cdot (1-\pi)^{\sum_{i=1}^{N} 1 \cdot y(i)} = \pi^{\#\text{successi}} \cdot (1-\pi)^{\#\text{fallimenti}}$$

($\#\text{successi} \to y$; $\#\text{fallimenti} \to 1-y$)

- Supponiamo una <u>prior</u> di questo tipo

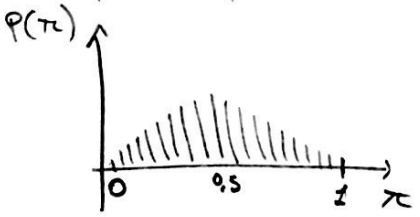

- Supponiamo di aver osservato $y = 10$ successi su $N = 40$ lanci. La <u>likelihood</u> ha la forma:

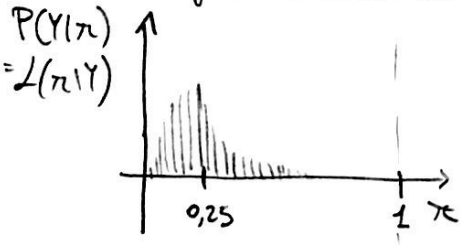

Il valore più probabile del parametro π è la stima ML. Nel caso di likelihood Bernoulli, ho che $\hat{\pi} = \frac{1}{N}\sum_{i=1}^{N} y(i)$, ovvero la % di successi.
In questo caso $\hat{\pi} = \frac{10}{40} = 0{,}25$

- Per calcolare la <u>posterior</u> faccio il <u>prodotto</u> di $P(Y|\theta)$ e $P(\theta)$ <u>per ogni</u> valore di θ e divido per $P(Y) = \sum_{\theta} P(Y|\theta)P(\theta)$, dove sommo su ogni valore di θ (della griglia)

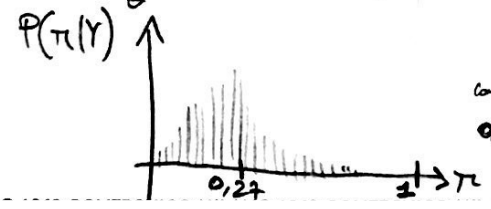

La MODA è un compromesso tra 0,25 e 0,5

DIETRO ⟹

- L'approccio a griglia non è perseguibile nel caso in cui θ sia un vettore con molte componenti

↓

Il PC ci impiegherebbe troppo a fare tutte le combinazioni di parametri

- La soluzione è usare prior e likelihood tali che le posteriori le une forme (molte) che si può ricavare analiticamente (se le posteriori le stesse forme delle PRIOR, prior e likelihood si dicono CONIUGATE)

  L oppure usi metodi MCMC

Supponiamo di aver $P(\theta|Y)$. Abbiamo una distribuzione di valori del parametro θ ignoto. Ci serve però un valore solo, un valore puntuale

↓

che valore prendiamo per la nostra stima $\hat{\theta}$?

Ci sono varie possibilità:

1) $\hat{\theta} = \arg\max_{\theta} P(\theta|Y)$, ovvero prendo il valore θ che risulta essere più probabile

Questa stima è nota come stima MASSIMO A POSTERIORI (MAP)

2) $\hat{\theta} = E[P(\theta|Y)] = E[\theta|Y]$, per la MEDIA della distribuzione a posteriori

3) Altre quantità come la MEDIANA, ecc - -

Ricordiamo che in generale indichiamo un stimatore come una funzione T dei dati D:

$$\hat{\theta} = T(D)$$

Vogliamo che la variabile casuale $\hat{\theta}$ sia vicina alla variabile casuale θ. Usiamo quindi la funzione di costo:

$$J(T(\cdot)) = E\left[\|\theta - T(D)\|^2\right] \quad (*)$$

MEAN SQUARED ERROR

Lo stimatore ottimo di Bayes è quella funzione $T^*(\cdot)$ tale che:

$$E\left[\|\theta - T^*(D)\|^2\right] \leq E\left[\|\theta - T(D)\|^2\right] \quad \forall T(\cdot)$$

cioè che minimizza la sfida di media rispetto a $T(\cdot)$

↓

Si dimostra che $\boxed{T^*(Y) = E[\theta|D=Y]}$, ovvero il valore atteso della distribuzione $P(\theta|Y)$, cioè il valore atteso di θ condizionato al fatto che i dati D abbiamo assunto valore Y

⇓

Consideriamo quindi $E[\theta|Y]$ come stima puntuale di $\hat{\theta}$, sapendo in che senso essa è una stima ottima

↙

nel senso che minimizza (*)

Supponiamo ora che sia: dato che il parametro θ siano delle v.c. Gaussiane, quindi la loro pdf congiunta è Gaussiana.

↓

Supponiamo per semplicità di avere un dato scalare y e che θ sia scalare, tali che $E[y]=0$ e $E[\theta]=0$

Vogliamo calcolare $P(\theta|y)$. Essendo θ e y congiuntamente Gaussiane si ha che:

$$\underbrace{\begin{bmatrix} y \\ \theta \end{bmatrix}}_{z \in \mathbb{R}^{2\times 1}} \sim N\left(\underbrace{\begin{bmatrix} 0 \\ 0 \end{bmatrix}}_{\mu \in \mathbb{R}^{2\times 1}}, \underbrace{\begin{bmatrix} \lambda_{yy} & \lambda_{y\theta} \\ \lambda_{\theta y} & \lambda_{\theta\theta} \end{bmatrix}}_{\Sigma \in \mathbb{R}^{2\times 2}} \right)$$

μ: vettore medie

Σ: matrice varianze-covarianze

al quadrato perché è congiunta di 2 variabili

La pdf congiunta $P(\theta, y)$ ha quindi la forma:

$$P(\theta, y) = \frac{1}{\sqrt{(2\pi)^2 \det \Sigma}} e^{-\frac{1}{2}(z-\mu)^T \Sigma^{-1} (z-\mu)}$$

La pdf dei dati è $P(y) = \frac{1}{\sqrt{2\pi\lambda_{yy}}} e^{-\frac{1}{2\lambda_{yy}}(y-0)^2}$

Si dimostra che $P(\theta|y) = \frac{P(\theta, y)}{P(y)}$ è una Gaussiana, $P(\theta|y) = N(\mu_{\theta|y}, \lambda_{\theta|y})$, con:

- VALORE ATTESO: $\boxed{\mu_{\theta|y} = \frac{\lambda_{\theta y}}{\lambda_{yy}} \cdot y}$

- VARIANZA: $\boxed{\lambda_{\theta|y} = \lambda_{\theta\theta} - \frac{\lambda_{\theta y}^2}{\lambda_{yy}}}$

• Il valore $\frac{\lambda_{\theta y}^2}{\lambda_{yy}}$ è >0. Quindi l'incertezza a posteriori è MINORE di quella a priori

Avendo osservato il dato $y = y(1)$, la stimatore ottimo di Bayes sono:

$$\boxed{\hat{\theta} = E[\theta | y = y(1)] = \frac{\lambda_{\theta y}}{\lambda_{yy}} y(1)}$$

Si può calcolare la varianza dell'errore di stima, ovvero:

$$Var[\vartheta - \hat{\vartheta}] = E\left[\left((\vartheta - \hat{\vartheta}) - E[\vartheta - \hat{\vartheta}]\right)^2\right]$$

$$\hookrightarrow E[\vartheta - \hat{\vartheta}] = E[\vartheta] - E[\hat{\vartheta}] = 0 - E\left[\frac{\lambda_{\vartheta y}}{\lambda_{yy}} y\right] = 0 - 0$$

$E[\vartheta] = 0$ per ipotesi; y ha valore atteso $= 0$ per ipotesi

$$\Rightarrow Var[\vartheta - \hat{\vartheta}] = E[(\vartheta - \hat{\vartheta})^2] = E\left[\left(\vartheta - \frac{\lambda_{\vartheta y}}{\lambda_{yy}} y\right)^2\right] = E\left[\vartheta^2 - 2\frac{\lambda_{\vartheta y}}{\lambda_{yy}}\vartheta y + \frac{\lambda_{\vartheta y}^2}{\lambda_{yy}^2} y^2\right]$$

$$= E[\vartheta^2] - 2\frac{\lambda_{\vartheta y}}{\lambda_{yy}} E[\vartheta y] + \frac{\lambda_{\vartheta y}^2}{\lambda_{yy}^2} E[y^2]$$

$$= \lambda_{\vartheta\vartheta} - 2\frac{\lambda_{\vartheta y}}{\lambda_{yy}} \cdot \lambda_{\vartheta y} + \frac{\lambda_{\vartheta y}^2}{\lambda_{yy}^2} \cdot \lambda_{yy} = \boxed{\lambda_{\vartheta\vartheta} - \frac{\lambda_{\vartheta y}^2}{\lambda_{yy}}}$$

VARIANZA DELLA POSTERIORI

STIMA LINEARE

Non è sempre il caso che ϑ e y siano congiuntamente Gaussiane. Vogliamo quindi trovare un stimatore che non faccia ipotesi sulle pdf congiunte di ϑ ed y.

Supponiamo ϑ e y r.c. scalari con valore atteso nullo e varianza $\lambda_{\vartheta\vartheta}$ e λ_{yy} rispettivamente:

$$E[\vartheta] = 0 \quad E[y] = 0 \quad E[\vartheta^2] = \lambda_{\vartheta\vartheta} \quad E[y^2] = \lambda_{yy} \quad E[\vartheta y] = \lambda_{\vartheta y}$$

Vogliamo stimare ϑ dato y tramite un stimatore lineare, t.c.:

$$\hat{\vartheta} = \alpha y + \beta \qquad \alpha, \beta \in \mathbb{R} \text{ parametri reali}$$

Per trovare α e β, impostiamo la cifra di merito da minimizzare

$J(\alpha,\beta)$ è la varianza dell'errore di stima

$$J(\alpha,\beta) = E[(\vartheta - \hat{\vartheta})^2] = E[(\vartheta - \alpha y - \beta)^2]$$

$$\bullet \frac{dJ(\alpha,\beta)}{d\alpha} = 0 \Rightarrow 2E[(\vartheta - \alpha y - \beta)\cdot(-y)] = 2\left(E[-\vartheta y] + E[\alpha y^2] + E[\beta y]\right) =$$

$$= 2\left(-\lambda_{\vartheta y} + \alpha\lambda_{yy} + \cancel{\beta \cdot 0}\right) = 2\left(-\lambda_{\vartheta y} + \alpha\lambda_{yy}\right) = 0$$

- $\frac{\partial J(\alpha,\beta)}{\partial \beta} = 0 \Rightarrow 2E\left[(\theta - \alpha y - \beta)\cdot(-1)\right] = 2E\left[-\theta + \alpha y + \beta\right] =$

$$= 2\left(E[-\theta] + \alpha E[y] + E[\beta]\right) = 2\beta = 0$$

$$\begin{cases} 2(-\lambda_{\theta y} + \alpha \lambda_{yy}) = 0 \\ 2\beta = 0 \end{cases} \begin{cases} \boxed{\alpha = \frac{\lambda_{\theta y}}{\lambda_{yy}}} \\ \boxed{\beta = 0} \end{cases}$$

Lo stimatore lineare ottimo è dato quindi da:

$$\boxed{\hat{\theta} = \alpha y + \beta = \frac{\lambda_{\theta y}}{\lambda_{yy}} \cdot y + 0 = \frac{\lambda_{\theta y}}{\lambda_{yy}} \cdot y}$$

COINCIDE CON LO STIMATORE DI BAYES!! NEL CASO GAUSSIANO

La varianza dell'errore di stima si ricava essere:

$$\boxed{Var[\theta - \hat{\theta}] = \lambda_{\theta\theta} - \frac{\lambda_{\theta y}^2}{\lambda_{yy}}}$$

COME BAYES NEL CASO GAUSSIANO!

↓

l'incertezza dell'errore di stima è minore rispetto a quella a priori

Osservazione

Lo stimatore lineare non fa nessuna ipotesi sulla distribuzione congiunta delle variabili. Infatti gli basta conoscere $\lambda_{\theta y}$ e λ_{yy}.

↓

Potrebbe dunque esserci uno stimatore migliore di quello lineare ottimo, cioè con varianza dell'errore di stima minore

↓

Se però incognita e data hanno distribuzione congiuntamente Gaussiana, allora non esiste nessuno stimatore migliore di quello lineare ottimo

Osservazioni

1) Se $\lambda_{\theta y} = 0$, cioè θ e y sono incorrelati, ovvero il dato y non porta informazioni su θ, allora la stima a priori non viene modificata dal dato. Infatti $\hat{\theta} = 0$ se $\lambda_{\theta y} = 0$, e $Var[\theta - \hat{\theta}] = Var[\theta] = \lambda_{\theta\theta}$

2) A parità di $\lambda_{\theta y}$, più elevato è λ_{yy}, e più piccola sarà la diminuzione di $Var[\theta - \hat{\theta}]$ causata dal dato y. Un valore elevato di λ_{yy} significa che il dato y è affetto da elevata incertezza (quindi porta poca informazione)

GENERALIZZAZIONE 1 : valore atteso non nullo, θ e y scalari

Se $E[\theta] = \mu_\theta \neq 0$
$E[y] = \mu_y \neq 0$
$\Rightarrow$ lo stimatore di Bayes nel caso gaussiano e lo stimatore lineare ottimo sono:

$$\hat{\theta} = \mu_\theta + \frac{\lambda_{\theta y}}{\lambda_{yy}}(y - \mu_y)$$

$$Var[\theta - \hat{\theta}] = \lambda_{\theta\theta} - \frac{\lambda_{\theta y}^2}{\lambda_{yy}}$$

GENERALIZZAZIONE 2: y e θ sono vettoriali, $y \in \mathbb{R}^{m_y \times 1}$, $\theta \in \mathbb{R}^{m_\theta \times 1}$

Se $E[\theta] = \mu_\theta \neq 0$
$E[y] = \mu_y \neq 0$

$$Var\begin{bmatrix} y \\ \theta \end{bmatrix} = \left[\begin{array}{c|c} \Lambda_{yy} & \Lambda_{y\theta} \\ \hline \Lambda_{\theta y} & \Lambda_{\theta\theta} \end{array}\right] \quad \text{con } \Lambda_{y\theta} = \Lambda_{\theta y}^T$$

$\mu_\theta \in \mathbb{R}^{m_\theta \times 1}$
$\mu_y \in \mathbb{R}^{m_y \times 1}$

$\Lambda_{yy} \in \mathbb{R}^{m_y \times m_y}$, $\Lambda_{\theta\theta} \in \mathbb{R}^{m_\theta \times m_\theta}$
$Var\begin{bmatrix} y \\ \theta \end{bmatrix} \in \mathbb{R}^{(m_y + m_\theta) \times (m_y + m_\theta)}$

Allora lo stimatore di Bayes nel caso Gaussiano e lo stimatore lineare ottimo sono dati da:

$$\hat{\theta} = \mu_\theta + \Lambda_{\theta y}\Lambda_{yy}^{-1}(y - \mu_y)$$

$$Var[\theta - \hat{\theta}] = \Lambda_{\theta\theta} - \Lambda_{\theta y}\Lambda_{yy}^{-1}\Lambda_{y\theta}$$

Nota

Le formule appena viste ammettono una forma ricorsiva: si effettua cioè la stima $\hat{\theta}$ con l'arrivo di nuovi dati, partendo dalla stima precedente

↓

Queste equazioni ricorsive saranno alla base del FILTRO DI KALMAN, in cui lo stato $x(t)$ e l'uscita $y(t)$ sono visti come variabili casuali, e si vuol stimare lo stato $x(t)$ (l'incognita) dato l'osservazione dei dati $y(t)$

STIMA BAYESIANA DEL VALORE ATTESO DI VARIABILI GAUSSIANE

Siano $y(i) \sim N(\theta, \lambda_{yy})$, i.i.d., λ_{yy} NOTO. Si vuole stimare il parametro θ tramite stima Bayesiana. Supponiamo $N = 1$

- Si definisce quindi una PRIOR sul parametro θ, ovvero $P(\theta)$. Ottenuto che il parametro ignoto in questo caso è $\theta = E[y]$, ovvero il valore atteso di y
- Imponiamo una PRIOR Gaussiana su θ, ovvero $P(\theta) = N(\mu_\theta, \lambda_{\theta\theta})$

Un modo per descrivere i dati y è: $y(i) = \theta + e(i)$ $e(i) \sim N(0, \lambda_{ee})$, i.i.d, e.i.i. θ,
ovvero, i dati hanno media data dal valore di θ e disturbo dato da $e(i)$

↓

posso definire la LIKELIHOOD $P(y|\theta) = N(\theta, \lambda_{ee})$, in cui θ è la variabile indipendente

Siamo quindi nel tipico caso di inferenza bayesiana in cui ho un prior su un parametro, $P(\theta)$, e ho una likelihood in funzione di quel parametro, $P(y|\theta)$
Posso calcolare la posterior come:

$$P(\theta|y) = \frac{P(y|\theta) \cdot P(\theta)}{P(y)}$$ → sì che è Gaussiana!

dove $P(y) = \int_{-\infty}^{+\infty} P(y|\theta) P(\theta)$, e usare come $\hat{\theta}$ il valore atteso condizionato di $P(\theta|y)$.

↓

Ossia più che, dato che $P(y|\theta)$ e $P(\theta)$ sono Gaussiane, allora anche $P(y, \theta)$ è Gaussiana

↓

Quindi uso le formule viste per le distribuzioni condizionate nel caso Gaussiano, e uso $\hat{\theta} = E[\theta|y]$ (che coincide con lo stimatore lineare ottimo)

La stima ottima è quindi:

$$\hat{\theta} = \mu_\theta + \frac{\lambda_{\theta y}}{\lambda_{yy}} (y - E[y])$$

Devo calcolare $E[y]$, $\lambda_{\theta y}$, λ_{yy}

- $E[y] = E[\vartheta + e] = E[\vartheta] + E[e] = \mu_\vartheta + 0 = \boxed{\mu_\vartheta}$

- $\lambda_{\vartheta y} = E\left[(\vartheta - \mu_\vartheta)\cdot(y - \mu_\vartheta)\right] = E\left[\vartheta y - \vartheta\mu_\vartheta - \mu_\vartheta y + \mu_\vartheta^2\right]$

$= E[\vartheta y] - E[\vartheta\mu_\vartheta] - E[\mu_\vartheta y] + E[\mu_\vartheta^2]$

$= E[\vartheta(\vartheta+e)] - \mu_\vartheta\mu_\vartheta - \cancel{\mu_\vartheta\mu_\vartheta} + \cancel{\mu_\vartheta^2}$

$= E[\vartheta^2] + \cancel{E[\vartheta e]} - \mu_\vartheta^2 = E[\vartheta^2] - E[\vartheta]^2 = Var[\vartheta] = \boxed{\lambda_{\vartheta\vartheta}}$

- $\lambda_{yy} = E\left[(y - E[y])^2\right] = E\left[(y-\mu_\vartheta)^2\right] = E\left[y^2 - 2y\mu_\vartheta + \mu_\vartheta^2\right]$

$= E[y^2] - 2\mu_\vartheta E[y] + E[\mu_\vartheta^2]$

$= E[(\vartheta+e)^2] - 2\mu_\vartheta\mu_\vartheta + \mu_\vartheta^2$

$= E[\vartheta^2 + 2\vartheta e + e^2] - \mu_\vartheta^2 = E[\vartheta^2] + 2\cancel{E[\vartheta e]} + E[e^2] - \mu_\vartheta^2$

$= \underbrace{E[\vartheta^2] - E[\vartheta]^2} + E[e^2]$

$= Var[\vartheta] + Var[e] = \boxed{\lambda_{\vartheta\vartheta} + \lambda_{ee}}$

Quindi:

$$\hat{\vartheta} = \mu_\vartheta + \frac{\lambda_{\vartheta y}}{\lambda_{yy}}(y - E[y]) = \mu_\vartheta + \frac{\lambda_{\vartheta\vartheta}}{\lambda_{\vartheta\vartheta} + \lambda_{ee}}(y - \mu_\vartheta)$$

$$= \mu_\vartheta + \frac{\lambda_{\vartheta\vartheta}}{\lambda_{\vartheta\vartheta}+\lambda_{ee}} y - \frac{\lambda_{\vartheta\vartheta}}{\lambda_{\vartheta\vartheta}+\lambda_{ee}}\mu_\vartheta = \frac{\mu_\vartheta(\lambda_{ee} + \cancel{\lambda_{\vartheta\vartheta}}) + \lambda_{\vartheta\vartheta} y - \cancel{\lambda_{\vartheta\vartheta}\mu_\vartheta}}{\lambda_{\vartheta\vartheta} + \lambda_{ee}}$$

$$= \boxed{\frac{\lambda_{ee}}{\lambda_{\vartheta\vartheta} + \lambda_{ee}}\mu_\vartheta + \frac{\lambda_{\vartheta\vartheta}}{\lambda_{\vartheta\vartheta}+\lambda_{ee}} y}$$

È IL VALORE ATTESO DELLA POSTERIOR $P(\vartheta|y)$

↓

la distribuzione a posteriori della media ha questo valore atteso

Osservazioni

- La stima a posteriori del valore atteso è una via di mezzo tra la stima a priori μ_0 e la stima data dal dato, ovvero il valore y

- Nel caso in cui osservo N dati, ho che:

$$\hat{\vartheta} = \frac{\lambda_{ee}}{N\cdot\lambda_{00} + \lambda_{ee}}\mu_0 + \frac{N\cdot\lambda_{00}}{N\cdot\lambda_{00} + \lambda_{ee}}\hat{\mu}_{ML}$$

STIMA ML della media di una gaussiana

$$\hat{\mu}_{ML} = \frac{1}{N}\sum_{i=1}^{N} y(i)$$

L se $N \to \infty$, allora $\hat{\vartheta} = \hat{\mu}_{ML}$ => ho un sacco di evidenza!!

L se $\lambda_{ee} \gg N\lambda_{00}$, allora i dati hanno molta incertezza e non fanno cambiare la stima a priori

PARTE II: SISTEMI DINAMICI

Tratteremo 2 problemi: 1) Analisi e modellistica di serie temporali
2) Analisi e modellistica di sistemi I/O

SERIE TEMPORALI

Insieme di dati nel tempo $D = \{y(1), y(2), \dots, y(N)\}$. Indicheremo ogni dato con $y(t)$, anziché $y(i)$ che denota dati statici

Esempi
- Valori di un titolo azionario
- mm di pioggia caduti in una settimana
- concentrazione di un ormone in un individuo, misurata ogni giorno alla stessa ora

Che problema vogliamo risolvere?

PREDIZIONE: noti i dati da $t=1$ e $t=N$, prevedere il valore di y al tempo $t=N+1$

$$\hat{y}(N+1|N)$$

$\hat{y}$: predico il valore a $t=N+1$; $|N$: noti i dati fin al tempo N

SISTEMI INGRESSO/USCITA

Abbiamo 2 insiemi di dati, uno di ingresso ed uno di uscita

$\{u(1), u(2), \dots, u(N)\}$ $\{y(1), y(2), \dots, y(N)\}$

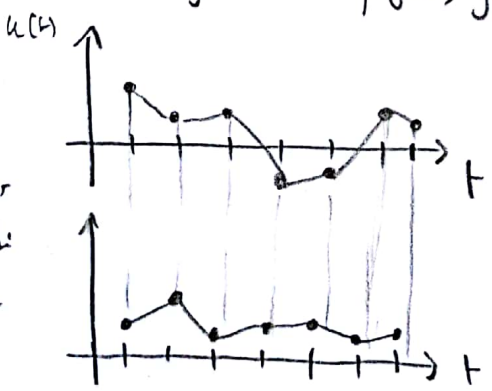

Nota

La presenza di un ingresso può ridurre l'incertezza di predizione dell'uscita

Esempio

INGRESSO (CAUSA)	USCITA (EFFETTO)
corrente	Coppia
dosaggio medicinale	Concentrazione ormone
mm di pioggia	Concentrazione di

Che tipo di problemi vogliamo risolvere?

1) PREDIZIONE: come prima
2) CONTROLLO: determinare la relazione $u \to y$, in modo da progettare un controllore che determini $u(t)$

Osservazione

Lavoreremo con segnali e sistemi a tempo discreto. I segnali sono quindi campionati con tempo di campionamento Δt

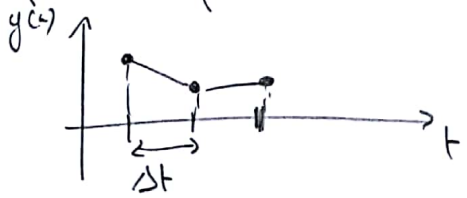

$$y(2) = y(2 \cdot \Delta t)$$

Come impostiamo il problema?

- SERIE TEMPORALI:

Modelliamo la serie temp. $y(t)$ come l'uscita di un sistema con ingresso "rumore" non misurabile

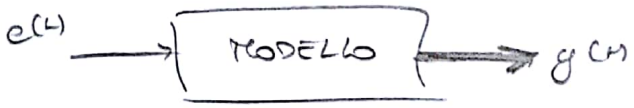

- SISTEMI I/O:

Modelliamo l'uscita come somma di una componente deterministica e una componente di errore

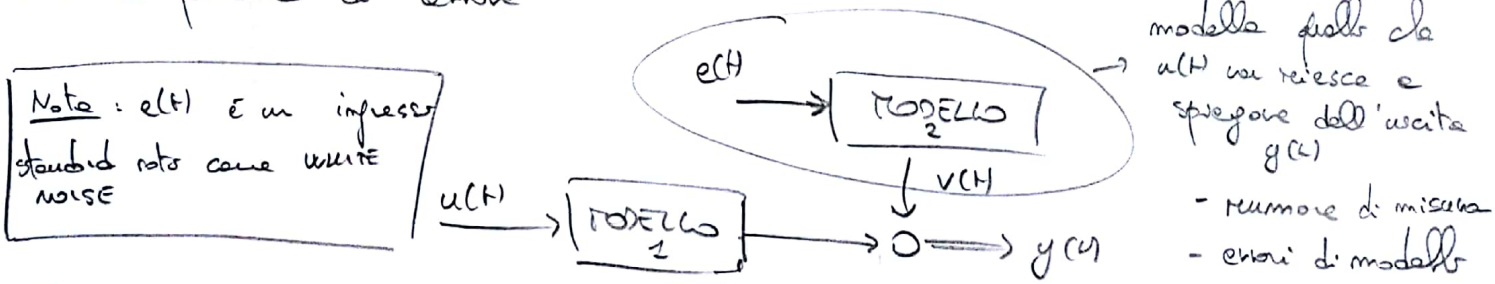

Osservazione

Come nel caso dei sistemi statici, le y sono affette da rumore. In quel caso avevamo modellato i dati y come delle variabili casuali (facendo o meno ipotesi sulla loro distribuzione di probabilità)

↓

In questo caso però i dati non sono indipendenti, ma sono campionati da un segnale che evolve nel tempo

Non abbiamo più quindi osservazioni di variabili casuali semplici, ma osserviamo una successione di v.c. nel tempo ⇒ PROCESSI STOCASTICI

PROCESSI STOCASTICI

Un processo stocastico a tempo discreto è una successione (INFINITA) di v.c. definite a partire dallo stesso esperimento casuale S e ordinate secondo un indice temporale t

$$v(1,s),\ v(2,s),\ v(3,s),\ \dots,\ v(t,s)$$

- Fissato l'esito $s=\bar{s}$, si ottiene una REALIZZAZIONE del processo stocastico. Se cambia l'esito, otteniamo un'altra serie di valori

- Si può pensare ad un PS come ad un segnale (anche se il PS può avere diverse realizzazioni)

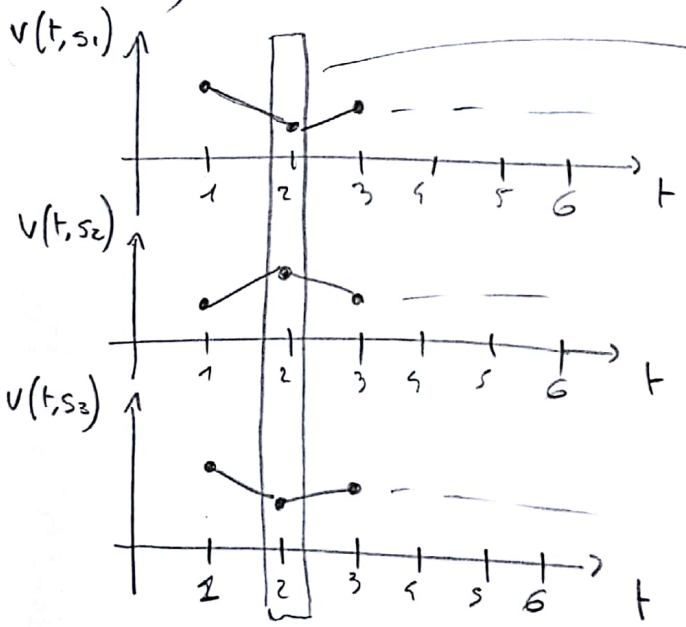

$v(2)$ è la variabile casuale al tempo $t=2$,
↓
a seconda dell'esito s ho ottenuto 3 valori diversi

Nota

Spesso ometteremo la dipendenza da s, indicando $v(1,\bar{s}),\ v(2,\bar{s}),\ \dots,\ v(3,\bar{s})$ con $v(1), v(2), v(3)$

Prima interpretavamo i dati $y(i)$ come variabili casuali per gestire l'incertezza nella loro misura
↓
Adesso interpretiamo la serie di dati $y(t)$ come realizzazione finita di un processo stocastico. Il segnale $u(t)$ è un segnale qualunque
→ STAZIONARIO

Dato un processo stocastico $v(t,s)$ si definiscono:

- VALORE ATTESO

$$m(t) = E[v(t,s)]$$

- è il valor atteso della variabile casuale $v(t,s)$ al tempo t
- Il valor atteso è rispetto a tutti gli esiti s

- COVARIANZA

$$\gamma(t_1, t_2) = E\left[\left(v(t_1) - m(t_1)\right) \cdot \left(v(t_2) - m(t_2)\right)\right]$$

- è la covarianza tra la variabile v al tempo t_1 e al tempo t_2

Nel caso in cui $t_1 = t_2 = t$, otteniamo la varianza al tempo t:

$$\gamma(t,t) = E\left[\left(v(t) - m(t)\right)^2\right]$$

La teoria che svilupperò si basa su un particolare tipo di ps.

PROCESSI STOCASTICI STAZIONARI (PSS)

Definizioni

- Un processo stocastico si dice STAZIONARIO IN SENSO STRETTO se e solo se, $\forall m \in \mathbb{N}$, scelti $t_1, t_2, \dots, t_m$, il comportamento della m-upla $v(t_1+\tau), v(t_2+\tau), v(t_m+\tau)$ è lo stesso di quello della m-upla $v(t_1), v(t_2), \dots, v(t_m)$

↓

la caratteristica probabilistica della m-upla $v(t_1), v(t_2), \dots, v(t_m)$ coincide a quella della m-upla $v(t_1+\tau), v(t_2+\tau), v(t_m+\tau)$

- Un processo stocastico si dice STAZIONARIO IN SENSO DEBOLE se:

1) $m(t) = m \quad \forall t$

2) $\gamma(t_1, t_2) = \gamma(t_3, t_4)$ se $|t_2 - t_3| = |t_2 - t_1| = \tau$ $\quad \forall t_1, t_2, t_3, t_4$

• la covarianza dipende solo dal lag e non dai valori specifici di t_1, t_2, t_3, t_4

Dato che la covarianza dipende solo da τ, si usa:

$$\gamma(\tau) = E\left[\left(v(t) - m\right) \cdot \left(v(t+\tau) - m\right)\right]$$

• è costante $\forall t$

PROPRIETÀ DELLA FUNZIONE DI COVARIANZA DI UN PSS

1) $\gamma(0) = E\left[(v(t) - m)^2\right] \geq 0$ VARIANZA DEL PROCESSO

2) $|\gamma(\tau)| \leq \gamma(0) \quad \forall \tau$ (la funzione è limitata)

3) $\gamma(\tau) = \gamma(-\tau)$ (è una funzione pari)

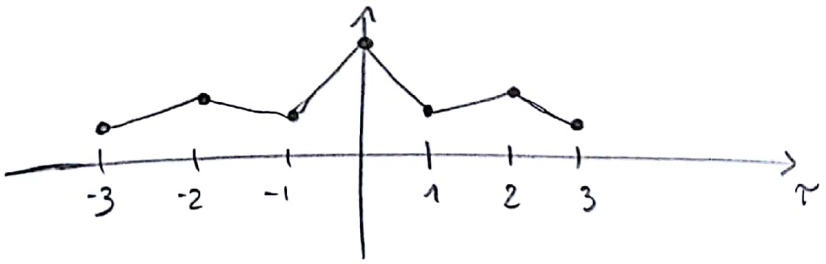

Definizione

Due processi stoc. staz $v_1(t)$ e $v_2(t)$ si dicono equivalenti se hanno la stessa value attesa m e la stessa covarianza $\gamma(\tau)$ $\forall \tau$

Nota

Durante il corso studieremo pss

CASO PARTICOLARE DI PSS: RUMORE BIANCO (WHITE NOISE)

Definizione

Un pss $e(t)$ è detto RUMORE BIANCO, e lo si indica come $e(t) \sim WN(\mu, \sigma^2)$ se:

1) $E[e(t)] = \mu$

2) $\gamma(0) = E\left[(e(t) - \mu)^2\right] = \sigma^2 \quad \forall t$

3) $\gamma(\tau) = E\left[(e(t) - \mu)(e(t+\tau) - \mu)\right] = 0 \quad \forall t, \forall \tau \neq 0$

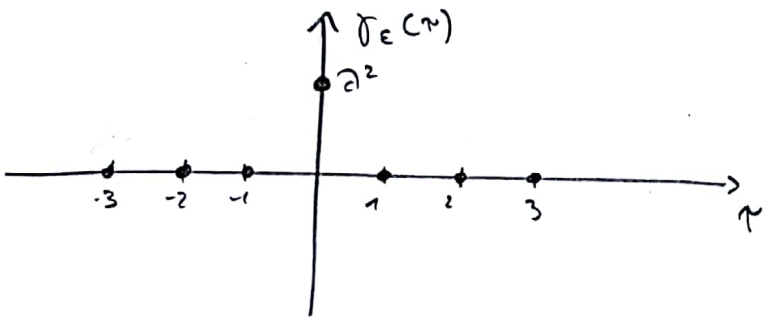

Un WN varia in modo imprevedibile da un istante al successivo

Nota

Non è determinata la distribuzione delle singole v.c. $e(t)$. Possono essere Gaussiane, uniformi, —. In particolare si indica con WGN un rumore bianco Gaussiano

Nota 2

Consideriamo pss a media nulla, infatti non contano le caratteristiche spettrali

RAPPRESENTAZIONE SPETTRALE DI UN PSS

→ dato che studiamo segnali nel tempo, si possono rappresentare in frequenza

↓

voglio studiare il pss → una quantità che caratterizza nel tempo è la $\gamma(\tau)$

Sia $y(t)$ un pss. Si definisce densità spettrale di potenza la trasformata di Fourier a tempo discreto della funzione di covarianza $\gamma_y(\tau)$:

$$\Gamma_y(\omega) = \sum_{\tau=-\infty}^{+\infty} \gamma_y(\tau)\, e^{-j\omega\tau}$$

- come le varie frequenze di $y(t)$ contribuiscono alla varianza di $y(t)$
- come l'energia del segnale si distribuisce alle varie frequenze

Nota

$\Gamma_y(\omega)$ esiste solo per pss tali che $\gamma_y(\tau) \to 0$ per $\tau \to +\infty$. Studieremo così in cui questo vale sempre

Proprietà di $\Gamma_y(\omega)$:

1) $\Gamma_y(\omega)$ è una funzione reale della variabile reale ω

$$\mathrm{Im}(\Gamma_y(\omega)) = 0 \quad \forall \omega \in \mathbb{R}$$

2) $\Gamma_y(\omega)$ è una funzione positiva: $\Gamma_y(\omega) \geq 0 \quad \forall \omega \in \mathbb{R}$

3) $\Gamma_y(\omega)$ è una funzione pari: $\Gamma_y(\omega) = \Gamma_y(-\omega) \quad \forall \omega \in \mathbb{R}$

4) $\Gamma_y(\omega)$ è una funzione periodica di periodo 2π:

$$\Gamma_y(\omega) = \Gamma_y(\omega + k \cdot 2\pi) \quad \forall \omega \in \mathbb{R},\ \forall k \in \mathbb{Z}$$

Nota

Come conseguenza di 4) si può tracciare la funzione solo tra $[-\pi, \pi]$

Si può ricavare $\gamma(\tau)$ partendo da $\Gamma_y(\omega)$ tramite l'antitrasformata:

$$\gamma_y(\tau) \cdot \frac{1}{2\pi} \int_{-\pi}^{+\pi} \Gamma_y(\omega)\, e^{+j\omega\tau}\, d\omega$$

Si nota che:

$$\gamma_y(0) = \frac{1}{2\pi}\int_{-\pi}^{+\pi} \Gamma_y(\omega)\, e^{j\omega\cdot 0}\, d\omega = \frac{1}{2\pi}\int_{-\pi}^{+\pi} \Gamma_y(\omega)\, d\omega$$

→ area sottesa a $\Gamma_y(\omega)$

Quindi, la varianza è l'area sottesa della densità spettrale di potenza, a meno del fattore 2π

DENSITÀ SPETTRALE DI POTENZA DI UN RUMORE BIANCO

Sia $e(n) \sim WN(0, \sigma^2)$. Nel tempo è un segnale imprevedibile

Supponiamo che: $\gamma_e(\tau) = \begin{cases} \sigma^2 & \text{se } \tau = 0 \\ 0 & \text{se } \tau \neq 0 \end{cases}$

Quindi: $\Gamma_e(\omega) = \sum_{\tau=-\infty}^{+\infty} \gamma_e(\tau)\, e^{-j\omega\tau} = \sigma^2 \cdot e^{-j\omega\cdot 0} = \boxed{\sigma^2}$

La densità spettrale di potenza del rumore bianco è una costante

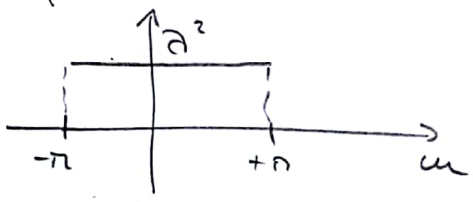

Questo vuol dire che tutte le frequenze contribuiscono in egual misura alla variabilità del segnale, non vi sono frequenze predominanti

↓

quindi imprevedibile

RAPPRESENTAZIONE DINAMICA DI UN PSS

Abbiamo rappresentato un PSS sia nel tempo con $\gamma(\tau)$ sia nella frequenza con $\Gamma(\omega)$. Queste rappresentazioni sono però "statiche"

↓

rappresentano il pss nella sua integrità

Per risolvere il problema della predizione, è necessario passare ad una rappresentazione dinamica, che metta in luce come il futuro dipende dal passato

↓

In che modo è possibile esprimere un pss in forma dinamica?

Consideriamo un rumore bianco $e(t) \sim WN(0, \lambda^2)$. Abbiamo visto che $e(t)$ ha uno spettro costante

↓

Un pss $v(t)$ può quindi essere rappresentato pesando opportunamente differenti campioni di $e(t)$ ad istanti diversi di tempo

$$v(t) = w_0 e(t) + w_1 e(t-1) + w_2 e(t-2) + \dots$$

Infatti:

$$v(t-1) = w_0 e(t-1) + w_1 e(t-2) + \dots$$
$$v(t-2) = w_0 e(t-2) + w_1 e(t-3) + \dots$$

$$\gamma(0) = E\left[v(t)^2\right] = \left(w_0^2 + w_1^2 + w_2^2 + \dots\right)\lambda^2$$

$$\gamma(1) = E\left[v(t)\,v(t-1)\right] = E\left[w_0 w_1 e(t-1)^2 + w_1 w_2 e(t-2)^2 + \dots\right] = \left(w_0 w_1 + w_1 w_2 + \dots\right)\lambda^2$$

$$\gamma(2) = E\left[v(t)\,v(t-2)\right] = E\left[w_0 w_2 e(t-1)^2 + w_1 w_3 e(t-2)^2 + \dots\right] = \left(w_0 w_2 + w_1 w_3 + \dots\right)\lambda^2$$

Quindi, combinando i pesi w_i, posso ottenere funzioni di covarianza (e quindi densità spettrali di potenza) arbitrarie

↓

quindi posso ottenere pss arbitrari (infatti la $\gamma(\tau)$ con stato ottenuta usando le proprietà del $e(t)$ che è un pss)

$v(t)$ è STAZIONARIO perché combinazione lineare di pss

$$v(t) = w_0 e(t) + w_1 e(t-1) + \dots$$
$$= \sum_{i=0}^{+\infty} w_i\, e(t-i)$$

FORMULA DI CONVOLUZIONE

w_i: coefficienti risposta all'impulso

risposta di un sistema dinamico causale AS. STAB ad un ingresso $e(t)$

↓

è il movimento forzato, (il movimento libero è 0 essendo AS. STAB)

Il sistema dinamico ha w_i come risposta impulsiva e:

$$W(z) = \sum_{i=0}^{+\infty} w_i \cdot z^{-i} \quad \Rightarrow \quad v(t) = W(z)\, e(t)$$

come funzione di trasferimento

$e(t)$ viene filtrato da $W(z)$

$W(z)$ fa SHAPING dello spettro di $e(t)$ che è costante

Studieremo il caso in cui $W(z)$ sia una fdt razionale fratta, ovvero $W(z) = \frac{C(z)}{A(z)}$ (FILTRO DIGITALE)

↓

I pss che si ottengono filtrando un rumore bianco tramite una fdt AS. STAB (razionale fratta) sono detti processi a spettro razionale

Teorema

Dato un processo stocastico $y(t)$, uscita di regime di un filtro $W(z)$, alimentato da un processo stocastico $v(t)$

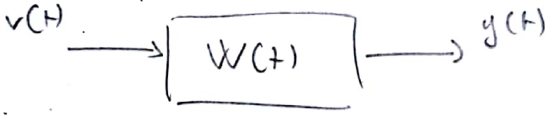

Condizione necessaria e sufficiente affinché, $\forall$ condizione iniziale, a regime $y(t)$ sia un pss è che:

1) $v(t)$ sia pss
2) $W(z)$ sia AS. STAB $\Rightarrow$ se $W(z) = \frac{C(z)}{A(z)} \Rightarrow$ radici di $A(z)$ $|\ | < 1$

Ovvero, l'uscita di regime di un filtro asintoticamente stabile, alimentato da un pss, è un pss

Riprendendo l'approccio iniziale di modellazione, abbiamo che la sequenza $e(t)$

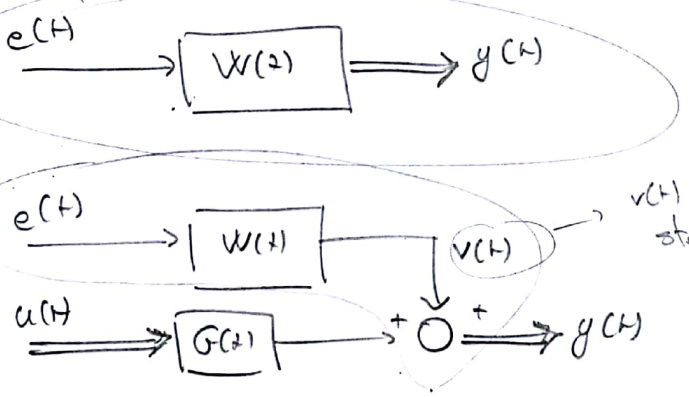

modella la stocasticità dei dati temporali

↓

può essere usato anche per modelli I/O, nel qual caso modella anche errori di modello $G(z)$

Nota

$G(z)$ è un sistema fisico, reale. $W(z)$ ed $e(t)$ non esistono: sono solo un metodo per modellare ciò che $G(z)$ non riesce a fare la stocasticità della serie di dati

Nota

Nella modellazione di serie storiche $e(t) \rightarrow \boxed{W(t)} \Longrightarrow y(t)$ si potrebbero essere trend o stagionalità

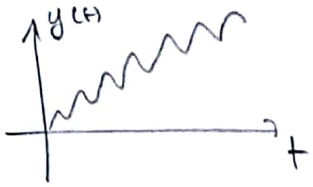

↓

Bisogna quindi prima rimuovere sia trend che stagionalità per ottenere un processo stazionario

↓

Un'altra operazione è rimuovere la media, in modo da semplificare il calcolo dei metodi di identificazione dei modelli

DEMEDIAZIONE

La demediazione permette di semplicare il calcolo di $\gamma(\tau)$ nel caso in cui un processo stocastico $\overset{stat}{v(t)}$ abbia media $m_v \neq 0$

$$\gamma(\tau) = E\left[\left(v(t) - m_v\right)\left(v(t+\tau) - m_v\right) \right]$$

Se avessimo $m_v = 0$

$$\gamma(\tau) = E\left[v(t)\, v(t+\tau) \right]$$

Definiamo quindi $\tilde{v}(t) = v(t) - m_v$

⇓

- $E\left[\tilde{v}(t)\right] = E\left[v(t) - m_v\right] = E\left[v(t)\right] - m_v = m_v - m_v = 0$
- $\tilde{\gamma}(\tau) = E\left[\tilde{v}(t)\,\tilde{v}(t+\tau)\right] = E\left[\left(v(t) - m_v\right)\left(v(t) - m_v\right)\right] = \gamma(\tau)$

Quindi $v(t)$ e $\tilde{v}(t)$ hanno la stessa funzione di covarianza (e stesse caratteristiche spettrali)

↓

non si lede nessuna generalità nello studiare p.s. e media nulla

FAMIGLIE DI MODELLI A SPETTRO RAZIONALE

MODELLI PER SERIE TEMPORALI

PROCESSI MA (Moving Average)

Un processo $y(t)$, generato a partire dal rumore bianco $e(t) \sim WN(\mu, \sigma^2)$, è detto di tipo MA(m) se:

$$y(t) = c_0 e(t) + c_1 e(t-1) + c_2 e(t-2) + \dots + c_m e(t-m) = \sum_{i=0}^{m} c_i\, e(t-i)$$

- $c_0, c_1, \dots, c_m$: COEFFICIENTI DEL MODELLO MA
- m: ORDINE DEL MODELLO
- MA(m): IL MODELLO MA

L'uscita di un MA(m) è la combinazione lineare degli ultimi $m+1$ valori del segnale in ingresso $e(t)$

Ricordando che $z^{-1} x(t) = x(t-1)$, possiamo scrivere $y(t)$ come:

$$y(t) = c_0 e(t) + c_1 e(t) z^{-1} + c_2 e(t) z^{-2} + \dots + c_m e(t) z^{-m}$$

$$= \left(c_0 + c_1 z^{-1} + c_2 z^{-2} + \dots + c_m z^{-m}\right) \cdot e(t) = \boxed{C(z)\, e(t)}$$

$$\Rightarrow \frac{y(t)}{e(t)} = \frac{z^m c_0 + z^{m-1} c_1 + \dots + c_m}{z^m}$$

$e(t) \rightarrow \boxed{C(z)} \rightarrow y(t)$

m poli in $z = 0$

$\Downarrow$

I processi MA sono sempre stazionari

Calcolo dei parametri caratteristici

- **Valor atteso**

$$m(t) = E[y(t)] = E[c_0 e(t) + c_1 e(t-1) + \dots + c_m e(t-m)] = c_0 E[e(t)] + c_1 E[e(t-1)] + \dots + c_m E[e(t-m)]$$

$$= c_0 \mu + c_1 \mu + \dots + c_m \mu$$

$$= \boxed{\mu \sum_{i=0}^{m} c_i}$$

$\Rightarrow$ se $e(t) \sim WN(0, \sigma^2) \Rightarrow \boxed{E[y(t)] = 0}$

- $\gamma(\tau)$, supponiamo $E[y(t)]=0$ per deporitazione

- $\gamma(0) = E\left[(v(t)-m(t))^2\right] = E\left[v(t)^2\right] = E\left[\left(c_0 e(t) + c_1 e(t-1) + \dots + c_m e(t-m)\right)^2\right] =$

$= E\Big[\underbrace{c_0^2 e(t)^2 + c_1^2 e(t-1)^2 + \dots + c_m e(t-m)^2}_{\text{quadrati}} + \underbrace{2c_0c_1 e(t)e(t-1) + \dots + 2c_{m-1}c_m e(t-m+1)e(t-m)}_{\text{doppi prodotti}}\Big]$

$= c_0^2 E[e(t)^2] + c_1^2 E[e(t-1)^2] + \dots + c_m^2 E[e(t-m)^2]$

$= c_0^2 \gamma_\varepsilon(0) + c_1^2 \gamma_\varepsilon(0) + \dots + c_m^2 \gamma_\varepsilon(0) = \boxed{\lambda^2 \cdot \sum_{i=0}^{m} c_i^2}$

- $\gamma(1) = E\left[(v(t)-m(t))(v(t-1)-m(t))\right] = E\left[v(t)\,v(t-1)\right] =$

$= E\left[\left(c_0 e(t) + c_1 e(t-1) + \dots + c_m e(t-m)\right)\left(c_0 e(t-1) + c_1 e(t-2) + \dots + c_m e(t-m-1)\right)\right]$

$= c_0 c_1 E[e(t-1)^2] + c_1 c_2 E[e(t-2)^2] + \dots + c_{m-1} c_m E[e(t-m)^2]$

$= \boxed{\lambda^2 \cdot (c_0 c_1 + c_1 c_2 + \dots + c_{m-1} \cdot c_m)}$

- $\gamma(2) = \lambda^2 (c_0 c_2 + c_1 c_3 + \dots + c_{m-2} c_m)$
- $\gamma(m) = \lambda^2 (c_0 c_m)$
- $\gamma(\tau)$ t.c. $\tau > m \Rightarrow \boxed{\gamma(\tau) = 0}$

Un processo MA(m) dipende solo dagli m valori prima. Oggi diventa impredicibile (come la caratteristica)

Un modo per capire se una serie temporale è MA è quello di guardare se la sua $\gamma(\tau)$ va a zero dopo un certo lag τ

Nota

Il processo $\tilde{y}(t) = \tilde{c}_0 \eta(t) + \tilde{c}_1 \eta(t-1) + \dots + \tilde{c}_m \eta(t-m)$ con $\tilde{c}_i = \alpha \cdot c_i$, $\tilde{\lambda}^2 = \frac{\lambda^2}{\alpha^2}$

$\eta(t) \sim WN(0, \tilde{\lambda}^2)$

ha stessa varianza e funzione di covarianza del processo

$y(t) = c_0 e(t) + c_1 e(t-1) + \dots + c_m e(t-m)$ $e(t) \sim WN(0, \lambda^2)$. Per evitare questa sovra-parametrizzazione, si pone di solito $c_0 = 1$

PROCESSI AR (Autoregressivi)

Un processo $y(t)$, generato a partire da $e(t) \sim WN(\mu, \sigma^2)$, è detto di tipo AR(m) se:

$$y(t) = a_1 y(t-1) + a_2 y(t-2) + \dots + a_m y(t-m) + e(t) = \sum_{i=1}^{m} a_i y(t-i) + e(t)$$

- $a_1, a_2, \dots, a_m$: COEFFICIENTI DEL MODELLO AR
- m : ORDINE DEL MODELLO

L'uscita di un AR(m) è la combinazione lineare degli ultimi m "vecchi" valori del processo stesso, più l'ingresso $e(t)$ allo stesso istante

Forma operatoriale:

$$y(t) = a_1 y(t-1) + a_2 y(t-2) + \dots + a_m y(t-m) + e(t)$$

$$y(t) = a_1 y(t) z^{-1} + a_2 y(t) z^{-2} + \dots + a_m y(t) z^{-m} + e(t)$$

$$y(t)\left[1 - a_1 z^{-1} - a_2 z^{-2} - \dots - a_m z^{-m}\right] = e(t)$$

$e(t) \longrightarrow \boxed{\frac{1}{A(z)}} \longrightarrow y(t)$

$$\frac{y(t)}{e(t)} = \frac{1}{1 - a_1 z^{-1} - a_2 z^{-2} - \dots - a_m z^{-m}} = \frac{1}{A(z)} \Rightarrow \boxed{y(t) = \frac{1}{A(z)} e(t)}$$

$$\Rightarrow \frac{y(t)}{e(t)} = \frac{z^m}{z^m - a_1 z^{m-1} - a_2 z^{m-2} - \dots - a_m}$$

- m ZERI NELL'ORIGINE
- m POLI: quindi non è sempre stabile

è stabile se tutti i poli sono in modulo < 1 ← bisogna fare attenzione alla stima dei parametri

Calcolo parametri caratteristici (nel caso in cui AR(m) è pss)

- **Valore atteso**

$$m = E[y(t)] = E[a_1 y(t-1) + a_2 y(t-2) + \dots + a_m y(t-m) + e(t)]$$

$$= a_1 E[y(t-1)] + a_2 E[y(t-2)] + \dots + a_m E[y(t-m)] + E[e(t)]$$

$$E[y(t)] = (a_1 + a_2 + \dots + a_m) E[y(t)] + \mu$$

$$(1 - a_1 - a_2 - \dots - a_m) E[y(t)] = \mu$$

$$\Rightarrow \boxed{E[y(t)] = \frac{\mu}{1 - a_1 - a_2 - \dots - a_m}}$$

- Se $E[e(t)] = 0$ $\Rightarrow E[y(t)] = 0$

- $\gamma(\tau)$ → calcolo per processi AR(1) perché è complesso

Dato il processo AR(1): $y(t) = a\,y(t-1) + e(t)$ $\quad e(t) \sim WN(\mu, \sigma^2)$

$$\Rightarrow y(t)\left[1 - az^{-1}\right] = e(t) \Rightarrow \boxed{y(t) = \frac{1}{1 - az^{-1}}\, e(t)} \rightarrow A(z)$$

$y(t)$ è stazionario se il polo ha modulo <1

$$1 - az^{-1} = 0 \Rightarrow z - a = 0 \Rightarrow \text{polo in } z = a$$

$$\downarrow$$

$A(z)$ AS. STAB. se $|a| < 1$

Supponiamo $A(z)$ AS. STAB. e che il processo $y(t)$ sia deviazione (media nulla)

- $\gamma(0) = E\left[y(t)^2\right] = E\left[\left(a\,y(t-1) + e(t)\right)^2\right] = E\left[a^2 y(t-1)^2 + e(t)^2 + 2a\,y(t-1)\,e(t)\right]$

$= a^2 E\left[y(t-1)^2\right] + E\left[e(t)^2\right] + 2a\,E\left[y(t-1)\,e(t)\right]$

$= a^2\gamma(0) + \sigma^2 + 0$

→ $y(t-1)$ è incorrelato con $e(t)$ perché dipende da $e(t-1)$ e da $y(t-2)$ → per ricorsione anche $y(t-2)$ è $\perp$ a $e(t)$ e così via

$$\Rightarrow \gamma(0) = a^2\gamma(0) + \sigma^2 \Rightarrow \boxed{\gamma(0) = \frac{\sigma^2}{1 - a^2}}$$

- $\gamma(1) = E\left[y(t)\,y(t-1)\right] = E\left[\left(a\,y(t-1) + e(t)\right)\cdot y(t-1)\right] = E\left[a\,y(t-1)^2 + y(t-1)\,e(t)\right]$

$= a\,E\left[y(t-1)^2\right] + E\left[y(t-1)\,e(t)\right] = a\,\gamma(0) \Rightarrow \boxed{\gamma(1) = a\cdot\gamma(0)}$

- $\gamma(2) = E\left[y(t)\,y(t-2)\right] = E\left[\left(a\,y(t-1) + e(t)\right)y(t-2)\right] = E\left[a\,y(t-1)\,y(t-2) + y(t-2)\,e(t)\right]$

$= a\,E\left[y(t-1)\,y(t-2)\right] + E\left[y(t-1)\,e(t)\right] = a\,\gamma(1) \Rightarrow \boxed{\gamma(2) = a\cdot\gamma(1)}$

$$\Downarrow$$

Generalizzando:

$$\begin{cases} \gamma(0) = \dfrac{\sigma^2}{1-a^2} \\ \gamma(\tau) = a \cdot \gamma(\tau-1) \quad \tau > 0 \end{cases}$$

EQUAZIONI DI YULE-WALKER PER UN AR(1) → esistono anche per un AR(m)

Osservazione

Dato che $|a| < 1$ (abbiamo supposto stazionario per poter calcolare $\gamma(\tau)$) si ha che:

$$|\gamma(\tau+1)| < |\gamma(\tau)|$$

e dato che $a \neq \pm 1$, $\gamma(0)$ esiste finito. Inoltre si ha che:

- Il processo $y(t) = a\,y(t-1) + e(t)$ con $\boxed{0 < a < 1}$ ha $\gamma(\tau) > 0 \ \forall \tau$, e avrà una funzione decrescente che non raggiunge mai lo 0.

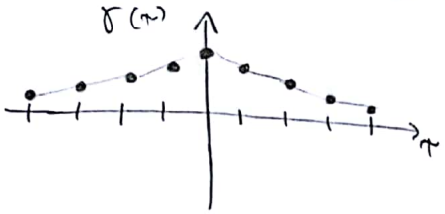

Le realizzazioni del pss $y(t)$ variano lentamente perché i dati sono molto correlati fra loro e non cambiano di segno (in media). Ci si aspetta una realizzazione con componenti a bassa frequenza

- Il processo $y(t) = a\,y(t-1) + e(t)$ con $\boxed{-1 < a < 0}$ ha una funzione $\gamma(\tau)$ che cambia segno ad ogni τ e decresce in valore assoluto

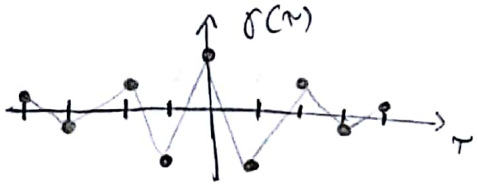

Le realizzazioni del pss $y(t)$ avranno quindi (in media) cambi di segno ripetuti, creando segnali con dei comportamenti in alta frequenza

Approfondimento

Abbiamo visto che, per un modello MA(m), $\gamma(\tau) = 0$ per $\tau > m$. Per gli AR(m) possiamo ottenere un comportamento simile usando le FUNZIONE DI AUTOCORRELAZIONE PARZIALE (PACF) $\gamma_{PAR}(\tau)$, che si annulla (nel caso di un AR(m)) per $\tau > m$

Nell'analisi delle serie temporali in pratica, si fanno questi passaggi:

1) Controllo se è un MA(m) plottando $\gamma(\tau)$
2) " " " AR(m) " $\gamma_{PAR}(\tau)$
3) Se nessuna delle due si annulla, mi servono altri modelli

Un altro tipo di modelli per risolvere il punto 3) è il seguente:

«MODELLI ARMA (Auto Regressive Moving Average)»

Un processo $y(t)$, generato a partire da un rumore bianco $e(t) \sim WN(\mu, \sigma^2)$, è detto di tipo ARMA(m, n) se:

$$y(t) = a_1 y(t-1) + a_2 y(t-2) + \dots + a_m y(t-m) + \quad \text{PARTE AR(m)}$$
$$+ e(t) + c_1 e(t-1) + \dots + c_n e(t-n) \quad \text{PARTE MA(n)}$$

- m: L'ORDINE DEL MODELLO AR
- $a_1, a_2, \dots, a_m$: COEFFICIENTI DEL MODELLO AR
- n: L'ORDINE DEL PROCESSO MA
- $c_1, \dots, c_n$: COEFFICIENTI DEL MODELLO MA

Notiamo che ARMA(0, m) = MA(m) e che ARMA(m, 0) = AR(m). Possiamo in forma operatoriale:

$$y(t)\left[1 - a_1 z^{-1} - a_2 z^{-2} - \dots - a_m z^{-m}\right] = \left(1 + c_1 z^{-1} + c_2 z^{-2} + \dots + c_n z^{-n}\right) e(t)$$

$$\Rightarrow y(t) = \frac{1 + c_1 z^{-1} + c_2 z^{-2} + \dots + c_n z^{-n}}{1 - a_1 z^{-1} - a_2 z^{-2} - \dots - a_m z^{-m}} e(t) = \boxed{\frac{C(t)}{A(t)} e(t)}$$

- $\frac{C(z)}{A(z)}$ è stabile se $A(z)$ ha radici $|z|<1$

MODELLI PER SISTEMI INPUT/OUTPUT

ARMAX (AutoRegressive Moving Average eXogenous)

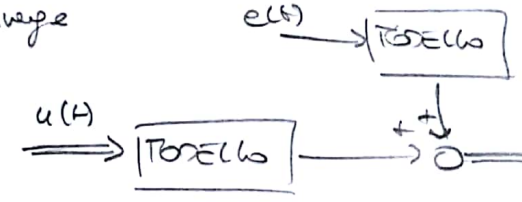

Un processo $y(t)$, generato a partire da un rumore bianco $e(t) \sim WN(\mu, \sigma^2)$ e da un ingresso esterno $u(t)$ (indipendente dal processo), è detto ARMAX $(m, n, k+p)$ se:

$$y(t) = a_1 y(t-1) + a_2 y(t-2) + \dots + a_m y(t-m) + \quad \text{PARTE AR}(m)$$
$$+ e(t) + c_1 e(t-1) + \dots + c_n e(t-n) + \quad \text{PARTE MA}(n)$$
$$+ b_0 u(t-k) + b_1 u(t-k-1) + \dots + b_p u(t-k-p) \quad \text{PARTE X}(k+p)$$

- m: ORDINE PROCESSO AR
- $a_1, a_2, \dots, a_m$: COEFFICIENTI PROCESSO AR
- n: ORDINE PROCESSO MA
- $c_1, c_2, \dots, c_n$: COEFFICIENTI PROCESSO MA
- p: ORDINE VARIABILE ESOGENA
- $p+1$: COEFFICIENTI VARIABILE ESOGENA
- k: RITARDO PURO TRA INGRESSO ED USCITA

$$y(t)\left[1 - a_1 z^{-1} - a_2 z^{-2} - \dots - a_m z^{-m}\right] = e(t)\left[1 + c_1 z^{-1} + c_2 z^{-2} + \dots + c_n z^{-n}\right]$$
$$+ u(t-k)\left[b_0 + b_1 z^{-1} + b_2 z^{-2} + \dots + b_p z^{-p}\right]$$

$$y(t) A(z) = e(t) C(z) + u(t-k) B(z)$$

$$y(t) = \frac{C(z)}{A(z)} e(t) + \frac{B(z)}{A(z)} u(t-k) = \boxed{\frac{C(z)}{A(z)} e(t) + \frac{B(z)}{A(z)} z^{-k} u(t)}$$

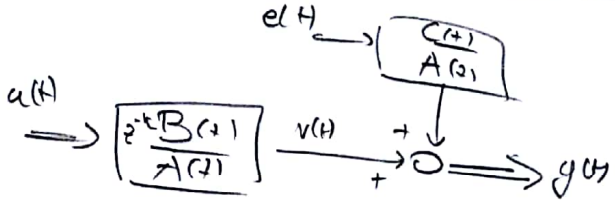

Osservazione

Dato che l'ingresso $u(t)$ influenza il processo, non si può dire a priori se $y(t)$ sia stazionario o meno; $y(t)$ è stazionario se:

- Le radici di $A(z)$ sono all'interno della circonferenza di raggio unitario
- $u(t)$ è stazionario (quindi costante, dato che non è un processo stocastico)

In generale il processo ARMAX non è stazionario, ma la sua componente stocastica (ARMA) deve essere. La fonte di non stazionarietà è una componente deterministica (nota), quindi la posso modellare

↓

In generale, le componenti di un stazionarietà o le tolgo (es trend, stagionalità) o le modello (nel caso di ingresso esogeno noto "si modella da solo" in quanto noto)

Es

Dire se il seguente processo è stazionario e calcolarne media e funzione di covarianza

$$y(t) = \frac{1}{3} y(t-1) + e(t) + 2 \qquad e(t) \sim WN(1,1)$$

$$y(t)\left[1 - \frac{1}{3}z^{-1}\right] = e(t) + 2 \quad \Rightarrow \quad y(t) = \underbrace{\frac{1}{1-\frac{1}{3}z^{-1}}}_{A(z)} e(t) + \underbrace{\frac{1}{1-\frac{1}{3}z^{-1}}}_{A(z)} \cdot \underbrace{2}_{B(z)} \to u(t)$$

Poli di $A(z)$

$$1 - \frac{1}{3}z^{-1} = 0 \Rightarrow z^{-1} = 3 \Rightarrow \boxed{z = \frac{1}{3} < 1}$$

$\Rightarrow$ - $A(z)$ AS. STAB
- $u(t)$ STAZIONARIO $\Rightarrow$ $\boxed{y(t) \text{ è PSS.}}$

Qual è il contributo di $u(t)$ sull'uscita $y(t)$? Teorema della risposta in frequenza: dato un ingresso sinusoidale $u(t) = a \cdot \cos(\omega t + \varphi)$ la sua uscita:

$$w(t) = \left|G(e^{j\omega})\right| \cdot a \cdot \cos\left(\omega t + \varphi + \angle G(e^{j\omega})\right) \qquad G(z) = \frac{B(z)}{A(z)}$$

Dato che $u(t)$ costante, la frequenza $\omega = 0$, quindi:

$$w(t) = \left|G(e^{j0})\right| \cdot a = \left|\frac{1}{1-\frac{1}{3}e^{-j0}}\right| \cdot 2 = \frac{1}{1-\frac{1}{3}} \cdot 2 = \frac{1}{\frac{3-1}{3}} \cdot 2 = \frac{3}{2} \cdot 2 = \boxed{3}$$

L'effetto di $u(t)$ è spostare la media del PSS

- $E[y] = m_y = E\left[\frac{1}{3}y(t-1) + e(t) + 2\right] = \frac{1}{3}m_y + 1 + 2 \Rightarrow \left(1-\frac{1}{3}\right)m_y = 3$

$\Rightarrow \frac{2}{3}m_y = 3 \Rightarrow \boxed{m_y = \frac{9}{2}}$

- $\gamma_y(\tau)$ $\Rightarrow$ Depolarizzo $y(t)$ ed $e(t)$.

$$\begin{cases} \tilde{y}(t) = y(t) - \frac{9}{2} \\ \tilde{e}(t) = e(t) - 1 \end{cases}$$

Scrivo il processo come:

$$y(t) = \frac{1}{3}y(t-1) + e(t) + 2$$

$$\tilde{y}(t) + \frac{9}{2} = \frac{1}{3}\left[\tilde{y}(t-1) + \frac{9}{2}\right] + \tilde{e}(t) + 1 + 2$$

$$\tilde{y}(t) = \frac{1}{3}\tilde{y}(t-1) + \frac{9}{6} - \frac{9}{2} + 3 + \tilde{e}(t)$$

$$\frac{3 - 9 + 6}{2} = 0$$

$$\boxed{\tilde{y}(t) = \frac{1}{3}\tilde{y}(t-1) + \tilde{e}(t)}$$ AR(1) a media nulla

$$\tilde{\gamma}(\tau) = \gamma(\tau) = \left(\frac{1}{3}\right)^{\tau} \cdot \frac{1}{1-\frac{1}{9}} = \frac{9}{8} \cdot \frac{1}{3^{\tau}} = \boxed{\frac{3^{2-\tau}}{8}}$$

YULE WALKER

$$a^{\tau} \cdot \frac{\lambda^2}{1-a^2} = a^{\tau} \cdot \gamma(0)$$

Teorema

Dato un processo stocastico stazionario ARMA(m, n), esso può essere scritto come MA(∞)

Es ARC1)

$$y(t) = a\,y(t-1) + e(t) \quad e(t) \sim WN(\mu, \lambda^2)$$

$$y(t) = \frac{1}{1-az^{-1}}\,e(t)$$ limite serie geometrica di ragione az^{-1}

$$= \sum_{k=0}^{+\infty} (az^{-1})^k \cdot e(t) = \sum_{k=0}^{+\infty} a^k \cdot e(t-k) \quad MA(\infty)$$

CALCOLO DELLO SPETTRO DI UN PSS A PARTIRE DAL SUO MODELLO

Nota: useremo i termini DENSITÀ SPETTRALE DI POTENZA e SPETTRO in modo equivalente

Se il pss $y(t)$ è rappresentabile come uscita di regime di un filtro AS. STABILE dimentato da un pss $v(t)$:

$$y(t) = F(z)\, v(t)$$

$$v(t) \longrightarrow \boxed{F(z)} \longrightarrow y(t)$$

è possibile calcolare lo spettro di $y(t)$ come:

$$\boxed{\Gamma_y(\omega) = \left|F(e^{j\omega})\right|^2 \cdot \Gamma_v(\omega)}$$

- $\Gamma_y(\omega)$: SPETTRO DELL'USCITA
- $\left|F(e^{j\omega})\right|^2$: MODULO AL QUADRATO DELLA RISPOSTA IN FREQUENZA DEL FILTRO
- $\Gamma_v(\omega)$: SPETTRO DELL'INGRESSO

Se l'ingresso è un white noise $e(t) \sim WN(0, \lambda^2)$: $\Gamma_y(\omega) = \left|F(e^{j\omega})\right|^2 \cdot \lambda^2$

Es

Consideriamo un processo $MA(1)$, calcolare $\Gamma_y(\omega)$:

$$y(t) = e(t) + c\,e(t-1) \qquad e(t) \sim WN(0,1)$$

1) Usando la definizione

$$\Gamma(\omega) = \sum_{\tau=-\infty}^{+\infty} \gamma(\tau)\, e^{-j\omega\tau} \qquad \lambda^2 \sum_{i=0}^{m} c_i^2$$

$\lambda^2(c_0 c_1)$

$$= \gamma(-1)\, e^{-j\omega(-1)} + \gamma(0)\, e^{-j\omega 0} + \gamma(1)\, e^{-j\omega(1)}$$

$$= 1^2 (1 \cdot c)\, e^{j\omega} + (1^2 + c^2)\cdot 1 + c\, e^{-j\omega} = c\left[e^{j\omega} + e^{-j\omega}\right] + c^2 + 1$$

($e^{j\omega} + e^{-j\omega} = 2\cos\omega$)

$$= \boxed{2c\cdot\cos\omega + c^2 + 1}$$

2) Usando il teorema

$$y(t) = (1 + cz^{-1})\, e(t) = C(z)\, e(t)$$

- $C(z)$ AS. STAB (poli nell'origine)
- $e(t)$ pss $\Rightarrow$ $y(t)$ pss

$$\Gamma_y = \left|C(e^{j\omega})\right|^2 \cdot \Gamma_e(\omega) = \left|1 + c\,e^{-j\omega}\right|^2 \cdot 1 = \left(1 + ce^{-j\omega}\right)\left(1 + ce^{j\omega}\right)$$

$$= 1 + c^2\left(e^{j\omega}\cdot e^{-j\omega}\right) + c\left(e^{j\omega} + e^{-j\omega}\right) = \boxed{1 + c^2 + 2c\cdot\cos\omega}$$

Tracciamo lo spettro per punti

$$\Gamma_y(0) = 1 + c^2 + 2c\cos(0) = 1 + 2c + c^2 = (1+c)^2$$

$$\Gamma_y(\pi/2) = 1 + c^2 + 2c \cdot \cos\left(\frac{\pi}{2}\right) = 1 + c^2$$

$$\Gamma_y(\pi) = 1 + c^2 + 2c \cdot \cos(\pi) = (1-c)^2$$

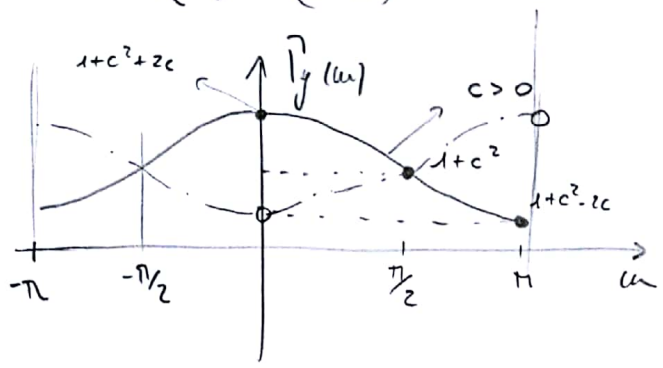

PREDIZIONE

Problema: data una sequenza di dati (ad esempio serie temporale)

$$\{y(1), y(2), \dots, y(N)\}$$

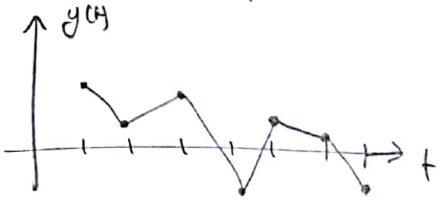

Vogliamo IDENTIFICARE un modello ARMA

$$y(t) = \frac{C(z)}{A(z)} e(t) \qquad e(t) \sim WN(0, \sigma^2)$$

Per stimare le incognite (coefficienti di $C(z)$ ed $A(z)$, eventualmente anche σ^2) seguiamo questo approccio:

- Calcoliamo il PREDITTORE DEL TEMPO DAI DATI $\hat{y}(t|t-1)$ → dipende dalle incognite θ
- Minimizziamo $J(\theta) = \sum_{i=1}^{N} \left(y(t) - \hat{y}(t|t-1,\theta)\right)^2$ VARIANZA CAMPIONARIA ERRORE DI PREDIZIONE

Approccio predittivo: un modello è buono se è capace di predirre un processo

FILTRO PASSA-TUTTO

È un filtro di ordine 1 con la seguente forma:

$$T(z) = \frac{1}{a} \cdot \frac{z+a}{z+\frac{1}{a}} \qquad a \neq 0,\ a \in \mathbb{R}$$

→ lo zero è opposto al polo

Ricordando il teorema della filtrazione spettrale, si ha che:

$$\Gamma_y(\omega) = |T(e^{j\omega})|^2 \cdot \Gamma_e(\omega)$$

$$|T(e^{j\omega})|^2 = \left(\frac{1}{a} \cdot \frac{e^{j\omega}+a}{e^{j\omega}+\frac{1}{a}}\right)\left(\frac{1}{a} \cdot \frac{e^{-j\omega}+a}{e^{-j\omega}+\frac{1}{a}}\right)$$

$$= \frac{1}{a^2} \frac{(e^{j\omega}+a)(e^{-j\omega}+a)}{\left(e^{j\omega}+\frac{1}{a}\right)\left(e^{-j\omega}+\frac{1}{a}\right)} = \frac{1}{a^2} \cdot \frac{1+a^2+a(e^{j\omega}+e^{-j\omega})}{1+\frac{1}{a^2}+\frac{1}{a}(e^{j\omega}+e^{-j\omega})}$$

$$= \frac{1}{a^2} \cdot \frac{1+a^2+2a\cos\omega}{\frac{a^2+1+2a\cos\omega}{a^2}} = 1$$

Quindi:

$$\Gamma_y(\omega) = |T(e^{j\omega})|^2 \cdot \Gamma_e(\omega) = \Gamma_e(\omega)$$

Il filtro passatutto non distorce lo spettro del segnale che lo elimenta

⇓

Il segnale in ingresso e quello in uscita al filtro passa-tutto sono EQUIVALENTI

Nota

Il filtro passatutto va modifica il modulo ma introduce una distorsione di fase, ritardando il segnale in ingresso. Ingresso e uscita NON SONO IDENTICI, ma sono SPETTRALMENTE EQUIVALENTI

Considerando un ARTAX:

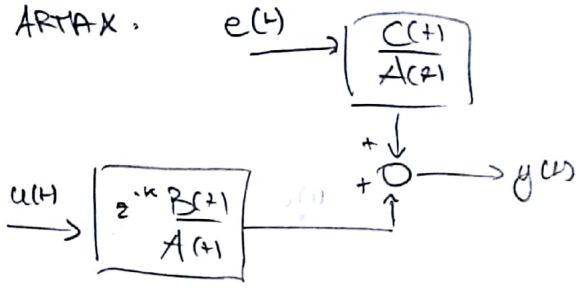

questo risulterà equivalente a:

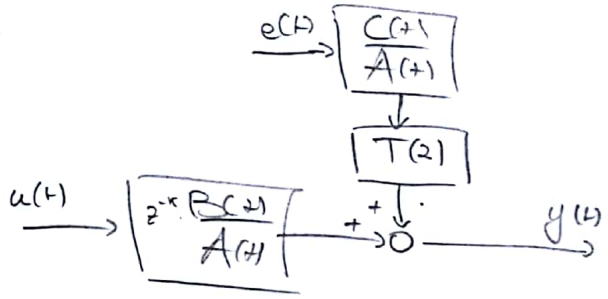

Osservazione

Il filtro passa-tutto è un "oggetto matematico". Non posso inserirlo tra u(t) e y(t), altrimenti cambierei la relazione ingresso/uscita, che è data da un "oggetto fisico", reale

FORMA CANONICA

Con l'introduzione del filtro passatutto $T(z)$, dobbiamo vista che il processo $y(t) = \frac{C(z)}{A(z)} e(t)$ ed il processo $y(t) = \frac{C(z)}{A(z)} T(z) e(t)$ sono EQUIVALENTI dal punto di vista spettrale

↓

esistono altre rappresentazioni equivalenti?

Consideriamo questi 5 processi ARMA:

1) $y_1(t) = \frac{z + \frac{1}{2}}{z - \frac{1}{3}} e(t)$ $\quad e(t) \sim WN(0,1)$

2) $y_2(t) = \frac{z + \frac{1}{2}}{z - \frac{1}{3}} e(t-2)$ $\quad e(t) \sim WN(0,1)$

3) $y_3(t) = \frac{z^2 - \frac{1}{4}}{z^2 + \frac{1}{6} - \frac{5}{6} z} e(t)$ $\quad e(t) \sim WN(0,1)$

4) $y_4(t) = \frac{2z + 1}{z - \frac{1}{3}} e(t)$ $\quad e(t) \sim WN(0, \frac{1}{4})$

5) $y_5(t) = \frac{z + 2}{z - \frac{1}{3}} e(t)$ $\quad e(t) \sim WN(0, \frac{1}{4})$

Si osserva che $m_{y_1} = m_{y_2} = \dots = m_{y_5} = 0$

Calcoliamo gli spettri dei processi:

1) $\Gamma_{y_1}(\omega) = \left| \frac{z+\frac{1}{2}}{z-\frac{1}{3}} \right|^2_{z=e^{j\omega}} \cdot \Gamma_e(\omega) = \left| \frac{e^{j\omega}+\frac{1}{2}}{e^{j\omega}-\frac{1}{3}} \right|^2 \cdot 1$

2) $\Gamma_{y_2}(\omega) = \left| \frac{z+\frac{1}{2}}{z-\frac{1}{3}} \cdot z^{-2} \right|^2_{z=e^{j\omega}} \cdot \Gamma_e(\omega) = \left| \frac{e^{j\omega}+\frac{1}{2}}{e^{j\omega}-\frac{1}{3}} \right|^2 \cdot \left| e^{-2j\omega} \right|^2 \cdot 1$

$= \Gamma_{y_1}(\omega) \cdot \left(e^{-2j\omega}\right) \cdot \left(e^{2j\omega}\right) = \Gamma_{y_1}(\omega)$

3) $\Gamma_{y_3}(\omega) = \left| \frac{z^2-\frac{1}{4}}{z^2+\frac{1}{6}-\frac{5}{6}z} \right|^2_{z=e^{j\omega}} \cdot \Gamma_e(\omega) = \left| \frac{\left(z-\frac{1}{2}\right)\left(z+\frac{1}{2}\right)}{\left(z-\frac{1}{2}\right)\left(z-\frac{1}{3}\right)} \right|_{z=e^{j\omega}} \cdot 1 = \Gamma_{y_1}(\omega)$

4) $\Gamma_{y_4}(\omega) = \left| \frac{2z+1}{z-\frac{1}{3}} \right|^2_{z=e^{j\omega}} \cdot \Gamma_e(\omega) = \left| 2 \cdot \frac{z+\frac{1}{2}}{z-\frac{1}{3}} \right|_{z=e^{j\omega}} \cdot \frac{1}{4} = 4 \cdot \left| \frac{e^{j\omega}+\frac{1}{2}}{e^{j\omega}-\frac{1}{3}} \right| \cdot \frac{1}{4}$

$= \Gamma_{y_1}(\omega)$

5) $\Gamma_{y_5}(\omega) = \left| \frac{z+2}{z-\frac{1}{3}} \right|^2_{z=e^{j\omega}} \cdot \Gamma_e(\omega) = \left| \frac{z+2}{z-\frac{1}{3}} \cdot 2\,\frac{z+\frac{1}{2}}{z+2} \right|^2_{z=e^{j\omega}} \cdot \frac{1}{4}$ → PASSA-TUTTO T(2)

$= \left| 2 \cdot \frac{z+\frac{1}{2}}{z-\frac{1}{3}} \right|^2_{z=e^{j\omega}} \cdot \frac{1}{4}$

$= 4 \cdot \frac{1}{4} \left| \frac{e^{j\omega}+\frac{1}{2}}{e^{j\omega}-\frac{1}{3}} \right|^2 = \Gamma_{y_1}(\omega)$

⇓

Tutti e 5 i processi sono gaussiani equivalenti. Un processo ARMA ammette infinite rappresentazioni equivalenti. Le cause di non unicità sono:

- ritardi puri (processo 2))
- fattori moltiplicativi che si cancellano (processo 3))
- coefficienti moltiplicativi su funzione di trasferimento e rumore si compensano (processo 4))
- poli/zeri "reciproci" (processo 5))

TEOREMA DELLA FATTORIZZAZIONE SPETTRALE

Dato un processo a spettro razionale, esiste una ed una sola rappresentazione del processo come uscita di un sistema dinamico alimentato da un rumore bianco tale che:

1) $C(z)$ ed $A(z)$ hanno stesso grado (grado relativo nullo)
2) $C(z)$ ed $A(z)$ sono coprimi (non hanno fattori in comune)
3) $C(z)$ ed $A(z)$ sono monici (il coefficiente del termine di grado max è 1)
4) $C(z)$ ed $A(z)$ hanno radici interne al cerchio unitario (poli e zeri $|z|<1$)

Es

$$y(t) = \frac{z+2}{z-\frac{1}{3}} e(t-2) \qquad e(t) \sim WN(0,1)$$

$$y(t) = \frac{z+2}{z-\frac{1}{3}} \cdot \underbrace{2 \cdot \frac{z+\frac{1}{2}}{z+2}}_{T(z)} e(t-2) = \frac{z+\frac{1}{2}}{z-\frac{1}{3}} \underbrace{2e(t-2)}_{\eta(t) \sim WN(0,4)}$$

$$\Rightarrow \boxed{y(t) = \frac{1+\frac{1}{2}z^{-1}}{1-\frac{1}{3}z^{-1}} \eta(t)} \qquad \eta(t) \sim WN(0,4)$$

IL PROBLEMA DELLA PREDIZIONE

Stimare il dato al tempo $t+k$ conoscendo i dati fino al tempo t. Indichiamo il predittore con la notazione $\hat{y}(t+k|t)$, oppure $\hat{y}(t|t-k)$

Informazioni disponibili

- Dati $y(1), y(2), \dots, y(N)$
- Vecchie predizioni $\hat{y}(t+k-1|t-1), \hat{y}(t+k-2|t-2), \dots$
- Modello $\frac{C(z)}{A(z)}$

Vogliamo trovare il predittore ottimo di dati. Esistono molti modi per calcolare il predittore di dati:

Es 1

$$\hat{y}(t+1|t) = \frac{y(t) + y(t-1) + y(t-2)}{3}$$ media valori passati

Es 2

$$\hat{y}(t+1|t) = \frac{2y(t) + \frac{1}{2}y(t-1) + \frac{1}{2}y(t-2)}{3}$$ diamo più peso a valori più recenti

Posso fare meglio? ⇓ Una prima proprietà che voglio è che il predittore sia corretto, ovvero $E[\varepsilon(t)] = E[y(t) - \hat{y}(t|t-1)] = 0$ (errore di predizione)

PREDITTORE OTTIMO

Un predittore è ottimo se:

1) $E[\hat{y}(t|t-k) \cdot \varepsilon(t)] = 0$, dove $\varepsilon(t) = y(t) - \hat{y}(t|t-k)$. Ovvero, predittore ed errore di predizione devono essere scorrelati

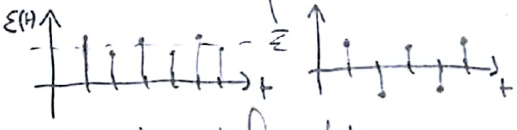

↓ tutta l'informazione è stata estratta dal predittore

2) $Var[\varepsilon(t)]$ MINIMA

Possiamo quindi scomporre $y(t)$ come: $y(t) = \hat{y}(t|t-k) + \varepsilon(t)$ con:

- $\varepsilon(t)$ parte imprevedibile al tempo $t-k$
- $\hat{y}(t|t-k)$ parte del processo che è predicibile al tempo $t-k$

PREDITTORE OTTIMO AD UN PASSO DI PROCESSI MA

Supponiamo un processo MA(m) in forma canonica:

$$y(t) = e(t) + c_1 e(t-1) + c_2 e(t-2) + \dots + c_m e(t-m) \qquad e(t) \sim WN(0, \lambda^2)$$

$$y(t) = \underbrace{e(t)}_{\text{parte imprevedibile}} + \underbrace{c_1 e(t-1) + \dots c_m e(t-m)}_{\text{parte predicibile al tempo } t-1}$$

Un possibile predittore potrebbe quindi essere:

$$\hat{y}(t|t-1) = c_1 e(t-1) + c_2 e(t-2) + __ + c_m e(t-m)$$

Osserviamo che:

- $\hat{y}(t|t-1)$ dipende dal WN fino al tempo $t-1$
- È corretto: $E[\varepsilon(t)] = 0$
- $E[\hat{y}(t|t-1)\,\varepsilon(t)] = 0$, infatti $\varepsilon(t) = y(t) - \hat{y}(t|t-1) = e(t)$

$$\Rightarrow E[\hat{y}(t|t-1)\,\varepsilon(t)] = E\left[\left(c_1 e(t-1) + c_2 e(t-2) + __ + c_m e(t-m)\right) \cdot e(t)\right] = 0$$

- Non è possibile trovare un predittore con $\mathrm{Var}[\varepsilon(t)]$ minore, infatti non posso avere un errore di predizione di $\mathrm{Var}[e(t)]$

$$\Downarrow$$

$$\hat{y}(t|t-1) = c_1 e(t-1) + __ + c_m e(t-m) \quad \text{è OTTIMO}$$

Questo, tuttavia, è un predittore ottimo "dal rumore". Vogliamo un predittore ottimo "dai dati"

$$y(t) = \left(1 + c_1 z^{-1} + c_2 z^{-2} + __ + c_m z^{-m}\right) e(t) \Rightarrow e(t) = \frac{1}{1 + c_1 z^{-1} + c_2 z^{-2} + __ + c_m z^{-m}}\, y(t)$$

$$\hat{y}(t|t-1) = \left(c_1 z^{-1} + c_2 z^{-2} + __ + c_m z^{-m}\right) e(t)$$

$$= \frac{c_1 z^{-1} + c_2 z^{-2} + __ + c_m z^{-m}}{1 + c_1 z^{-1} + c_2 z^{-2} + __ + c_m z^{-m}}\, y(t) \Rightarrow$$

si nota come $C(z)$ deve essere AS. STAB., quindi è necessaria la forma canonica

moltiplico per z^{-1}

$$\hat{y}(t|t-1)\left[1 + c_1 z^{-1} + __ + c_m z^{-m}\right] = \left(c_1 + c_2 z^{-1} + __ + c_m z^{-m-1}\right) y(t-1)$$

$$\Rightarrow \boxed{\begin{aligned} \hat{y}(t|t-1) = & -c_1 \hat{y}(t-1|t-2) - c_2 \hat{y}(t-2|t-3) - __ - c_m \hat{y}(t-m|t-m-1) + \\ & c_1 y(t-1) + c_2 y(t-2) + __ + c_m y(t-m) \end{aligned}}$$

VECCHIE PREDIZIONI

DATI FINO A $t-1$

Osservazione

Il predittore è ricorsivo, bisogna dire quanto vale $\hat{y}(1|0)$. Di solito si usa la media dei campioni

↓

Se il predittore è AS. STAB., l'effetto dell'inizializzazione svanisce dopo un certo periodo di tempo

Osservazione

La proprietà $E[\hat{y}(t|t-k)\,\varepsilon(t)] = 0$, dove $\varepsilon(t) = y(t) - \hat{y}(t|t-k)$ è l'errore di predizione, è una condizione <u>necessaria ma non sufficiente</u> per l'ottimalità del predittore

PREDITTORE K PASSI MA(m)

Generico processo MA(m) in forma canonica $e(t) \sim WN(0, \sigma^2)$

$$y(t) = \underbrace{e(t) + c_1 e(t-1) + \dots + c_{k-1} e(t-k+1)}_{\text{PARTE IMPREDICIBILE}} + \underbrace{c_k e(t-k) + \dots + c_m e(t-m)}_{\text{PARTE PREDICIBILE}}$$

$\Downarrow$ $\varepsilon(t)$ $\perp$ $\hat{y}(t|t-k)$ $\Downarrow$

Il predittore è <u>ottimo</u> in quanto la condizione necessaria è soddisfatta ed $\varepsilon(t)$ è a varianza minima

Osservazione

$\varepsilon_1(t) = y(t) - \hat{y}(t|t-1) \Rightarrow Var[\varepsilon_1(t)] = Var[e(t)] = \sigma^2$

$\varepsilon_2(t) = y(t) - \hat{y}(t|t-2) \Rightarrow Var[\varepsilon_2(t)] = Var[e(t) + c_1 e(t-1)] = (1 + c_1^2)\sigma^2$

$\vdots$

$\varepsilon_m(t) = y(t) - \hat{y}(t|t-m) \Rightarrow Var[\varepsilon_m(t)] = Var[e(t) + c_1 e(t-1) + \dots + c_m e(t-m)] = Var[y(t)]$

La varianza di $\varepsilon(t)$ aumenta con l'aumento di predizione, fino a diventare uguale alla varianza del processo. Il predittore $\hat{y}(t|t-m)$ sarà il predittore banale, ovvero la media del processo $\hat{y}(t|t-m) = E[y(t)] = 0 \Rightarrow$ un predittore non può mai avere varianza dell'errore di predizione maggiore della varianza del processo

PREDITTORE DI PROCESSI ARMA

Sia dato un processo ARMA(m, m) in forma canonica

$$y(t) = \frac{C(z)}{A(z)} e(t) \qquad e(t) \sim WN(0, \sigma^2)$$

$C(z) = 1 + c_1 z^{-1} + c_2 z^{-2} + \dots + c_m z^{-m}$

$A(z) = 1 - a_1 z^{-1} - a_2 z^{-2} - \dots - a_m z^{-m}$

Non è chiaro come scomporre parte nota e parte imprevedibile, perché $y(t), y(t-1), \dots$ dipendono dai passi precedenti di $e(t)$

Ci ricordiamo che possiamo esprimere ARMA(m,m) come MA(∞)

↓

Non è però fattibile, perché la parte predicibile conterrebbe ∞ elementi

Si esprime quindi $\frac{C(z)}{A(z)}$ come un quoziente $E(z)$ più un resto $R(z) = z^{-k}\tilde{R}(z)$ effettuando una <u>lunga divisione</u>. Otteniamo quindi:

$$C(z) = E(z)\cdot A(z) + R(z) \Rightarrow \quad \frac{C(z)}{A(z)} = E(z) + \frac{R(z)}{A(z)} = E(z) + \frac{z^{-k}\tilde{R}(z)}{A(z)}$$

Effettuando <u>k passi</u> di lunga divisione (possono essere ∞), otteniamo le informazioni per una previsione a k passi

<u>Es</u>

$$y(t) = \frac{1+\frac{1}{2}z^{-1}}{1+\frac{1}{3}z^{-1}}\,e(t) \qquad e(t) \sim WN(0,\sigma^2) \qquad k=2$$

($1+\frac{1}{2}z^{-1} \to C(t)$, $1+\frac{1}{3}z^{-1} \to A(t)$)

Lunga divisione di $k=2$ passi:

$$\begin{array}{l|l} 1+\frac{1}{2}z^{-1} & 1+\frac{1}{3}z^{-1} \to A(t) \\ -1-\frac{1}{3}z^{-1} & \\ \hline \frac{1}{6}z^{-1} & 1+\frac{1}{6}z^{-1} \to E(z) \\ \frac{1}{6}z^{-1}-\frac{1}{18}z^{-2} & \\ \hline \frac{1}{18}z^{-2} & \end{array} \qquad C(t) \leftarrow$$

$$R(z) = z^{-k}\tilde{R}(z) = z^{-2}\cdot\left(\frac{1}{18}\right)$$

Sostituendo in $y(t) = \frac{C(z)}{A(z)}e(t)$, otteniamo $\boxed{y(t) = E(z)\,e(t) + \frac{\tilde{R}(z)}{A(z)}\,e(t-k)}$

1) $E(z)\,e(t)$ è IMPREDICIBILE al tempo $t-k$, dipende solo da $e(t)$, $e(t-1)$, …, $e(t-k+1)$

2) $\frac{\tilde{R}(z)}{A(z)}\,e(t-k)$ è COMPLETAMENTE NOTO, dipende da $e(t-k)$, $e(t-k-1)$, $e(t-k-2)$, …

Quindi il <u>predittore del rumore</u> è: $\boxed{\hat{y}(t|t-k) = \frac{\tilde{R}(z)}{A(z)}\,e(t-k)}$

<u>L'errore di predizione</u> è: $\boxed{\varepsilon(t) = y(t) - \hat{y}(t|t-k) = E(z)\,e(t)}$

Osserviamo che:

- $\hat{y}(t|t-k)$ dipende dal rumore fino al tempo $t-k$
- $E[\hat{y}(t|t-k)\cdot\varepsilon(t)] = 0$, infatti $E\left[\hat{y}(t|t-k)\,\varepsilon(t)\right] = E\left[\left(\frac{\tilde{R}(z)}{A(z)}e(t-k)\right)\left(E(z)e(t)\right)\right] = 0$
- Non è possibile trovare un predittore con le due proprietà precedenti, con $\mathrm{Var}[\varepsilon(t)]$ inferiore

$$\Downarrow$$

$$\hat{y}(t|t-k) = \frac{\tilde{R}(z)}{A(z)}e(t-k) \quad \text{è ottimo}$$

Predittore dei dati

$$y(t) = \frac{C(z)}{A(z)}e(t) \Rightarrow e(t) = \frac{A(z)}{C(z)}y(t)$$

$$\hat{y}(t|t-k) = \frac{\tilde{R}(z)}{A(z)}e(t-k) = \frac{\tilde{R}(z)z^{-k}}{A(z)}e(t) = \frac{\tilde{R}(z)z^{-k}}{A(z)}\frac{A(z)}{C(z)}y(t) = \boxed{\frac{\tilde{R}(z)}{C(z)}y(t-k)}$$

Osservazione

$\varepsilon(t) = y(t) - \hat{y}(t|t-k) = E(z)e(t)$ l'errore di predizione è un processo MA $(k-1)$

CASO $k=1$

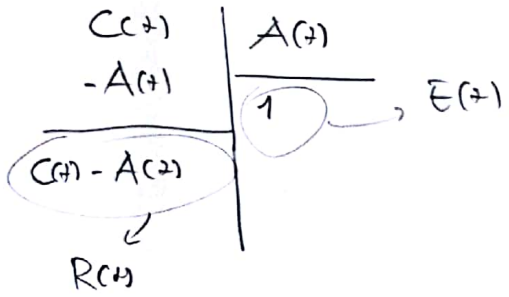

$E(z) = 1$

$R(z) = C(z) - A(z)$

$$\boxed{\hat{y}(t|t-1) = \frac{C(z)-A(z)}{C(z)}y(t)}$$ PREDITTORE DAI DATI

$$\boxed{\hat{y}(t|t-1) = \frac{C(z)-A(z)}{A(z)}e(t)}$$ PREDITTORE DAL RUMORE

$$\boxed{\varepsilon(t) = y(t) - \hat{y}(t|t-1) = e(t)}$$

Osservazione

Gli stimatori trovati sono corretti in quanto $E[\varepsilon(t)] = 0$

QUALITÀ DEL PREDITTORE

Possiamo valutare la qualità di un predittore mettendo a confronto la varianza dell'errore di predizione con la varianza della predizione banale

"Error to Signal Ratio" ← $ESR = \dfrac{Var\left[y(t) - \hat{y}(t|t-k)\right]}{Var\left[y(t)\right]} = \dfrac{Var\left[\varepsilon_k(t)\right]}{Var\left[y(t)\right]}$ vogliamo che sia più piccolo possibile

---

PREDITTORE OTTIMO DI UN PROCESSO ARMAX

Sia $y(t)$ un processo ARMAX(n, m, p), $\frac{C(z)}{A(z)}$ è in forma canonica

$$y(t) = \frac{B(z)}{A(z)} u(t-k) + \frac{C(z)}{A(z)} e(t) \qquad e(t) \sim WN(0, \lambda^2)$$

$\frac{B(z)}{A(z)}$ è il modello del sistema, non si può mettere in forma canonica

Si vuol fare una predizione a k passi, in modo da l'ingresso influenzi l'uscita

Utilizziamo la lunga divisione per scomporre $\frac{C(z)}{A(z)}$.

$$y(t) = \underbrace{\frac{B(z)}{A(z)} u(t-k) + \frac{\tilde{R}(z)}{A(z)} e(t-k)}_{\text{PARTE PREDICIBILE A } t-k} + \underbrace{E(z)\, e(t)}_{\text{PARTE IMPREDICIBILE}}$$

Predittore del rumore

$$\hat{y}(t|t-k) = \frac{B(z)}{A(z)} u(t-k) + \frac{\tilde{R}(z)}{A(z)} e(t-k) \qquad \varepsilon(t) = E(z)\, e(t)$$

Osserviamo che

- $\hat{y}(t|t-k)$ dipende dal WN e dall'ingresso fino al tempo $t-k$
- $E[\varepsilon(t)] = 0$ CORRETTO
- $E\left[\hat{y}(t|t-k) \cdot \varepsilon(t)\right] = 0$ (consideriamo $u(t) \perp e(t)$)
- Si dimostra che $\hat{y}(t|t-k)$ è OTTIMO
- $\varepsilon(t)$ è identico al caso ARMA: questo perché l'ingresso $u(t-k)$ è completamente NOTO e non introduce incertezze

Predittore dei dati

$$y(t) = \frac{B(z)}{A(z)} u(t-k) + \frac{C(z)}{A(z)} e(t) \quad \Rightarrow \quad e(t) = \frac{A(z)}{C(z)} y(t) - \frac{B(z)}{C(z)} u(t-k)$$

$$\hat{y}(t|t-k) = \frac{B(z)}{A(z)} u(t-k) + \frac{R(z)}{A(z)} e(t)$$

Facendo i passaggi si ottiene:

$$\hat{y}(t|t-k) = \frac{\tilde{R}(z)}{C(z)} y(t-k) + \frac{B(z)E(z)}{C(z)} u(t-k)$$

CASO $k=1$

$E(z) = 1$

$R(z) = C(z) - A(z)$

$$\Rightarrow \quad \hat{y}(t|t-1) = \frac{C(z) - A(z)}{C(z)} y(t) + \frac{B(z)}{C(z)} u(t-1)$$

$$\mathcal{E}(t) = E(z)\, e(t) = e(t)$$

Osservazione

Il predittore ARMAX ha varianza di $\mathcal{E}(t)$ data solo dalla parte ARMA. Si può calcolare la bontà della predizione come:

$$ESR = \frac{Var[\mathcal{E}(t)]}{Var\left[\frac{C(z)}{A(z)} e(t)\right]}$$

Es

Dato il processo $y(t) = (2 + 6z^{-1}) u(t-2) + \frac{2}{3 + \frac{3}{2} z^{-1}} \eta(t-1) \quad \eta(t) \sim WN(0, 1)$

Calcolare il predittore dei dati e la varianza dell'errore

Il ritardo puro è $k=2$, quindi la serie calcolare un predittore a 2 passi.

- Il processo è in forma canonica? $\Rightarrow$ Solo la parte stocastica può essere modificata!

$$y(t) = (2+6z^{-1})\cdot u(t-2) + \frac{z^{-1}}{1+\frac{1}{2}z^{-1}} \cdot \frac{2}{3}\eta(t)$$

$$= (2+6z^{-1})\,u(t-2) + \frac{1}{1+\frac{1}{2}z^{-1}} \underbrace{\frac{2}{3}\eta(t-1)}_{e(t)\sim WN\left(0,\frac{4}{9}\right)}$$

$$= (2+6z^{-1})\,u(t-2) + \underbrace{\frac{1}{1+\frac{1}{2}z^{-1}}}_{C(z)}\,e(t)$$

$\rightarrow A(z)$

Per il predittore, parte esogena e parte retroata devono avere lo stesso denominatore $A(z)$:

$$y(t) = \underbrace{\frac{(2+6z^{-1})\left(1+\frac{1}{2}z^{-1}\right)}{1+\frac{1}{2}z^{-1}}}_{B(z)}\,u(t-2) + \frac{1}{1+\frac{1}{2}z^{-1}}\,e(t) \qquad e(t)\sim WN\left(0,\frac{4}{9}\right)$$

$$A(z) = 1+\frac{1}{2}z^{-1} \qquad C(z) = 1$$

$$B(z) = 2\left(1+3z^{-1}\right)\left(1+\frac{1}{2}z^{-1}\right)$$

Il denominatore comune è stato fatto dopo la comparizione di $\frac{C(z)}{A(z)}$

- Predittore a $k=2$ passi $\Rightarrow$ 2 passi di lunga divisione tra $\frac{C(z)}{A(z)}$

$C(z)$

1	$1+\frac{1}{2}z^{-1}$ $\rightarrow A(z)$
$-1\ -\frac{1}{2}z^{-1}$	
$-\frac{1}{2}z^{-1}$	$1-\frac{1}{2}z^{-1}$ $\rightarrow E(z)$
$\frac{1}{2}z^{-1}+\frac{1}{4}z^{-2}$	
$\frac{1}{4}z^{-2}$ $\rightarrow R(z) = z^{-2}\tilde{R}(z)$	

$$\hat{y}(t+k|t-k) = \frac{\tilde{R}(z)}{C(z)}\,y(t-k) + \frac{B(z)E(z)}{C(z)}\cdot u(t-k)$$

$$\Downarrow$$

$$\hat{y}(t+k|t-2) = \frac{\frac{1}{4}}{1}\,y(t-2) + \frac{2\left(1+3z^{-1}\right)\left(1+\frac{1}{2}z^{-1}\right)\left(1-\frac{1}{2}z^{-1}\right)}{1}\,u(t-2)$$

$$\text{Var}[\varepsilon(t)] = E[\varepsilon(t)^2] = E\left[\left(E(z)e(t)\right)^2\right] = E\left[\left(\left(1-\frac{1}{2}z^{-1}\right)e(t)\right)^2\right] = E\left[\left(e(t)-\frac{1}{2}e(t-1)\right)^2\right]$$

$$= \left(1+\frac{1}{4}\right)\text{Var}[e(t)] = \frac{5}{4}\cdot\frac{4}{9} = \boxed{\frac{5}{9}}$$

Non ho senso per un ARIMA confrontare $\text{Var}[\varepsilon(t)]$ con $\text{Var}[y(t)]$, perché $y(t)$ potrebbe essere non stazionario

↓

si confronta con $\text{Var}\left[\frac{C(t)}{A(t)}e(t)\right]$, ovvero con la parte stocastica del processo

- $\text{Var}\left[\frac{1}{1+\frac{1}{2}z^{-1}}e(t)\right] = \text{Var}\left[-\frac{1}{2}v(t-1)+e(t)\right] = E\left[\left(-\frac{1}{2}v(t-1)+e(t)\right)^2\right] = +\frac{1}{4}\text{Var}[v(t)] + \text{Var}[e(t)$

$v(t)$ $\Rightarrow \text{Var}[v(t)] = \frac{1}{4}\text{Var}[v(t)] + \text{Var}[e(t)] \Rightarrow \frac{3}{4}\text{Var}[v(t)] = \frac{4}{9}$

$\Rightarrow \text{Var}[v(t)] = \frac{16}{27}$

$$ESR = \frac{\text{Var}[\varepsilon(t)]}{\text{Var}[v(t)]} = \frac{\frac{5}{9}}{\frac{16}{27}} = \frac{5\cdot 3}{16} = 0,9375$$

IDENTIFICAZIONE

Le analisi viste finora si basano sulla conoscenza dei parametri del modello dinamico.

↓

La disciplina dell'identificazione consiste nello stimare il sistema ignoto. Disponendo di un set di dati sperimentali ingresso-uscita $u(t)$ e $y(t)$, si vuole ricavare il sistema $G(z)$ tale che:

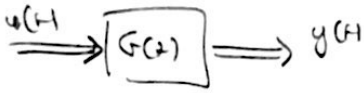

I passi di un problema di identificazione sono:

(1) RACCOLTA DATI SPERIMENTALI

- Scelta del tipo di ingresso $u(t)$, in modo da massimizzare l'informazione contenuta nei dati
- Numero di dati da acquisire

(2) SCELTA DELLA FAMIGLIA DI MODELLI

a) Scelta del tipo di modello $M(\theta)$ da usare, il quale dipende da dei parametri $\theta \in \mathbb{R}^{d_\theta}$, da stimare. Tipi di modelli:

- Tempo discreto / continuo
- Sistema lineare / non lineare
- Tempo invariante / variante
- Dinamico / statico

$\Rightarrow$ ARMAX sono la categoria di modelli più completa che vedremo

b) Scelta degli ordini del modello

(3) SCELTA DELLA CIFRA DI MERITO

È una funzione $J_N(\theta): \mathbb{R}^{d_\theta} \to \mathbb{R}^+$ che definisce la qualità della stima di $\theta \in \mathbb{R}^{d_\theta}$. L'approccio che useremo sarà l'approccio PEM (Prediction Error Minimization), minimizza la varianza dell'errore di predizione ad un passo:

$$J(\theta) = E\left[\left(y(t) - \hat{y}(t|t-1,\theta)\right)^2\right]$$

Dato che ho solo N dati, (e non conosco la pdf dei dati) si usa la varianza campionaria:

$$J_N(\theta) = \frac{1}{N}\sum_{t=1}^{N}\left(y(t) - \hat{y}(t|t-1,\theta)\right)^2$$

è uno stimatore CORRETTO!

(4) MINIMIZZAZIONE CIFRA DI MERITO

Vi sono diversi casi:

a) $J_N(\theta)$ è quadratica: è possibile trovare il minimo $\hat{\theta}_N$ in forma esplicita (minimi quadrati)

b) $J_N(\theta)$ non quadratica ma con più minimi locali: metodi iterativi
- gradiente
- Newton
- Quasi-Newton

=> convergenza verso l'unico minimo

c) $J_N(\theta)$ non quadratica e con minimi locali: metodi iterativi, tentando di evitare minimi locali

- AR / ARX → $J_N(\theta)$ quadratica
- ARMAX, ARMA, MA → $J_N(\theta)$ non quadratica + minimi locali

(5) VALIDAZIONE DEL MODELLO $M(\hat{\theta}_N)$

(QUESTO PEZZO PRIMA DI TUTTO)

STIMA CAMPIONARIA DI MEDIA E FUNZIONE COVARIANZA

Sia $y(t)$ un pss e supponiamo di aver misurato una realizzazione di $y(t)$: $\{y(1), y(2), \dots, y(N)\}$. Intendiamo $y(1) = y(1,\bar{s})$, $y(2) = y(2,\bar{s})$, ...

Problema: stimare dai dati le seguenti quantità teoriche

$$m = E[y(t)] \longrightarrow \hat{m}_N\left(y(1), y(2), \dots, y(N)\right)$$

$$\gamma(\tau) = E\left[(y(t)-m)(y(t+\tau)-m)\right] \longrightarrow \hat{\gamma}_N(\tau)\left(y(1), y(2), \dots, y(N)\right)$$

Lo stimatore ci serve perché non possiamo calcolare il valore atteso dato che non conosciamo la distribuzione dei dati

MEDIA CAMPIONARIA

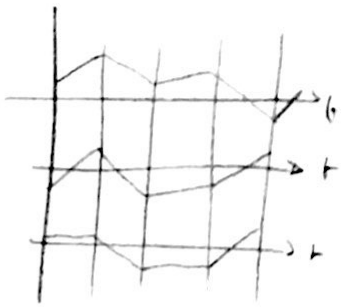

Un possibile stimatore è $\hat{m}_N = \frac{1}{N}\sum_{t=1}^{N} y(t)$

Verifica correttezza

$$\hat{m}_N = \frac{1}{N}\sum_{t=1}^{N} y(t,s) \Rightarrow E_s[\hat{m}_N] = \frac{1}{N} E_s\left[\sum_{t=1}^{N} y(t,s)\right] = \frac{1}{N}\sum_{t=1}^{N} E_s[y(t,s)]$$

$$= \frac{1}{N}\sum_{t=1}^{N} m(t) = \frac{1}{N}\cdot N \cdot m = \boxed{m} \quad \text{corretto}$$

Consistenza

Garantita dai teoremi:

Teorema

$\hat{m}_N$ è CONSISTENTE SSE $\gamma(\tau) \to 0$ per $|\tau| \to +\infty$

Teorema

Dato un processo ARMA, si ha che $\gamma(\tau) \to 0$ per $|\tau| \to +\infty$

INTRODUZIONE

Un primo modo per identificare un processo è stimarne le caratteristiche fondamentali

⇓

STIMA DI MEDIA, COVARIANZA, SPETTRO

FUNZIONE DI COVARIANZA CAMPIONARIA

Ottimizziamo un po' a media nulla. Ricordando che $\gamma(\tau) = E[y(t)\cdot y(t+\tau)]$, un possibile stimatore può essere:

$$\hat{\gamma}_N(\tau) = \frac{1}{N-|\tau|}\sum_{t=1}^{N-|\tau|} y(t)\cdot y(t+|\tau|) \qquad \boxed{|\tau| \le N-1}$$

Osservazioni

- Più τ è grande, meno campioni posso usare. Quindi $\hat{\gamma}_N(\tau)$ è accurato se $N \gg |\tau|$.

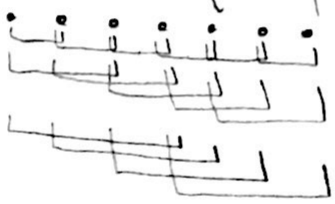

Correttezza

$$E_s[\hat{\gamma}_N(\tau)] = E_s\left[\frac{1}{N-|\tau|}\sum_{t=1}^{N-|\tau|} y(t)\cdot y(t+|\tau|)\right] = \frac{1}{N-|\tau|}\sum_{t=1}^{N-|\tau|} E_s[y(t)\,y(t+|\tau|)]$$

$$= \frac{1}{N-|\tau|}\cdot(N-|\tau|)\cdot\gamma(\tau) = \boxed{\gamma(\tau)} \quad \text{CORRETTO!}$$

REGOLARIZZAZIONE DELLA STIMA DELLO SPETTRO

Lo stimatore dello spettro ha gode di buone proprietà. La stima ha scarsa quindi buona.

↓

Un metodo per migliorare la stima è il seguente:

Ottimizzare di dividere gli N dati del processo misurato in M parti

- Calcolare $\hat{\Gamma}_{N/M}^{(i)}(\omega)$ per ciascuna parte i, $i = 1, \dots, M$
- Calcolare la stima finale $\hat{\bar{\Gamma}}_N(\omega) = \frac{1}{M} \cdot \sum_{i=1}^{M} \hat{\Gamma}_{N/M}^{(i)}(\omega)$

Si dimostra che:

$$E\left[\left(\hat{\bar{\Gamma}}_N(\omega) - \Gamma(\omega)\right)^2\right] = \frac{1}{M} E\left[\left(\hat{\Gamma}_N(\omega) - \Gamma(\omega)\right)^2\right]$$

ottengo cioè ridotta di $\frac{1}{M}$ la varianza dell'errore di stima

Osservazione

La scelta di M rappresenta un trade-off. Infatti se regolarizzo troppo (M grande), avrò uno stimatore ANCHE DISTORTO (perché uso meno dati per la stima, e lo stimatore è solo ASINTOTICAMENTE CORRETTO)

↓

Lo stesso trade-off esisteva quando abbiamo visto la regolarizzazione di funzioni di costo

$$J(\theta) = \frac{1}{N} \sum_{i=1}^{N} \left(y(i) - \varphi^T(i)\theta\right)^2 + \boxed{\lambda} \sum_{i=1}^{d} \theta_i^2$$

- λ GRANDE $\Rightarrow$ + BIAS − VARIANCE

⇓

RIPRESA IDENTIFICAZIONE

Consistenza

Teorema

$\hat{\gamma}_N(\tau)$ è consistente sse $\gamma(\tau) \to 0$ per $|\tau| \to +\infty$

VARIANTE NON CORRETTA

$\hat{\gamma}'_N(\tau) = \frac{1}{N} \cdot \sum_{t=1}^{N-|\tau|} y(t) \cdot y(t+|\tau|)$ non è corretto, ma è asintoticamente corretto $N \to +\infty$

Questa stima è comunque utilizzabile perché anche nella variante corretta si suppone che $N \gg |M|$

DENSITÀ SPETTRALE CAMPIONARIA

Ipotesi: un pss a media nulla. Sappiamo che $\Gamma(\omega) = \sum_{\tau=-\infty}^{+\infty} \gamma(\tau) e^{-j\omega\tau}$ (è DTFT - Discrete Time Fourier Transform della $\gamma(\tau)$). $\Gamma(\omega)$ è una funzione continua di ω.

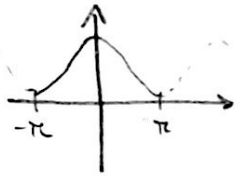

Osservazione

La pulsazione $\omega = \pi$ corrisponde alla frequenza di Nyquist del sistema $\Rightarrow$ Es se $f_s = 100$ Hz, $\pi = \frac{f_s}{2} = 50$ Hz

Una possibile stima potrebbe essere $\hat{\Gamma}_N(\omega) = \sum_{\tau=-\infty}^{+\infty} \hat{\gamma}_N(\tau) e^{-j\omega\tau}$. Ricordando però che:

$$\hat{\gamma}_N(\tau) = \frac{1}{N-|\tau|} \cdot \sum_{t=1}^{N-|\tau|} y(t)\, y(t+|\tau|) \qquad |\tau| \leq N-1$$

notiamo che non possiamo avere valori di $\hat{\gamma}_N(\tau)$ per $|\tau| \geq N$. Quindi approssimiamo.

$$\hat{\Gamma}'_N(\omega) = \sum_{\tau=-(N-1)}^{N-1} \hat{\gamma}_N(\tau) \cdot e^{-j\omega\tau}$$

Osservazione

$\hat{\Gamma}(\omega)$ contiene due approssimazioni:

1) Usiamo $\hat{\gamma}_N(\tau)$ al posto di $\gamma(\tau)$
2) Abbiamo troncato la sommatoria a $\pm(N-1)$

Osservazione

$\hat{\Gamma}(\omega)$ è continua. Nella pratica, dobbiamo discretizzare l'intervallo $[0, \pi]$

Correttezza

$$E_s\left[\hat{\Gamma}_N(\omega)\right] = E_s\left[\sum_{\tau=-(N-1)}^{N-1} \hat{\gamma}_N(\tau)\, e^{-j\omega\tau}\right] = \sum_{\tau=-(N-1)}^{N-1} \underbrace{E_s\left[\hat{\gamma}_N(\tau)\right]}_{\gamma(\tau)} e^{-j\omega\tau}$$

$$= \sum_{\tau=-(N-1)}^{N-1} \gamma(\tau)\, e^{-j\omega\tau} \neq \Gamma(\omega)$$ perché gli indici delle sommatorie sono diversi! NON CORRETTO

Se però $N \to \infty$, abbiamo che:

$$E_s\left[\hat{\Gamma}_N(\omega)\right] \xrightarrow[N\to\infty]{} \Gamma(\omega) \Rightarrow \hat{\Gamma}_N \text{ è ASINTOTICAMENTE CORRETTO}$$

Consistenza

Si dimostra che: $\lim_{N\to+\infty} E_s\left[\left(\hat{\Gamma}_N(\omega) - \Gamma(\omega)\right)^2\right] = \Gamma(\omega)^2 \neq 0$

$\Downarrow$

$\hat{\Gamma}_N(\omega)$ NON È CONSISTENTE

Inoltre abbiamo che:

$$\lim_{N\to+\infty} E_s\left[\left(\hat{\Gamma}_N(\omega_1) - \Gamma(\omega_1)\right)\cdot\left(\hat{\Gamma}_N(\omega_2) - \Gamma(\omega_2)\right)\right] = 0 \quad \forall \omega_1, \omega_2, \omega_1 \neq \omega_2$$

Ovvero l'errore di stima ad una frequenza ω_1 è incorrelato con l'errore di stima ad una frequenza ω_2

$\Downarrow$

difficile valutare la varianza della stima

STIMATORE ALTERNATIVO

Usiamo la versione NON CORRETTA $\hat{\gamma}'_N(\tau)$ invece di $\hat{\gamma}_N(\tau)$. Abbiamo che:

$$\hat{\Gamma}'_N(\omega) = \sum_{\tau=-(N-1)}^{N-1} \hat{\gamma}'_N(\tau)\, e^{-j\omega\tau} = \sum_{\tau=-N+1}^{N-1} \left[\frac{1}{N}\sum_{s=1}^{N-\tau} y(s)\, y(s+\tau)\right] \cdot e^{-j\omega\tau}$$

$\Rightarrow \boxed{r = s+\tau} \Rightarrow \boxed{\tau = r-s}$

- $\tau = -N+1 \Rightarrow r=1, s=N$
- $\tau = N-1 \Rightarrow r=N, s=1$

$$= \frac{1}{N}\cdot\sum_{r=1}^{N}\sum_{s=1}^{N} y(r)\, y(s)\, e^{-j\omega(r-s)} = \frac{1}{N}\sum_{r=1}^{N} y(r)\, e^{-j\omega r}\cdot\sum_{s=1}^{N} y(s)\, e^{j\omega s}$$

$$= \boxed{\left|\frac{1}{N}\cdot\left|\sum_{t=1}^{N} y(t)\, e^{-j\omega t}\right|^2\right|}$$

È il modulo al quadrato del valore ritornato dalla DFT (Discrete Fourier Transform), che valuta lo spettro in un range discreto di frequenze ω

Questo stimatore è uguale al precedente ma si calcola velocemente (FFT) senza passare per $\hat{\gamma}_N(\tau)$

IDENTIFICAZIONE (PEM) DI MODELLI ARX

Dati disponibili: $\{y(1), y(2), \dots, y(N)\}$ e $\{u(1), u(2), \dots, u(N)\}$

Consideriamo un generico modello ARX$(m, p+1)$:

$$y(t) = \frac{B(z)}{A(z)} u(t-1) + \frac{1}{A(z)} e(t) \qquad e(t) \sim WN(0, \lambda^2)$$

$B(z) = b_0 + b_1 z^{-1} + \dots + b_p z^{-p}$ $\qquad C(z) = 1$

$A(z) = 1 + a_1 z^{-1} + a_2 z^{-2} + \dots + a_m z^{-m}$

Osservazione

$C(z) = 1$ poiché non esiste la parte MA. Fissando il ritardo puro $k = 1$ lediamo di generalità? No, perché, ad esempio, se k fosse $= 2$, identificheremmo $b_0 = 0$

Cifra di merito

È la varianza campionaria dell'errore di predizione

$$J_N(\theta) = \frac{1}{N} \sum_{t=1}^{N} \left(y(t) - \hat{y}(t|t-1, \theta) \right)^2$$

Predittore:

$$\hat{y}(t|t-1) = \underbrace{\frac{B(z)}{1}}_{C(z)} u(t-1) + \underbrace{\frac{1 - A(z)}{1}}_{C(z)} y(t)$$

$$= \left(b_0 + b_1 z^{-1} + \dots + b_p z^{-p}\right) u(t-1) + \left(-a_1 z^{-1} - a_2 z^{-2} - \dots - a_m z^{-m}\right) y(t)$$

$$= b_0 u(t-1) + b_1 u(t-2) + \dots + b_p u(t-p-1) - a_1 y(t-1) - a_2 y(t-2) - \dots - a_m y(t-m)$$

VETTORE DEI PARAMETRI

$$\theta = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \\ b_0 \\ b_1 \\ \vdots \\ b_p \end{bmatrix} \in \mathbb{R}^{m+p+1 \times 1}, \quad d = m + p + 1$$

VETTORE DELLE OSSERVAZIONI (dei dati)

$$\varphi(t) = \begin{bmatrix} -y(t-1) \\ -y(t-2) \\ \vdots \\ -y(t-m) \\ u(t-1) \\ u(t-2) \\ \vdots \\ u(t-p-1) \end{bmatrix} \in \mathbb{R}^{m+p+1 \times 1}$$

$$\Downarrow$$

$$\hat{y}(t|t-1) = \underset{1 \times d}{\varphi(t)^T} \cdot \underset{d \times 1}{\theta}$$

$$\Downarrow$$

$$J_N(\theta) = \frac{1}{N} \sum_{t=1}^{N} \left(y(t) - \varphi(t)^T \cdot \theta \right)^2 \Rightarrow$$

STIMA A MINIMI QUADRATI

$$\hat{\theta}_N = \left[\sum_{t=1}^{N} \underset{d\times 1}{\varphi(t)} \underset{1\times d}{\varphi(t)^T} \right]^{-1} \cdot \left[\sum_{t=1}^{N} \underset{d\times 1}{\varphi(i)} \underset{1\times 1}{y(t)} \right]$$

Osservazione

In generale per un ARX $(m, p+1)$ è più corretto scrivere

$$J_N(\theta) = \frac{1}{N-h} \sum_{t=h+1}^{N} \left(y(t) - \varphi(t)^T\theta \right)^2 \quad \text{con } h = \max(m, p+1)$$

Es

Supponiamo di avere $N=10$ dati I/O $\{y(1), y(2), \dots, y(10)\}$

$\{u(1), u(2), \dots, u(10)\}$

Stimare un modello ARX del tipo:

$$y(t) = \frac{b}{1+az^{-1}} u(t-1) + \frac{1}{1+az^{-1}} e(t) \qquad e(t) \sim WN(0, \sigma^2)$$

È un ARX$(1,1)$. Il predittore è: $\hat{y}(t|t-1) = \frac{B(z)}{C(z)} u(t-1) + \frac{C(z) - A(z)}{C(z)} y(t)$

$= b\,u(t-1) - a\,y(t-1) \qquad \theta = \begin{bmatrix} a \\ b \end{bmatrix} \in \mathbb{R}^{2\times 1}$

Cifra di merito, ottenuta $h = \max(m, \hat{p}^0+1) = 1$ (dove potrei partire da $t=2$ se mi va a calcolare $u(t-1), y(t-1)$)

$$J_{10}(\theta) = \frac{1}{10-1} \sum_{t=1+1}^{10} \left(y(t) - \hat{y}(t|t-1) \right)^2 = \frac{1}{9} \sum_{t=2}^{10} \left(y(t) - bu(t-1) + ay(t-1) \right)^2$$

regressori $x_1(t)$ e $x_2(t)$

OTTIMIZZO

$$\begin{cases} \dfrac{dJ_{10}(\theta)}{da} = \dfrac{2}{9} \displaystyle\sum_{t=2}^{10} \left(y(t) - bu(t-1) + ay(t-1) \right) y(t-1) = 0 \\ \dfrac{dJ_{10}(\theta)}{db} = \dfrac{2}{9} \displaystyle\sum_{t=2}^{10} \left(y(t) - bu(t-1) + ay(t-1) \right) \left(-u(t-1) \right) = 0 \end{cases}$$

$$\Rightarrow \begin{bmatrix} \displaystyle\sum_{t=2}^{10} y(t-1)^2 & -\displaystyle\sum_{t=2}^{10} u(t-1)y(t-1) \\ -\displaystyle\sum_{t=2}^{10} u(t-1)y(t-1) & +\displaystyle\sum_{t=2}^{10} u(t-1)^2 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} -\displaystyle\sum_{t=2}^{10} y(t)y(t-1) \\ \displaystyle\sum_{t=2}^{10} y(t)u(t-1) \end{bmatrix}$$

$$\begin{bmatrix} \hat{a}_{10} \\ \hat{b}_{10} \end{bmatrix} = \begin{bmatrix} \displaystyle\sum_{t=2}^{10} y(t-1)^2 & -\displaystyle\sum_{t=2}^{10} u(t-1)y(t-1) \\ -\displaystyle\sum_{t=2}^{10} u(t-1)y(t-1) & \displaystyle\sum_{2}^{10} u(t-1)^2 \end{bmatrix}^{-1} \cdot \begin{bmatrix} -\displaystyle\sum_{2}^{10} y(t)y(t-1) \\ \displaystyle\sum_{2}^{10} y(t)u(t-1) \end{bmatrix}$$

La soluzione del problema PEM per modelli ARX può essere formulata dal punto di vista matriciale.

MATRICE DEI REGRESSORI

$$\underset{(N-n)\times d}{\Phi} = \underset{(N-1)\times 2}{\Phi} = \underset{8\times 2}{\begin{bmatrix} -y(1) & u(1) \\ -y(2) & u(2) \\ | & | \\ -y(8) & u(8) \end{bmatrix}} \quad \begin{matrix} y(t-1) & u(t-1) \end{matrix}$$

VETTORE OUTPUT

$$\underset{8\times 1}{Y} = \begin{bmatrix} y(2) \\ y(3) \\ | \\ y(10) \end{bmatrix} \Rightarrow \underset{8\times 1}{Y} = \underset{8\times 2}{\Phi}\ \underset{2\times 1}{\theta} \qquad \hat{y}(t|t-1) = -a\,y(t-1) + b\,u(t-1)$$

$$\downarrow$$

$$y(2) = -a\,y(1) + b\,u(1)$$
$$y(3) = -a\,y(2) + b\,u(2)$$
$$\vdots$$
$$y(10) = -a\,y(8) + b\,u(8)$$

$$\boxed{\underset{2\times 1}{\hat{\theta}_N} = \left(\underset{2\times 8}{\Phi^T}\underset{8\times 2}{\Phi}\right)^{-1}\cdot \underset{2\times 8}{\Phi^T}\cdot \underset{8\times 1}{Y}}$$

Es

Si supponga di aver 5 dati da una serie temporale $y(t)$ a media nulla:

$$y(1) = \frac{1}{2} \quad y(2) = 0 \quad y(3) = -1 \quad y(4) = -\frac{1}{2} \quad y(5) = +\frac{1}{4}$$

Si identifichi un modello AR(1): $y(t) = a\,y(t-1) + e(t)$ $\quad e(t) \sim WN(0, \lambda^2)$

Usando il modello identificato, si calcoli $\hat{y}(6|5)$ e λ^2

Nota

La media campionaria $\hat{m}_5 = \frac{1}{5}\sum_{t=1}^{5} y(t) = -0{,}15$ non è nulla. L'esercizio però ci dice di considerare medie nulle, altrimenti avremmo bisogno dell'osservazione del time di aver un predittore corretto, $E[E(t)] = 0$

Calcolare il predittore

$$y(t) = \frac{1}{1 - a z^{-1}}\, e(t) \quad \left(\text{Supponiamo } |a|<1 \text{ FORMA CANONICA}\right) \Rightarrow \boxed{\hat{y}(t|t-1) = \frac{C(z) - A(z)}{C(z)}\, y(t)}$$

$$= \frac{1 + a z^{-1}}{1}\, y(t) = \boxed{a\,y(t-1)}$$

$$J_N(\theta) = \frac{1}{N-1}\sum_{t=2}^{N}\left(y(t) - a\,y(t-1)\right)^2$$

$$= \frac{1}{4}\left[\left(y(2) - a\,y(1)\right)^2 + \left(y(3) - a\,y(2)\right)^2 + \left(y(4) - a\,y(3)\right)^2 + \left(y(5) - a\,y(4)\right)^2\right]$$

$$= \frac{1}{4}\left[\left(0 - a\frac{1}{2}\right)^2 + \left(-1 - a\cdot 0\right)^2 + \left(-\frac{1}{2} + a\cdot 1\right)^2 + \left(\frac{1}{4} + a\frac{1}{2}\right)^2\right]$$

$$= \frac{1}{4}\left[\frac{1}{4}a^2 + 1 + \frac{1}{4} + a^2 - a + \frac{1}{16} + \frac{1}{4}a^2 + \frac{1}{4}a\right]$$

$$= \frac{1}{4}\left[\frac{16+4+1}{16} + \frac{-4a+a}{4} + \frac{a^2+a^2+4a^2}{4}\right] = \frac{1}{4}\cdot\left[\frac{21}{16} - \frac{3}{4}a + \frac{36}{24}a^2\right]$$

Minimizzo

$$\frac{dJ_S(\theta)}{da} = 3a - \frac{3}{4} = 0 \Rightarrow \boxed{\hat{a}_S = \frac{1}{4}}$$

Modello identificato

$$\boxed{y(t) = \frac{1}{1 - \frac{1}{4}z^{-1}}\, e(t)} \qquad e(t) \sim WN(0, \lambda^2)$$

Osservazione

Se avessimo ottenuto $|\hat{a}_S| > 1$, avremmo potuto usare un filtro passatutto (a, a^2)

$$\lambda^2 = Var[e(t)] = Var[\varepsilon(t)] \approx J_S(\hat{a}_S) = \frac{1}{4}\left[\frac{21}{16} - \frac{3}{4}\cdot\frac{1}{4} + \frac{3}{2}\cdot\left(\frac{1}{4}\right)^2\right]$$

Calcolare $\hat{y}(6|5)$

$$\hat{y}(t+1|t-1) = \frac{1}{4}y(t-1) \Rightarrow \hat{y}(6|5) = \frac{1}{4}y(5) = \frac{1}{4}\cdot\frac{1}{4} = \boxed{\frac{1}{16}}$$

IDENTIFICAZIONE PEM DI MODELLI ARMAX

(Metodo della massima verosimiglianza anche)

Questo metodo si chiama così perché si dimostra che, nel caso in cui $e(t)$ sia un WN Gaussiano, l'approccio PEM equivale al metodo ML

Dati disponibili

$\{u(1), u(2), \dots, u(N)\}$

$\{y(1), y(2), \dots, y(N)\}$

Generico modello ARMAX $(m, n, p+1)$

$$y(t) = \frac{B(z)}{A(z)}u(t-1) + \frac{C(z)}{A(z)}e(t) \qquad e(t) \sim WN(0, \lambda^2)$$

$$A(z) = 1 + a_1 z^{-1} + a_2 z^{-2} + \dots + a_m z^{-m}$$

$$B(z) = b_0 + b_1 z^{-1} + b_2 z^{-2} + \dots + b_p z^{-p}$$

$$C(z) = 1 + c_1 z^{-1} + c_2 z^{-2} + \dots + c_m z^{-m}$$

Vettore dei parametri

$$\theta = \begin{bmatrix} a_1 \\ | \\ a_m \\ b_0 \\ | \\ b_p \\ c_1 \\ | \\ c_m \end{bmatrix} \in \mathbb{R}^{(m+n+p+1)\times 1}$$

Approccio predittivo

$$\hat{\theta}_N = \arg\min_{\theta} J_N(\theta)$$

$$J_N(\theta) = \frac{1}{N}\sum_{t=1}^{N} \varepsilon(t,\theta)^2$$

Errore di predizione ad un passo

Se $k=1 \Rightarrow E(z)=1 \Rightarrow \varepsilon(t) = e(t)$

$$e(t) = \varepsilon(t,\theta) = \frac{A(z)}{C(z)} y(t) - \frac{B(z)}{C(z)} u(t-1)$$

$$\Downarrow$$

$$\boxed{J_N(\theta) = \frac{1}{N}\sum_{t=1}^{N} \left(\frac{A(z)}{C(z)} y(t) - \frac{B(z)}{C(z)} u(t-1) \right)^2}$$

PROBLEMA

A causa di $C(z)$ al denominatore, la cifra di merito non è quadratica in θ (e lo, in generale, più minimi locali)

Si usano quindi **metodi iterativi** per la minimizzazione

↓

GIÀ VISTO con Logistic Regression!

PROBLEMA MINIMI LOCALI

Si gestisce così:
- Scegliamo M inizializzazioni diverse, otteng M soluzioni
- Se le M soluzioni sono uguali, posso pensare (non sono certo) di aver raggiunto il minimo globale di $J_N(\theta)$
- Se sono diverse, considero quella che mi fa stare $J_N(\theta)$ MINORE

METODO DI NEWTON

Idea: sviluppo in serie di Taylor troncato al secondo ordine di $J_N(\theta)$ nell'intorno di θ^i (NOTO)

$$J_N(\theta) \approx V(\theta) = J_N(\theta^i) + \underbrace{\left.\frac{dJ(\theta)}{d\theta}\right|_{\theta=\theta^i}}_{\text{GRADIENTE}} \cdot (\theta - \theta^i) + \frac{1}{2}(\theta-\theta^i)^T \underbrace{\left.\frac{d^2 J(\theta)}{d\theta^2}\right|_{\theta=\theta^i}}_{\text{HESSIANA}} (\theta - \theta^i)$$

Assegno a θ^{i+1} il MINIMO di $V(\theta)$ attorno a θ^i => trovo il minimo della parabola

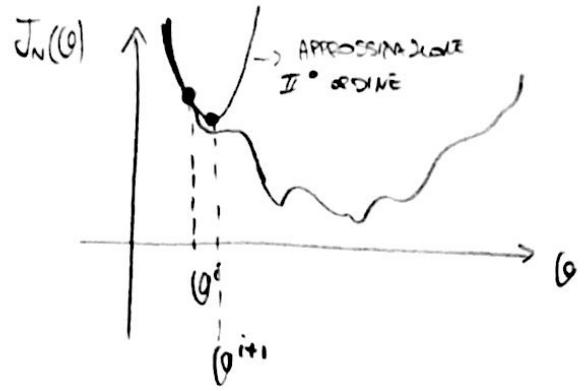

Minimo di $V(\theta)$

$$\frac{dV(\theta)}{d\theta} = 0 \Rightarrow \left.\frac{dJ(\theta)}{d\theta}\right|_{\theta=\theta^i} + \frac{1}{2} \cdot 2 \cdot \left.\frac{d^2J(\theta)}{d\theta^2}\right|_{\theta=\theta^i} \cdot (\theta - \theta^i) = 0$$

$$\Rightarrow \boxed{\theta^{i+1} = \theta^i - \left[\left.\frac{d^2J_N(\theta)}{d\theta^2}\right|_{\theta=\theta^i}\right]^{-1} \cdot \left[\left.\frac{dJ_N(\theta)}{d\theta}\right|_{\theta=\theta^i}\right]}$$

È simile al gradient descent se si mantiene costante $\left[\left.\frac{d^2J_N(\theta)}{d\theta^2}\right|_{\theta=\theta^i}\right] = \alpha > 0$

↓

Il metodo funziona se l'Hessiana è DEFINITA POSITIVA, altrimenti vado nella direzione sbagliata.

Calcoliamo in dettaglio due quantità:

- $\left.\frac{d^2J_N(\theta)}{d\theta^2}\right|_{\theta=\theta^i}$ HESSIANO
- $\left.\frac{dJ_N(\theta)}{d\theta}\right|_{\theta=\theta^i}$ GRADIENTE

Calcolo di $\frac{dJ_N(\theta)}{d\theta}$

Ricordiamo che: $J_N(\theta) = \frac{1}{N}\sum_{t=1}^{N} \varepsilon(t)^2 \Rightarrow \boxed{\frac{dJ_N(\theta)}{d\theta} = \frac{2}{N}\sum_{t=1}^{N} \varepsilon(t) \cdot \frac{d\varepsilon(t)}{d\theta}}$

- **Calcolo di $\frac{d^2 J_N(\theta)}{d\theta^2}$** ⇒ deriv la derivata I°, regola della derivazione del prodotto

$$\frac{d^2 J_N(\theta)}{d\theta^2} = \frac{2}{N}\sum_{t=1}^{N} \frac{d\varepsilon(t)}{d\theta}\cdot\frac{d\varepsilon(t)^T}{d\theta} + \frac{2}{N}\sum_{t=1}^{N} \varepsilon(t)\frac{d^2\varepsilon(t)}{d\theta^2}$$

Si ignora questo termine, approssimando così l'Hessiano (metodi Quasi-Newton)
Le motivazioni sono:

1) Se siamo vicini all'ottimo, $\varepsilon(t)$ è piccolo e il termine conta poco
2) Possiamo evitare di calcolare $\frac{d^2\varepsilon(t)}{d\theta^2}$
3) Ci assicuriamo un Hessiano DEFINITO POSITIVO → la procedura è sicuramente di MINIMIZZAZIONE

Otteniamo quindi

$$\theta^{i+1} = \theta^i - \left[\frac{2}{N}\sum_{t=1}^{N} \frac{d\varepsilon(t)^{(i)}}{d\theta}\cdot\left(\frac{d\varepsilon(t)^{(i)}}{d\theta}\right)^T\right]^{-1}\cdot\left[\frac{2}{N}\sum_{t=1}^{N}\varepsilon(t)^{(i)}\cdot\frac{d\varepsilon(t)^{(i)}}{d\theta}\right]$$

per garantire l'invertibilità si applica un termine $+\delta I$ piccolo, matrice identità

Nota

La notazione "apice (i)" indica la stima valutata θ in θ^i (NOTO)

- **Calcolo di $\frac{d\varepsilon(t)}{d\theta}$**

$$\varepsilon(t) = e(t) = \frac{A(z)}{C(t)}y(t) - \frac{B(z)}{A(z)}u(t-1)$$

$$\varepsilon(t) = \frac{1+a_1 z^{-1}+\dots+a_m z^{-m}}{1+c_1 z^{-1}+\dots+c_m z^{-m}}y(t) - \frac{b_0+b_1 z^{-1}+\dots+b_p z^{-p}}{1+c_1 z^{-1}+\dots+c_m z^{-m}}u(t-1)$$

$$\theta = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \\ b_0 \\ \vdots \\ b_p \\ c_1 \\ \vdots \\ c_m \end{bmatrix} \in \mathbb{R}^{(m+p+m+1)\times 1}$$

Derivata di $\varepsilon(t)$ rispetto a $a_1, a_2, \dots, a_m$:

- $\frac{d\varepsilon(t)}{da_1} = \frac{z^{-1}}{C(z)} y(t) = \frac{1}{C(z)} y(t-1) = \alpha(t-1)$

$$\alpha(t) = \frac{1}{C(z)} y(t)$$

- $\frac{d\varepsilon(t)}{da_2} = \frac{z^{-2}}{C(z)} y(t) = \frac{1}{C(z)} y(t-2) = \alpha(t-2)$

- $\frac{d\varepsilon(t)}{da_m} = \frac{z^{-m}}{C(z)} y(t) = \frac{1}{C(z)} y(t-m) = \alpha(t-m)$

Derivata di $\varepsilon(t)$ rispetto a $b_0, b_1, \dots, b_p$

- $\frac{d\varepsilon(t)}{db_0} = -\frac{1}{C(z)} u(t-1) = \beta(t-1)$

$$\beta(t) = -\frac{1}{C(z)} u(t)$$

- $\frac{d\varepsilon(t)}{db_1} = -\frac{z^{-1}}{C(z)} u(t-1) = \beta(t-2)$

- $\frac{d\varepsilon(t)}{db_p} = \frac{-z^{-p}}{C(z)} u(t-1) = \beta(t-p-1)$

Derivata di $\varepsilon(t)$ rispetto a $c_1, c_2, \dots, c_m$

$$\varepsilon(t) = \frac{A(z)}{C(z)} y(t) - \frac{B(z)}{C(z)} u(t-1) \Rightarrow \left(1 + c_1 z^{-1} + \dots + c_m z^{-m}\right)\varepsilon(t) = A(z) y(t) - B(z) u(t-1)$$

$$\Rightarrow \frac{d\left[\left(1 + c_1 z^{-1} + \dots + c_m z^{-m}\right)\cdot \varepsilon(t)\right]}{dc_1} = \frac{d\left[A(z) y(t) - B(z) u(t-1)\right]}{dc_1}$$

derivando

$$\Rightarrow z^{-1}\varepsilon(t) + C(z)\frac{d\varepsilon(t)}{dc_1} = 0 \Rightarrow \bullet\ \frac{d\varepsilon(t)}{dc_1} = -\frac{1}{C(z)} \varepsilon(t-1) = \gamma(t-1)$$

$$\gamma(t) = -\frac{1}{C(z)} \varepsilon(t)$$

- $\frac{d\varepsilon(t)}{dc_m} = -\frac{1}{C(z)} \varepsilon(t-m) = \gamma(t-m)$

Riassumendo, abbiamo che il vettore delle derivate è:

$$\frac{d\varepsilon(t)}{d\vartheta} = \begin{bmatrix} -\alpha(t-1) \\ \vdots \\ -\alpha(t-m) \\ -\beta(t-1) \\ \vdots \\ -\beta(t-1-p) \\ \gamma(t-1) \\ \\ \\ \gamma(t-m) \end{bmatrix} \in \mathbb{R}^{(m+m+p+1)\times 1} \qquad t = 1, \dots, N$$

Abbiamo quindi creato un FILTRO che, dati $u(t)$, $y(t)$ e θ^i, permette di calcolare il necessario per avere θ^{i+1}:

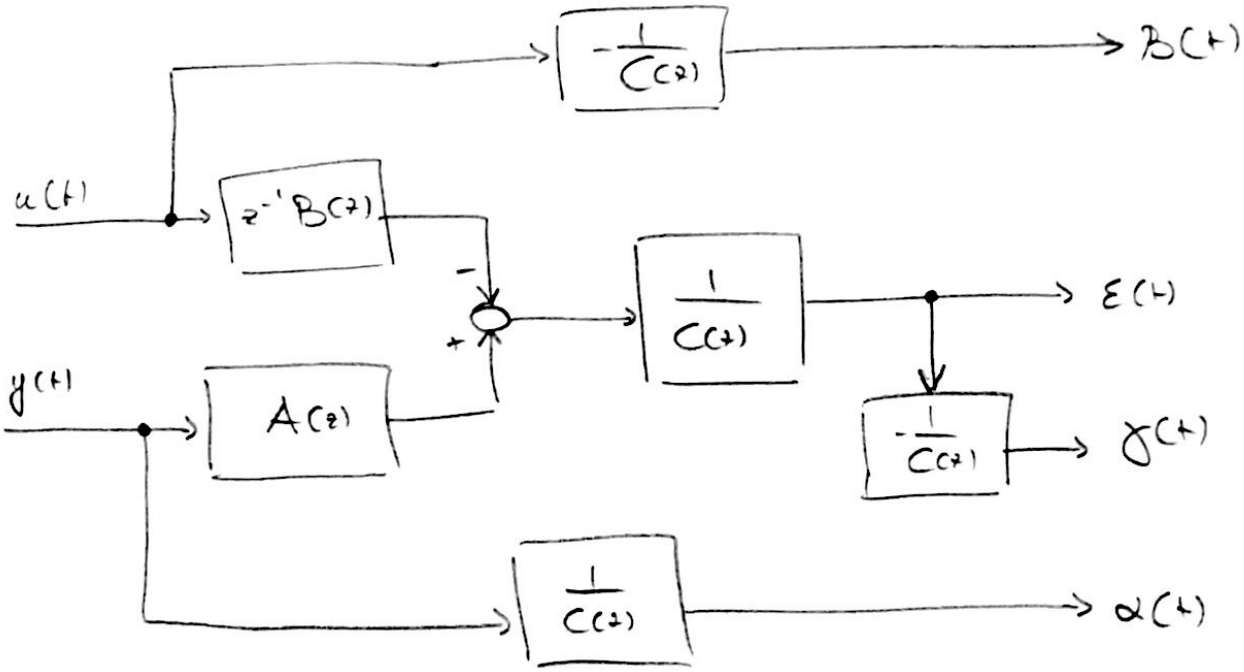

Osservazione

Dobbiamo verificare che $C(z)^{(i)}$ sia AS. STAB: se così è dobbiamo riportare i poli instabili nel cerchio unitario (METODO DI PAGER)

IDENTIFICAZIONE: ANALISI E COMPLEMENTI

ANALISI ASINTOTICA METODI PEM

Ipotizziamo di aver N dati $\{y(1), y(2), \dots, y(N)\}$, $\{u(1), u(2), \dots, u(N)\}$

La stima PEM trova $\hat{\theta}_N$ che minimizza: $J_N(\theta) = \frac{1}{N}\sum_{t=1}^{N} \varepsilon(t,\theta)^2$

↓

Come facciamo a sapere se questa stima è (almeno asintoticamente) buona?

Considerando $N \to \infty$, otteniamo che:

$$J_N(\theta) \xrightarrow[N\to\infty]{} J(\theta) = E\left[\varepsilon(t,\theta)^2\right]$$

L'insieme dei punti di minimo globale di $J(\theta)$ è $\Delta = \left\{ \bar{\theta} \mid J(\bar{\theta}) \geq J(\theta), \forall \theta \right\}$

Osservazioni

- Caso particolare: $\Delta = \bar{\theta}$ ($J(\theta)$ ha un unico minimo globale)
- Dato che $J_N(\theta) \xrightarrow[N\to\infty]{} J(\theta)$, ci aspettiamo che $\hat{\theta}_N \xrightarrow[N\to\infty]{} \Delta$

Supponiamo che $\boxed{S \in M(\theta)}$.

S: SISTEMA VERO

$M(\theta)$: CLASSE DI MODELLI M CON PARAMETRI θ

$$\Downarrow$$

$$\exists M(\theta^\circ) = S \qquad \theta^\circ: \text{VETTORE VERO DI PARAMETRI}$$

Dimostrazione

Consideriamo un modello $M(\theta)$ e scriviamo l'errore di predizione:

$$\varepsilon(t) = y(t) - \hat{y}(t|t-1,\theta) \Rightarrow \varepsilon(t) - \hat{y}(t|t-1,\theta^\circ) = y(t) - \hat{y}(t|t-1,\theta) - \hat{y}(t|t-1,\theta^\circ)$$

$$\Rightarrow \varepsilon(t) = e(t) - \hat{y}(t|t-1,\theta) + \hat{y}(t|t-1,\theta^\circ)$$

RUMORE BIANCO $e(t)$ che alimenta il sistema (è l'errore di predizione di un passo)

Applichiamo $E[(\,)^2]$ ad entrambi i membri:

$$E[\varepsilon(t)^2] = E\left[\left(e(t) + \left(\hat{y}(t|t-1,\theta^\circ) - \hat{y}(t|t-1,\theta)\right)\right)^2\right] =$$

considero gli ultimi 2 termini nella loro interezza

$$= E[e(t)^2] + E\left[\left(\hat{y}(t|t-1,\theta^\circ) - \hat{y}(t|t-1,\theta)\right)^2\right] + 2E\left[e(t)\cdot\left(\hat{y}(t|t-1,\theta^\circ) - \hat{y}(t|t-1,\theta)\right)\right]$$

$J(\theta)$

predittori incorrelati con $e(t)$

$$J(\theta) = \lambda^2 + \underbrace{E\left[\left(\hat{y}(t|t-1,\theta^\circ) - \hat{y}(t|t-1,\theta)\right)^2\right]}_{\geq 0,\ \text{si annulla per } \theta = \theta^\circ} + 0$$

$$\Rightarrow J(\theta) \geq \lambda^2 = J(\theta^\circ), \quad \forall \theta$$

$$\Downarrow$$

$$\boxed{J(\theta) \geq J(\theta^\circ) \quad \forall \theta}$$

Conclusione

Se $S \in \mathcal{M}(\theta)$, il metodo PEM è in grado di garantire che il modello stimato è quello vero, (nel caso in cui $N \to \infty$)

- PEM è ASINTOTICAMENTE CORRETTO
- PEM è ASINTOTICAMENTE CONSISTENTE (si minimizza la varianza dell'errore)

Se la classe di modelli è sbagliata, i metodi PEM non convergono ai parametri veri

Osservazione

Se $S \in \mathcal{M}(\theta)$, in corrispondenza di θ° si ha che $\varepsilon(t, \theta^\circ) = e(t) \sim WN$

↓

Si può fare un test di bianchezza per verificare che il modello identificato sia quello vero.

Quando identifichiamo un modello, possono capitarci diverse situazioni:

1) $S \in \mathcal{M}(\theta)$ e $\Delta = \bar{\theta} \equiv \theta^\circ$. La famiglia di modelli scelta è quella del sistema vero. $J(\theta)$ ha un unico minimo che è θ°. Allora avremo che $\hat{\theta}_N \xrightarrow[N \to +\infty]{} \theta^\circ$

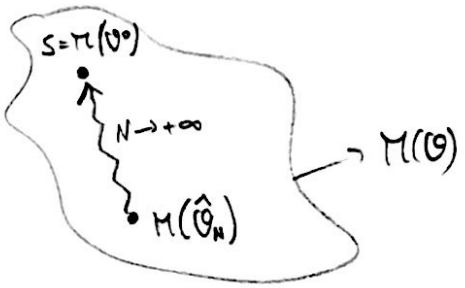

2) $S \in \mathcal{M}(\theta)$ ma Δ è costituito da più valori. Non è un problema tanto l'identificazione tra un set di parametri con lo stesso valore della cifra di merito,

sono equivalenti dal punto di vista predittivo

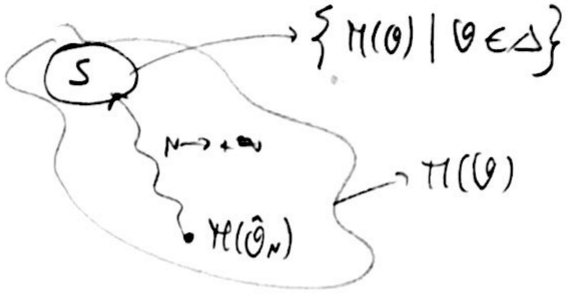

3) $S \notin \mathcal{M}(\theta)$ e $\Delta \equiv \bar{\theta}$. Si ottiene il modello $\mathcal{M}(\bar{\theta})$ <u>miglior approssimante</u> di S nella classe di modelli $\mathcal{M}(\theta)$ scelta

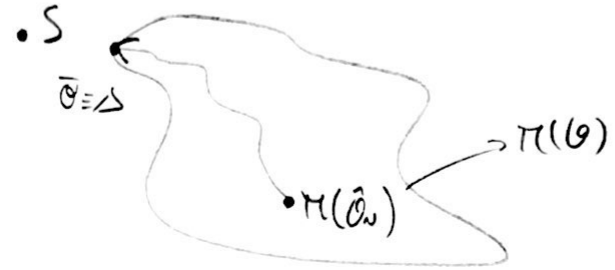

4) $S \notin \mathcal{M}(\theta)$ e Δ è costituito da più valori

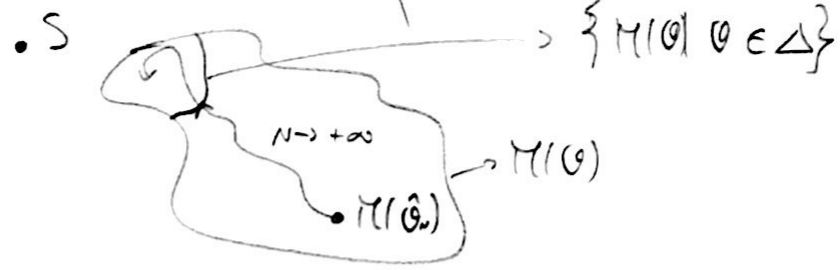

IDENTIFICABILITÀ DEI MODELLI

Abbiamo visto che i metodi PEM sono ASINTOTICAMENTE CORRETTI. Analizziamo come ottenevamo le stime (nel caso ARX $(m, p+1)$)

$$y(t) = \frac{B(z)}{A(z)} u(t-1) + \frac{1}{A(z)} e(t) \qquad e(t) \sim WN(0, \lambda^2) \qquad B(z) = b_0 + b_1 z^{-1} + \dots + b_p z^{-p}$$

$$A(z) = 1 + a_1 z^{-1} + \dots + a_m z^{-m}$$

$$\hat{\theta}_N = \left[\sum_{t=1}^{N} \varphi(t) \varphi(t)^T \right]^{-1} \cdot \left[\sum_{t=1}^{N} \varphi(t) y(t) \right] = \underset{d \times N}{\left(\Phi^T\right)} \underset{N \times d}{\left(\Phi\right)}^{-1} \underset{d \times 1}{\Phi^T Y}$$

PROBLEMA DI IDENTIFICABILITÀ

Quando $\hat{\theta}_N$ esiste ed è unico $\iff$ Quando $\sum_{t=1}^{N} \underset{d \times 1}{\varphi(t)} \underset{1 \times d}{\varphi(t)^T}$ è invertibile?

$$S(N) = \sum_{t=1}^{N} \underset{d \times 1}{\varphi(t)} \underset{1 \times d}{\varphi(t)^T} \implies \hat{\theta}_N = S(N)^{-1} \cdot \left[\sum_{t=1}^{N} \varphi(t) y(t) \right]$$

$$R(N) = \frac{1}{N} S(N) = \frac{1}{N} \sum_{t=1}^{N} \varphi(t) \varphi(t)^T \implies \hat{\theta}_N = R(N)^{-1} \left[\frac{1}{N} \sum_{t=1}^{N} \varphi(t) y(t) \right]$$

$R(N) \geq 0$ in quanto prodotto di un vettore per se stesso. Affinché $\hat{\theta}_N$ esista e sia unico occorre però che $R(N) > 0$ (DEF. POS) e quindi abbia tutti gli autovalori POSITIVI

Consideriamo il CASO ASINTOTICO $N \to +\infty \implies R(N) \xrightarrow[N \to \infty]{} \bar{R}$

Per un ARX $(m, p+1)$, $\bar{R}$ è una matrice quadrata $\underbrace{(m+p+1)}_{d} \times \underbrace{(m+p+1)}_{d}$ t.c:

$$\bar{R} = \begin{bmatrix} \bar{R}_y & -\bar{R}_{yu} \\ -\bar{R}_{uy} & \bar{R}_u \end{bmatrix} \in \mathbb{R}^{\underbrace{(m+p+1)}_{d} \times \underbrace{(m+p+1)}_{d}}$$

- ARX $(1,1) \implies \varphi(t) = \begin{bmatrix} -y(t-1) \\ u(t-1) \end{bmatrix} \implies R(N) = \frac{1}{N} \sum_{t=1}^{N} \varphi(t) \cdot \varphi(t)^T = \frac{1}{N} \sum_{t=1}^{N} \begin{bmatrix} -y(t-1) \\ u(t-1) \end{bmatrix} \begin{bmatrix} -y(t-1) & u(t-1) \end{bmatrix}$

$$= \frac{1}{N} \sum_{t=1}^{N} \begin{bmatrix} +y(t-1)^2 & -y(t-1)u(t-1) \\ -u(t-1)y(t-1) & u(t-1)^2 \end{bmatrix}$$

Se $N \to +\infty$ abbiamo (dato che la stimatore della covarianza è ASINT. CORRETTO)

$$\bar{R} = \begin{bmatrix} E[y(t-1)^2] & -E[u(t-1)\,y(t-1)] \\ -E[u(t-1)\,y(t-1)] & E[u(t-1)^2] \end{bmatrix}$$

IPOTESI

$u(t)$ e $y(t)$ sono PSS

$$= \begin{bmatrix} \gamma_y(0) & -\gamma_{yu}(0) \\ -\gamma_{uy}(0) & \gamma_u(0) \end{bmatrix}$$

$\to \bar{R}_y$ (prima riga) — $\to -R_{yu}$ — $\to -R_{uy}$ — $\to \bar{R}_u$

$\bar{R}$ è la matrice di VARIANZE - COVARIANZE

In generale:

$$\bar{R}_y = \begin{bmatrix} \gamma_y(0) & \gamma_y(1) & \cdots & \gamma_y(m-1) \\ \gamma_y(1) & \gamma_y(0) & \gamma_y(1) & \\ \vdots & \gamma_y(1) & & \\ \gamma_y(m-1) & & & \gamma_y(0) \end{bmatrix}$$

- Matrice $m \times m$
- Matrice covarianza di ordine $m-1$ di $y(t)$
- Toeplitz

$$\bar{R}_u = \begin{bmatrix} \gamma_u(0) & \gamma_u(1) & \cdots & \gamma_u(p) \\ \gamma_u(1) & \gamma_u(0) & \gamma_u(1) & \\ \vdots & \gamma_u(1) & & \\ \gamma_u(p) & & & \gamma_u(0) \end{bmatrix}$$

- Matrice $(p+1) \times (p+1)$
- Matrice covarianza ordine p di $u(t)$
- Toeplitz

$$\bar{R}_{yu} = \begin{bmatrix} \gamma_{yu}(0) & \gamma_{yu}(1) & \cdots & \gamma_{yu}(0) \\ \gamma_{yu}(1) & \gamma_{yu}(0) & \gamma_{yu}(1) & \\ & & & \\ \gamma_{yu}(m-1) & & & \gamma_{yu}(0) \end{bmatrix}$$

- Matrice rettangolare $m \times (p+1)$
- Matrice covarianza $u(t)$ e $y(t)$
- $\bar{R}_{uy} = \bar{R}_{yu}^T$

Vogliamo una condizione per l'invertibilità di $\bar{R}$

Lemma di Schur

Data una matrice H nella forma $H = \begin{bmatrix} F & K \\ K^T & H \end{bmatrix}$, con F e H simmetriche condizione <u>necessaria</u> e <u>sufficiente</u> affinché $H>0$ è che: - $H>0$

- $F - KH^{-1}K^T > 0$

$$\bar{R} = \begin{bmatrix} \bar{R}_y & -\bar{R}_{yu} \\ -\bar{R}_{uy} & \bar{R}_u \end{bmatrix} \rightarrow H \quad \Rightarrow \boxed{\begin{array}{l} \text{CONDIZIONE NECESSARIA per invertire } \bar{R} \text{ è che} \\ \bar{R}_u > 0 \end{array}}$$

↓

la seconda condizione ($F - KH^{-1}K^T > 0$) è difficile da valutare. Cerchiamo di imporre almeno le prime

La condizione $\bar{R}_u > 0$ riguarda solo l'ingresso $u(t)$, che progettiamo noi!

Sia:

$$\bar{R}_u^{(i)} = \begin{bmatrix} \gamma_u(0) & \gamma_u(1) & \cdots & \gamma_u(i-1) \\ \gamma_u(1) & & & \gamma_u(i-2) \\ & & & \\ \gamma_u(i-1) & & & \gamma_u(0) \end{bmatrix}$$

la matrice di covarianza di $u(t)$, di ordine i

↓

Un segnale $u(t)$ è detto <u>PERSISTENTEMENTE ECCITANTE DI ORDINE m</u> se:

- $\bar{R}_u^{(1)} > 0$, $\bar{R}_u^{(2)} > 0$, —, $\bar{R}_u^{(m)} > 0$
- $\bar{R}_u^{(m+1)} > 0$, $\bar{R}_u^{(m+2)} > 0$, — ≥ 0

avere m è l'ordine massimo di $\bar{R}_u^{(i)}$ per cui questa matrice è invertibile

⇓

Condizione <u>NECESSARIA</u> per l'identificabilità di un modello ARX$(m, p+1)$ è che il segnale $u(t)$, usato per produrre i dati, sia "persistentemente eccitante" di ordine <u>pari ad almeno</u> $p+1$

Osservazione

Consideriamo $u(t) \sim WN(0, \lambda^2)$. Abbiamo che:

$$\bar{R}_u^{(i)} = \begin{bmatrix} \lambda^2 & 0 & 0 & \cdots & 0 \\ 0 & \lambda^2 & & & \\ | & & \lambda^2 & & \\ 0 & & & & \lambda^2 \end{bmatrix} = \lambda^2 \cdot \underline{I}^{(i)}$$

- Il WN è un segnale persistentemente eccitante di ordine ∞
- Se usiamo un WN per identificare il sistema, siamo certi che è un segnale sufficientemente ricco di informazioni per poter identificare il sistema
- Il WN eccita tutte le frequenze, avendo uno spettro piatto

Osservazione

La condizione vista è solo NECESSARIA. Anche con $u(t) \sim WN$ la $\bar{R}$ potrebbe non essere invertibile

Es

- Il sistema vero è ARX(1,1)
- Lo eccitiamo con $u(t) \sim WN$
- Il modello usato è ARX(3,3)

$\Rightarrow$ Dato che il modello è SOVRAPARAMETRIZZATO esistono ∞ soluzioni (tutte le cancellazioni polo-zero)

↓

SCELTA COMPLESSITÀ DEL MODELLO

Affinché un modello sia univocamente identificabile occorre avere:

1) IDENTIFICABILITÀ "STRUTTURALE": il modello non deve essere sovraparametrizzato rispetto al sistema

2) IDENTIFICABILITÀ "SPERIMENTALE": i dati devono contenere sufficiente informazione

VALUTAZIONE DELL'INCERTEZZA

Le analisi fatte in precedenza si basavano sull'ipotesi che $N \to +\infty$. Nella realtà abbiamo N finito.

IPOTESI

- $SEM(\theta) \Rightarrow \theta^\circ \in \Delta$
- Se $\Delta \equiv \bar{\theta} \Rightarrow \bar{\theta} = \theta^\circ$

$\Rightarrow$

Stimiamo $\hat{\theta}_N$ con N dati:

$\hat{\theta}_N = \arg\min_\theta J_N(\theta) = \frac{1}{N}\sum_{t=1}^{N} \varepsilon(t,\theta)^2$

↳ È UNA VARIABILE CASUALE!

↓

Dalle ipotesi abbiamo che $E[\hat{\theta}_N] = \theta^\circ$

La varianza dello stimatore è:

$$Var[\hat{\theta}_N] = \frac{1}{N}\lambda^2 \cdot \bar{H}^{-1}$$

- $\lambda^2 = Var[e(t)] = Var[\underbrace{y(t) - \hat{y}(t|t-1,\theta^\circ)}_{Var[\varepsilon(t,\theta^\circ)]}]$
- $\bar{H} = E\left[\left(\left.\frac{d\varepsilon(t,\theta)}{d\theta}\right|_{\theta=\theta^\circ}\right)\cdot\left(\left.\frac{d\varepsilon(t,\theta)}{d\theta}\right|_{\theta=\theta^\circ}\right)^T\right]$

Come stimiamo in pratica λ^2 e $\bar{H}$?

$$\lambda^2 = E[\varepsilon(t,\theta^\circ)] \approx E[\varepsilon(t,\hat{\theta}_N)] \approx \frac{1}{N}\sum_{t=1}^{N}\left(y(t) - \hat{y}(t|t-1;\hat{\theta}_N)\right)^2 = J_N(\hat{\theta}_N)$$

$$\bar{H} \approx \hat{H} = \frac{1}{N}\sum_{t=1}^{N}\left[\left(\left.\frac{d\varepsilon(t,\theta)}{d\theta}\right|_{\theta=\hat{\theta}_N}\right)\cdot\left(\left.\frac{d\varepsilon(t,\theta)}{d\theta}\right|_{\theta=\hat{\theta}_N}\right)^T\right]$$

Interpretazione di $\bar{H}$

Ricordiamo che $J(\theta) = E[\varepsilon(t,\theta)^2] \Rightarrow \frac{dJ(\theta)}{d\theta} = E\left[2\varepsilon(t,\theta)\frac{d\varepsilon(t,\theta)}{d\theta}\right]$

$$\Rightarrow \frac{d^2J(\theta)}{d\theta^2} = E\left[2\frac{d\varepsilon(t,\theta)}{d\theta}\cdot\frac{d\varepsilon(t,\theta)}{d\theta}^T + 2\varepsilon(t,\theta)\frac{d^2\varepsilon(t,\theta)}{d\theta^2}\right]$$

Se $\theta = \theta^\circ \Rightarrow \varepsilon(t,\theta) = e(t) \Rightarrow \frac{d^2\varepsilon(t,\theta)}{d\theta^2}$ è funzione dell'errore di predizione e dipende da $e(t-1), e(t-2), \ldots$

$\Downarrow$ quindi $\frac{d\varepsilon(t)}{d\theta} = \frac{d[y(t) - \hat{y}(t|t-1,\theta)]}{d\theta} \Rightarrow$ dipende da $e(t-1), \ldots$

il predittore è costruito con $e(t-1)$ ← $\varepsilon(t) = y(t) - \hat{y}(t|t-1) = e(t)$

$\Downarrow$

Il termine $E\left[2\varepsilon(t)\,\frac{d^2\varepsilon(t)}{d\theta^2}\right] = E\left[2e(t)\cdot\frac{d^2\varepsilon(t)}{d\theta^2}\right] = 0$ → dipende da $e(t-1)$, —

Osserviamo che:

$$\left.\frac{d^2J(\theta)}{d\theta^2}\right|_{\theta=\theta^0} = 2E\left[\left(\left.\frac{d\varepsilon(t,\theta)}{d\theta}\right|_{\theta=\theta^0}\right)\cdot\left(\left.\frac{d\varepsilon(t,\theta)}{d\theta}\right|_{\theta=\theta^0}\right)^T\right] = 2\bar{H}$$

$\Downarrow$

$$\boxed{\bar{H} = \frac{1}{2}\left.\frac{d^2J(\theta)}{d\theta^2}\right|_{\theta=\theta^0}}$$

- $\bar{H}$ è metà dell'Hessiano della cifra di merito valutata nell'ottimo θ^0

Conclusione

$$Var\left[\hat{\theta}_N\right] = \frac{1}{N}\cdot\lambda^2\cdot\bar{H}^{-1} = \frac{1}{N}\lambda^2\cdot\frac{1}{2}\left.\frac{d^2J(\theta)}{d\theta^2}\right|_{\theta=\theta^0}$$

- $N\uparrow \Rightarrow Var\left[\hat{\theta}_N\right]\downarrow$
- $\lambda^2 \Rightarrow Var\left[\hat{\theta}_N\right]\uparrow$
- $\bar{H}\uparrow \Rightarrow Var\left[\hat{\theta}_N\right]\downarrow \Rightarrow$ Si vuole avere Hessiano grande nel punto di minimo (grande variazione dell'intorno del minimo)

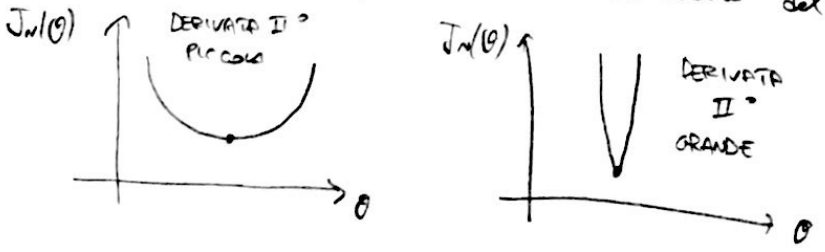

SCELTA DELLA COMPLESSITÀ DEL MODELLO

Scelta una classe di modelli $M(\theta)$, troviamo $\hat{\theta}_N$ nel seguente modo:

$$\hat{\theta}_N = \arg\min_{\theta} J_N(\theta) \qquad J_N(\theta) = \frac{1}{N}\sum_{t=1}^{N}\left(y(t) - \hat{y}(t|t-1)\right)^2$$

- Se $M(\theta)$ è un ARX $\Rightarrow$ esiste una forma esplicita per $\hat{\theta}_N$
- Se $M(\theta)$ è un ARMAX $\Rightarrow$ va risolto iterativamente un problema di ottimizzazione

d: dimensione di θ.

Nel caso generale ARMAX abbiamo $d = m + n + p + 1$

$\Downarrow$

Problema: scelta dell'ordine d del modello

Osservazione

In realtà dobbiamo scegliere 3 parametri (m, p, n), con 1 (d). Per semplicità, si fissa $m = n = p$, gestendo quindi un solo parametro, d

Supponiamo già che non è ovvio scegliere l'ordine del modello con minor $J_N(\hat{\theta}_N) \Rightarrow$ OVERFITTING

Vediamo quindi 3 metodi, che si basano sull'idea:

- N dati
- ordine del modello $d = 1, 2, 3, 4, \dots$
- $J_N(\hat{\theta}_N, d)$ è il valore della cifra di merito valutata all'"ottimo" (ovvero dopo aver trovato il miglior modello di dimensione d)

METODO 1 : TEST DI BIANCHEZZA

Procedura:
- Fissare un valore di d
- Trovare $\hat{\theta}_N$
- Calcolare $J_N(\hat{\theta}_N, d)$
- Test di bianchezza su $\varepsilon(t, \hat{\theta}_N) = y(t) - \hat{y}(t|t-1; \hat{\theta}_N)$
- Ripetere per $d = 1, 2, 3, 4, \dots$

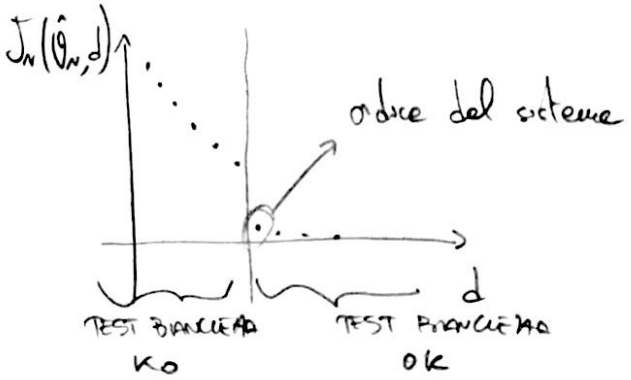

In realtà questo metodo funziona male
- Paramete le le "discontinuità"
- Il test di bianchezza va dà una discontinuità netta (da un "salto" di valori)

METODO 2: CROSS-VALIDAZIONE

Divido i dati in 2 sottoinsiemi

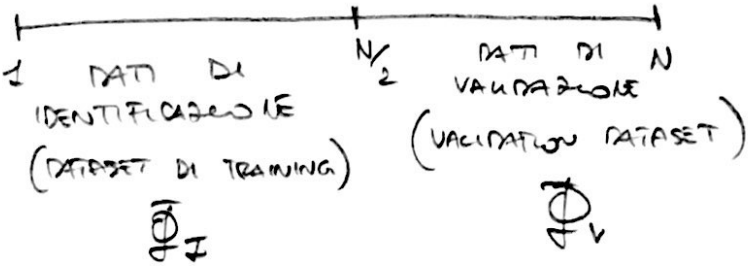

- Fisso un valore di d
- Trovo $\hat{\theta}_N$ minimizzando $J_N(\theta, \Phi_I)$
- Calcolo $J_N(\hat{\theta}_N, \Phi_I)$ e $J_N(\hat{\theta}_N, \Phi_V)$
  (IN-SAMPLE ERROR / OUT OF SAMPLE ERROR)
- Ripeto per $d = 1, 2, 3, 4, \dots$

Nota
Quelli che $J_N(\theta, \Phi_I)$ e $J_N(\theta, \Phi_V)$ è la dipendenza da d

La differenza rispetto al caso statico è che NON POSSO MISCHIARE I DATI, perché adesso c'è una dipendenza dal tempo

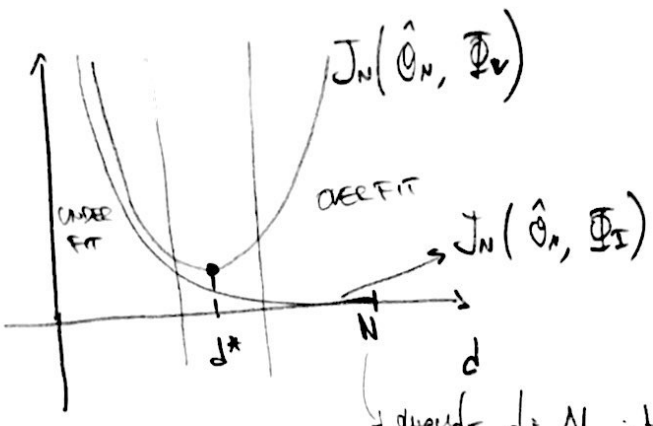

↳ quando d = N, interpolo: dati perfettamente

la cross-validazione è la procedura migliore, però richiede molti dati

METODO 3: FORMULE PER LA STIMA DELLA COMPLESSITÀ OTTIMA

Permettono di stimare OUT OF SAMPLE ERROR senza usare dati diversi rispetto ai dati di identificazione (di train) ⇒ modifico la cifra di merito e la minimizzo

↓

Sono state ricavate teoricamente per ARX, ma in pratica si usano anche per ARMAX

FINAL PREDICTION ERROR (FPE)

$$FPE(d) = \frac{N+d}{N-d} \cdot J_N(\hat{\theta}_N, d)$$

- $d \uparrow \Rightarrow \frac{N+d}{N-d} \uparrow$
- $d \uparrow \Rightarrow J_N(\hat{\theta}_N, d) \downarrow$

Il metodo predilige modelli con d grandi

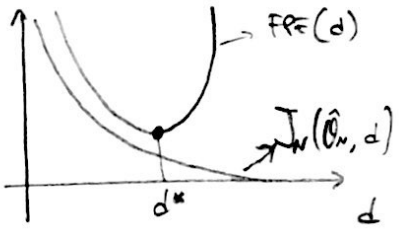

AKAIKE INFORMATION CRITERION (AIC)

$$AIC(d) = 2 \cdot \frac{d}{N} + \ln\left[J_N(\hat{\theta}_N, d)\right]$$

- $d \uparrow \Rightarrow 2 \cdot \frac{d}{N} \uparrow$
- $d \uparrow \Rightarrow \ln[J_N(\hat{\theta}_N, d)] \downarrow$

- **MINIMUM DESCRIPTION LENGTH (MDL)**

$$MDL(d) = \ln(N) \cdot \frac{d}{N} + \ln\left[J_N(\hat{\theta}_N, d)\right]$$

- $d \uparrow \Rightarrow \ln(N) \cdot \frac{d}{N} \uparrow$
- $d \uparrow \Rightarrow \ln\left[J_N(\hat{\theta}_N, d)\right] \downarrow$

CONFRONTO FPE vs AIC

I due criteri sono simili. Se si calcola il logaritmo di FPE si ottiene:

$$\ln\left[FPE(d)\right] = \ln\left[\frac{N+d}{N-d} \cdot J_N(\hat{\theta}_{N,d})\right] = \ln\left[\frac{1+\frac{d}{N}}{1-\frac{d}{N}} \cdot J_N(\hat{\theta}_{N,d})\right] =$$

$$= \ln\left[\frac{1+\frac{d}{N}}{1-\frac{d}{N}}\right] + \ln\left[J_N(\hat{\theta}_{N,d})\right] =$$

$$= \ln\left[1+\frac{d}{N}\right] - \ln\left[1-\frac{d}{N}\right] + \ln\left[J_N(\hat{\theta}_{N,d})\right]$$

Ricordiamo che $\ln(1+x) \approx x$ quando $x \approx 0$; inoltre $\frac{d}{N} \approx 0$ per evitare overfitting

$$\ln\left[FPE(d)\right] \approx \frac{d}{N} - \left(-\frac{d}{N}\right) + \ln\left[J_N(\hat{\theta}_N, d)\right]$$

$$\approx 2\frac{d}{N} + \ln\left[J_N(\hat{\theta}_N, d)\right] = AIC(d)$$

Quindi, se $d \ll N$ $\Rightarrow$ $\ln\left[FPE(d)\right] \approx AIC$

(come per la LIKELIHOOD)

Il minimo di $f(x)$ è anche il minimo di $\ln\left[f(x)\right]$, quindi i metodi sono equivalenti

CONFRONTO AIC vs MDL

$$AIC(d) = 2 \cdot \frac{d}{N} + \ln\left[J_N(\hat{\theta}_N)\right] \quad \rightleftharpoons \quad MDL(d) = \ln(N) \cdot \frac{d}{N} + \ln\left[J_N(\hat{\theta}_N)\right]$$

: condizione sugli unici termini

Se $\ln(N) > 2$, ovvero abbiamo più di 8 dati, MDL penalizza di più, e quindi suggerisce di usare modelli più parsimoniosi.

HDL quindi diminisce il rischio di fare overfitting (a scapito di un maggior rischio di fare underfitting)

↓

- Nel caso in cui la scelta della famiglia di modelli è sicura, è possibile usare AIC o ~~FPE~~, in quanto il rischio di fare overfitting è minore
- Nel caso in cui non si conosce nulla del sistema, è meglio usare HDL, essendo più robusto a overfitting

FINE